# 第三章 随机向量

提 纲

§ 3.1 随机向量及其联合分布

§ 3.2 边际分布与随机变量的独立性

§ 3.3 条件分布

§ 3.4 随机向量函数的分布

§ 3.5 数字特征

# § 3.1 随机向量及其联合分布

## 一、随机向量

对于较复杂的随机现象，用单个 r.v.去研究是不够的，往往需要同时用多个 r.v.、从多个侧面去刻画；往往需要考察各个 r.v.之间的联系。这就产生了随机向量的概念。

**定义 3.1.1** 设 $X_1(\omega),\cdots,X_k(\omega)$ 是定义在可测样本空间 $(\Omega,\mathcal{F})$ 上的 $k$ 个随机变量，称由它们组成的 $k$ 维向量 $(X_1(\omega),\cdots,X_k(\omega))'$ 为 $(\Omega,\mathcal{F})$ 上的 $k$ 维随机向量 (random vector)。

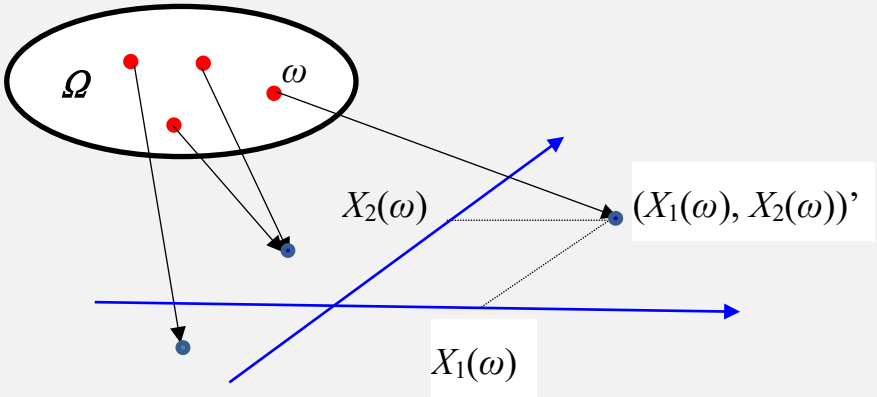

**例 3.1.1** 随机向量的例子。

- 研究某股票市场日波动的规律性，单看综合指数的日收盘值($X_1$)一般不够，往往还要研究日最高值($X_2$)、最低值($X_3$)、交易量($X_4$)、交易笔数($X_5$)等多个指标。若用$\omega$表示股市一天内可能出现的情况，那么 $(X_1,\cdots,X_5)'$ 就是描述 $\omega$ 的一个五维随机向量。
- 测试一个人的外语水平，通常在一次测试中需要同时得到听力($X_1$)、语法($X_2$)、阅读($X_3$)、写作($X_4$)等几方面的成绩。$(X_1,\cdots,X_4)'$ 即为描述一个人外语水平的一个四维随机向量。
- 一项试验由独立重复的 $n$ 次成功概率为 $p$ 的 Bernoulli 试验组成。记 $X_i$ 为第 $i$ 次试验中的成功次数，$i=1,\cdots,n$。则 $(X_1,\cdots,X_n)'$ 是描述该项试验的一个 $n$ 维的随机向量。
- 一项试验中独立地测试 $n$ 个产品的寿命。记 $X_i$ 为第 $i$ 个产品的寿命，$i=1,\cdots,n$，则 $(X_1,\cdots,X_n)'$ 是描述该试验的一个 $n$ 维的随机向量。
- 有时候也可能研究看似没有关系的随机现象之间的联系，比如股市综指日收盘值($X_1$)与某地当日平均气温($X_2$)之间的关系。

**命题 3.1.1** $\boldsymbol{X}(\omega)=(X_1(\omega),\cdots,X_k(\omega))'$ 为 $(\Omega,\mathcal{F})$ 上的 $k$ 维随机向量的充要条件是：$\boldsymbol{X}(\omega)$ 为 $(\Omega,\mathcal{F})\to(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 的可测映照。且 $\sigma(\boldsymbol{X})=\sigma(\bigcup_{i=1}^k\sigma(X_i))$。

**证明：**

必要性。由例 1.2.5/2)知，$\mathcal{B}_{\mathbb{R}^k}=\sigma(\mathcal{D})$，其中 $\mathcal{D}=\{\times_{i=1}^k(-\infty,b_i]:(b_1,\cdots,b_k)'\in\mathbb{R}^k\}$。对于 $\forall B\in\mathcal{D}$，

$$\boldsymbol{X}^{-1}(B)=\{\omega\in\Omega:\boldsymbol{X}(\omega)\in B\}=\bigcap_{i=1}^k\{\omega\in\Omega:X_i(\omega)\in(-\infty,b_i]\}=\bigcap_{i=1}^kX_i^{-1}((-\infty,b_i])。$$

因 $X_i$ 是 $(\Omega,\mathcal{F})$ 上的 r.v.，故 $X_i^{-1}((-\infty,b_i])\in\sigma(X_i)\subset\mathcal{F},i=1,\cdots,k$，故 $\boldsymbol{X}^{-1}(B)\in\sigma(\bigcup_{i=1}^k\sigma(X_i))\subset\mathcal{F}$。这说明 $\boldsymbol{X}^{-1}(\mathcal{D})\subset\sigma(\bigcup_{i=1}^k\sigma(X_i))$，由定理 2.1.1 知，$\boldsymbol{X}^{-1}(\mathcal{B}_{\mathbb{R}^k})\subset\sigma(\bigcup_{i=1}^k\sigma(X_i))\subset\mathcal{F}$，即 $\boldsymbol{X}(\omega)$ 为 $(\Omega,\mathcal{F})\to(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 的可测映照，且 $\sigma(\boldsymbol{X})\subset\sigma(\bigcup_{i=1}^k\sigma(X_i))$。

充分性。对于 $\forall b_i\in\mathbb{R}$，$X_i^{-1}((-\infty,b_i])=\boldsymbol{X}^{-1}(\mathbb{R}\times\cdots\times(-\infty,b_i]\times\cdots\times\mathbb{R})\in\sigma(\boldsymbol{X})\subset\mathcal{F}$，故由定理 2.1.1 知 $\sigma(X_i)=X_i^{-1}(\mathcal{B}_{\mathbb{R}})\subset\sigma(\boldsymbol{X}),i=1,\cdots,k$。故 $X_1,\cdots,X_k$ 都是 $(\Omega,\mathcal{F})$ 上的 r.v.，且 $\sigma(\bigcup_{i=1}^k\sigma(X_i))\subset\sigma(\boldsymbol{X})$。

命题 3.1.1 给出了 r.vec. 的等价定义：$(\Omega,\mathcal{F})\to(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 的可测映照称为 $(\Omega,\mathcal{F})$ 上的 $k$ 维 r.vec.。

**定义 3.1.2 (r.vec.的概率分布)** 设 $(\Omega,\mathcal{F},P)$ 是一个概率空间，$\boldsymbol{X}$ 是 $(\Omega,\mathcal{F})$ 上的 $k$ 维 r.vec.。令

$$P_X(A)=P(\boldsymbol{X}^{-1}(A))=P(\boldsymbol{X}\in A),\quad \forall A\in\mathcal{B}_{\mathbb{R}^k},$$

则 $P_X(\cdot)$ 为由 r.vec. $\boldsymbol{X}$ 在 $(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 上导出的概率测度，称之为 r.vec. $\boldsymbol{X}$ 的概率分布。

与 r.v.一样，r.vec.的概率分布也取决于 $P(\cdot)$。引进 r.vec. 就是要通过它的概率分布去研究随机现象。与 r.v.类似，由于 $\mathcal{B}_{\mathbb{R}^k}=\sigma(\mathcal{D})$，其中 $\mathcal{D}=\{\times_{i=1}^k(-\infty,b_i]:(b_1,\cdots,b_k)'\in\mathbb{R}^k\}$ 是一个 $\pi$ 类，由引理 1.2.1 知，$(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 上的任一概率测度都由 $\mathcal{D}$ 中各事件的概率值唯一确定，因而 $k$ 维 r.vec.的概率分布也是如此。用一个 $k$ 元实函数记录 $\mathcal{D}$ 中各事件的概率值，便得到了一个能全面刻画 $(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 上概率测度的工具——联合分布函数。

**定义 3.1.3 (联合分布函数)** 设 $P_X(\cdot)$ 为 $(\mathbb{R}^k, \mathcal{B}_{\mathbb{R}^k})$ 上的概率测度，称 $k$ 元实函数

$$F(x_1,\cdots,x_k) = P_X(\mathop{\times}_{i=1}^{k}(-\infty, x_i]), \quad (x_1,\cdots,x_k) \in \mathbb{R}^k$$

为 $P_X(\cdot)$ 的分布函数。若 $P_X(\cdot)$ 是 r.vec. $\boldsymbol{X} = (X_1,\cdots,X_k)'$ 的概率分布，则也称其分布函数

$$F(x_1,\cdots,x_k) = P(\boldsymbol{X} \in \mathop{\times}_{i=1}^{k}(-\infty, x_i]) = P(X_1 \le x_1,\cdots,X_k \le x_k), \quad (x_1,\cdots,x_k) \in \mathbb{R}^k$$

为 r. vec. $\boldsymbol{X}$ 的联合分布函数 (joint distribution function, j.d.f.)。

**注：**定义中事件

$$\begin{aligned}\{X_1 \le x_1,\cdots,X_k \le x_k\} &= \{\omega \in \Omega : X_1(\omega) \le x_1,\cdots,X_k(\omega) \le x_k\} \\ &= \bigcap_{i=1}^{k}\{\omega \in \Omega : X_i(\omega) \le x_i\} = \bigcap_{i=1}^{k}\{X_i \le x_i\}.\end{aligned}$$

$k=2$ **的情况**。设随机向量 $(X,Y)'$ 的 j.d.f. 为 $F(x,y)$，则

$$P(X\le a, Y\le b)=F(a,b).$$

$$P(a<X\le b, c<Y\le d)$$
$$=F(b,d)-F(a,d)-F(b,c)+F(a,c).$$

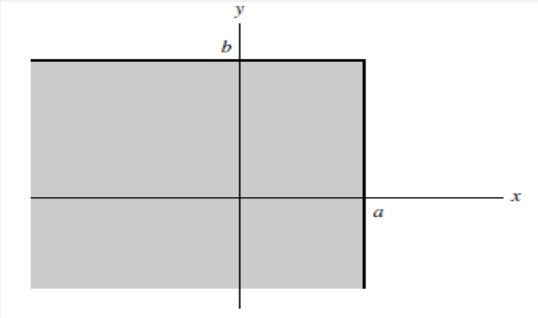


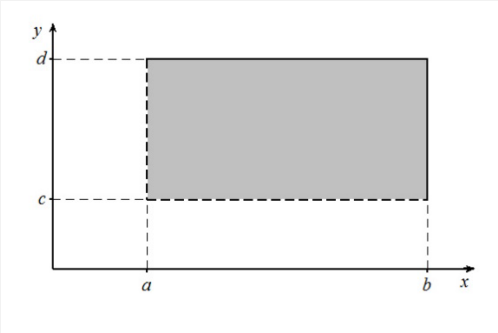


$$P(X\le x)=P(X\le x, Y<\infty)=\lim_{y\to\infty}F(x,y)\hat{=}F(x,\infty),\quad P(Y\le y)=F(\infty,y).$$

$$P(X\le x, Y<y)=\lim_{y'\to y-}F(x,y')=F(x,y-0),\quad P(X<x, Y\le y)=F(x-0,y).$$

$$P(X<x, Y<y)=\lim_{x'\to x-,y'\to y-}F(x',y')=F(x-0,y-0).$$

**问题：**若随机向量 $(X,Y)'$ 的 jdf 为 $F(x,y)$，则随机向量 $(Y,X)'$ 的 jdf 是什么？

**定理 3.1.1 (联合分布函数的基本性质)** 若 $k$ 元实函数 $F(\cdot)$ 是某 $k$ 维 r.vec.的 j.d.f.（或 $(\mathbb{R}^k, \mathcal{B}_{\mathbb{R}^k})$ 上某概率测度的 d.f.），则 $F(\cdot)$ 必满足：

a) (单调性) $\forall c < d,\ F(x_1,\cdots,x_{j-1},c,x_{j+1},\cdots,x_k) \le F(x_1,\cdots,x_{j-1},d,x_{j+1},\cdots,x_k),\ j=1,\cdots,k;$

b) (有界性)

$$F(x_1,\cdots,-\infty,\cdots,x_k) = \lim_{x_j\to-\infty} F(x_1,\cdots,x_{j-1},x_j,x_{j+1},\cdots,x_k) = 0,\ j=1,\cdots,k,$$

$$F(+\infty,\cdots,+\infty) = 1.$$

c) (右连续性)

$$\forall (x_1,\cdots,x_k) \in \mathbb{R}^k,\ F(x_1,\cdots,x_j+,\cdots,x_k) = F(x_1,\cdots,x_j,\cdots,x_k),\ j=1,\cdots,k\ 。$$

这三条是 j.d.f. 的必要条件，但不充分。$k=2$ 时，$F(.,.)$ 还需满足

d) $\forall a_1 < b_1, a_2 < b_2$， $F(b_1,b_2) - F(a_1,b_2) - F(b_1,a_2) + F(a_1,a_2) \ge 0$

才能成为二维 j.d.f.。更一般地，当 $k \ge 2$ 时，$F(.)$ 要成为 $k$ 维 j.d.f. 还需满足

d) 对于任意满足 $a_i < b_i, i = 1, \cdots, k$ 的 $\boldsymbol{a} = (a_1, \cdots, a_k)', \boldsymbol{b} = (b_1, \cdots, b_k)'$，有

$$\Delta_{\boldsymbol{ab}}^k F = F(b_1, \cdots, b_k) - \sum_{i_1} F(b_1, \cdots, b_{i_1-1}, a_{i_i}, b_{i_1+1}, \cdots, b_k)$$
$$+ \sum_{i_1 < i_2} F(b_1, \cdots, a_{i_1}, \cdots, a_{i_2}, b_{i_2+1}, \cdots, b_k) - \cdots + (-1)^k F(a_1, \cdots, a_k) \geq 0.$$

**例 3.1.2** 二元函数

$$G(x, y) = \begin{cases} 0, & x + y < 0, \\ 1, & x + y \geq 0. \end{cases}$$

满足二维 j.d.f. 的性质 a)~c)，但不满足 d)，故不是一个 j.d.f.。

**多元概率分布的支撑 (support)** 设 $P$ 是 $(\mathbb{R}^k, \mathcal{B}_{\mathbb{R}^k})$ 上的概率分布(测度)，称集合

$$S = \left\{ x \in \mathbb{R}^k : P(\delta_\varepsilon(x)) > 0, \delta_\varepsilon(x) = \{\tilde{x} : \|\tilde{x} - x\| < \varepsilon\}, \forall \varepsilon > 0 \right\}$$

为 $P$ 的支撑。也常称满足 $P(B) = 1$ 且 $B \subset S$ 的 $B$ 为 $P$ 的支撑。

## 二、离散型随机向量

**定义 3.1.4** 若 $S_X \subset \mathbb{R}^k$ 最多含可列个元素，$\boldsymbol{X} = (X_1, \cdots, X_k)'$ 是 $k$ 维 r.vec.，满足 $P(\boldsymbol{X} \in S_X) = 1$，则称 $\boldsymbol{X}$ 为离散型随机向量。称

$$p(x_1, \cdots, x_k) \triangleq P(X_1 = x_1, \cdots, X_k = x_k),\ (x_1, \cdots, x_k)' \in S_X$$

为 $(X_1, \cdots, X_k)'$ 的联合分布列。

**注：**

✧ 离散型随机向量的分布列与 j.d.f.一一对应，其概率分布也完全由其分布列决定。

✧ 联合分布列的基本性质：

a) 非负性：$p(x_1, \cdots, x_k) \geq 0,\ \forall (x_1, \cdots x_k)' \in S_X$；

b) 规范性：$\sum\limits_{(x_1, \cdots, x_k)' \in S_X} p(x_1, \cdots, x_k) = 1$。

✧ 联合分布列也常用表格形式或者联合概率质量函数(j.p.m.f.)表示：

$$p(x_1,\cdots,x_k)=\begin{cases}P(X_1=x_1,\cdots,X_k=x_k), & \text{if } (x_1,\cdots x_k)'\in S_X,\\ 0, & \text{else.}\end{cases}$$

✧ 对于 $\mathbb{R}^k$ 中的任意一个区域 $A$，

$$P((X_1,\cdots,X_k)'\in A)=\sum_{(x_1,\cdots,x_k)'\in A\cap S_X}p(x_1,\cdots,x_k).$$

$(X_1,\cdots,X_k)'$ 的 j.d.f.为

$$F(x_1,\cdots,x_k)=\sum_{(t_1,\cdots,t_k)'\in A\cap S_X}p(t_1,\cdots,t_k),\ \text{其中}\ A=\mathop{\times}_{j=1}^{k}(-\infty,x_j],(x_1,\cdots,x_k)\in\mathbb{R}^k.$$

**例 3.1.3** 从 1、2、3、4 中随机取一个数记为 $X$，再从 1~$X$ 中随机取一个数记为 $Y$。求：

(1) $(X,Y)$ 的联合分布列；(2) $P(X=Y)$。

**解：**

$(X, Y)$ 的可能取值范围为 $S_X=\{(i,j):\ j=1,\cdots,i,\ i=1,\cdots,4\}$。$\forall(i,j)\in S_X$，

$$P(X=i,Y=j)=P(Y=j\mid X=i)P(X=i)=\frac{1}{i}\cdot\frac{1}{4}。$$

联合分布列可用表格形式表示为：

| $x, y$ | $P(X=x,Y=y)$ |
|---|---|
| 1, 1 | 1/4 |
| 2, 1 | 1/8 |
| 2, 2 | 1/8 |
| 3, 1 | 1/12 |
| 3, 2 | 1/12 |
| 3, 3 | 1/12 |
| 4, 1 | 1/16 |
| 4, 2 | 1/16 |
| 4, 3 | 1/16 |
| 4, 4 | 1/16 |

| $X$ \ $Y$ | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| 1 | 1/4 | 0 | 0 | 0 |
| 2 | 1/8 | 1/8 | 0 | 0 |
| 3 | 1/12 | 1/12 | 1/12 | 0 |
| 4 | 1/16 | 1/16 | 1/16 | 1/16 |

$$P(X=Y)=P\left(\sum_{i=1}^{4}\{X=i,Y=i\}\right)=\frac{1}{4}+\frac{1}{8}+\frac{1}{12}+\frac{1}{16}=\frac{25}{48}=0.5208。$$

$(X,Y)$ 的联合分布函数为

$$F(x,y)=\begin{cases}0, & y<1 \ \ or \ \ x<1,\\ 1/4, & 1\le y,\ 1\le x<2,\\ 1/4+1/8, & 1\le y<2,\ 2\le x<3,\\ 1/4+2/8, & 2\le y,\ 2\le x<3,\\ 1/4+1/8+1/12, & 1\le y<2,\ 3\le x<4,\\ 1/4+2/8+2/12, & 2\le y<3,\ 3\le x<4,\\ 1/4+2/8+3/12, & 3\le y,\ 3\le x<4,\\ 1/4+1/8+1/12+1/16, & 1\le y<2,\ 4\le x,\\ 1/4+2/8+2/12+2/16, & 2\le y<3,\ 4\le x,\\ 1/4+2/8+3/12+3/16, & 3\le y<4,\ 4\le x,\\ 1, & 4\le y,\ 4\le x,\end{cases}$$

**例 3.1.4 多项分布**(Multinomial Distribution) 一次试验的结果可分为 $r$ 个互斥的类 $A_1,\cdots,A_r$，$P(A_j)=p_j>0,\ j=1,\cdots,r$，且 $p_1+\cdots+p_r=1$。独立地重复 $n$ 次试验，记 $A_j$ 出现的次数为 $X_j,\ j=1,\cdots,r$。则称随机向量 $(X_1,\cdots,X_r)'\sim MN(n;p_1,p_2,\cdots,p_r)$，其联合分布列为

$$P(X_1=x_1,\cdots,X_r=x_r)=\binom{n}{x_1}\binom{n-x_1}{x_2}\cdots\binom{n-x_1-\cdots-x_{r-1}}{x_r}p_1^{x_1}\cdots p_r^{x_r}=\frac{n!}{x_1!\cdots x_r!}p_1^{x_1}\cdots p_r^{x_r},$$

其中 $x_j\in\{0,1,\cdots,n\}$，$j=1,\cdots,r$，且 $n=\sum_{j=1}^{r}x_j$。

$(X_1,X_2,X_3)'\sim MN(3;0.2,0.3,0.5)$，其中 $(X_1,X_2)'$ 的概率分布图

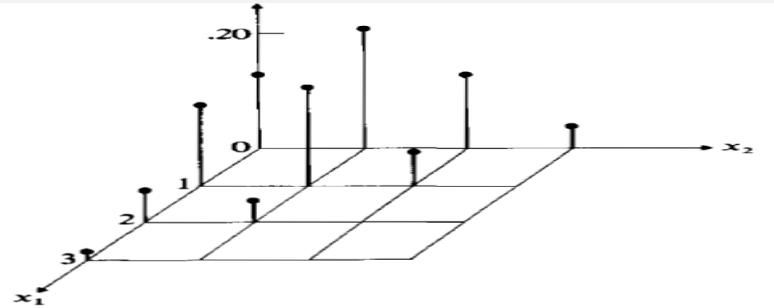


**注：**

✧ 多项分布是二项分布的推广。$r$ 项分布联合分布列中的每一个概率，都是多项式 $(p_1+\cdots+p_r)^n$ 展开式中的一项。

✧ $r$ 项分布的取值落在 $r$ 维空间的一个平面上，本质上是 $r-1$ 维的，其联合分布列由其任意一个 $r-1$ 维子向量的联合分布列决定。因此，$X \sim B(n,p)$ 等价于 $(X, n-X)' \sim MN(n; p, 1-p)$ 或者 $(n-X, X)' \sim MN(n; 1-p, p)$。

**例 3.1.5 多维超几何分布** 设一袋子中共有 $N$ 球，其中编号 $j$ 的球有 $N_j > 0$ 个，$j = 1, \cdots, r$。从中**不放回地**任取 $n(\le N)$ 个球，记抽中的 $j$ 号球数为 $X_j$。称 $(X_1, \cdots, X_r)'$ 服从 $r$ 维超几何分布，其联合分布列为

$$P(X_1 = x_1, \cdots, X_r = x_r) = \binom{N_1}{x_1} \cdots \binom{N_r}{x_r} \binom{N}{n}^{-1},$$

其中 $x_j \in \{0, \cdots, \min(n, N_j)\}$，$j = 1, \cdots, r$，且满足 $x_1 + \cdots + x_r = n$。

## 三、连续型随机向量

**定义 3.1.5** 若存在非负可测实函数 $p(x_1,\cdots,x_k)$ 使得随机向量 $\boldsymbol{X}=(X_1,\cdots,X_k)'$ 的 j.d.f.

$$F(x_1,\cdots,x_k)=\int_{-\infty}^{x_1}\cdots\int_{-\infty}^{x_k}p(t_1,\cdots,t_k)dt_1\cdots dt_k,\quad \forall(x_1,\cdots,x_k)'\in\mathbb{R}^k,$$

则称 $\boldsymbol{X}$ 为 $k$ 维连续型随机向量，称其概率分布是 $k$ 维连续型分布，称 $p(x_1,\cdots,x_k)$ 为 $\boldsymbol{X}$ 或其概率分布的联合密度函数 (j.p.d.f.)。

**注：**

✧ $k$ 维连续型 r.vec.的概率分布 $P_X$，是关于 $k$ 维 Lebesgue 测度 $\lambda$ 绝对连续的概率测度，即 $\forall A\in\mathcal{B}_{\mathbb{R}^k}$，若 $\lambda(A)=0$ 则必 $P_X(A)=0$。由 Radon-Nikodym 定理知，这与定义 3.1.5 等价。

✧ 定义中用的是 Lebesgue 积分，暂时可理解为 Riemann 重积分、按 Riemann 积分计算。

✧ 与连续型 p.d.f.类似，j.p.d.f.也不唯一。若非负可测实函数 $\tilde{p}(x_1,\cdots,x_k)=p(x_1,\cdots,x_k)\ a.e.\ \lambda$，则它们描述的 $k$ 维连续型分布相同。可测函数是指 $(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})\to(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 的可测映照。

**联合密度函数的基本性质：**

(1) 非负性：$p(x_1,\cdots,x_k)\ge 0,\quad \forall (x_1,\cdots x_k)'\in\mathbb{R}^k$；

(2) 规范性：$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}p(x_1,\cdots,x_k)dx_1\cdots dx_k=1$。

**其他性质：**

✧ 连续型随机向量的 jdf 取决于其 jpdf，因此其统计性质也完全由其 jpdf 决定。

✧ 连续型 r.vec.所表示事件的概率可由 jpdf 的重积分计算，即

$$P(\boldsymbol{X}\in C)=\int_C\cdots\int p(t_1,\cdots,t_k)dt_1\cdots dt_k$$

其中 $C\in\mathcal{B}_{\mathbb{R}^k}$。若 $C$ 体积(Lebesgue 测度)为 0，则 $P(\boldsymbol{X}\in C)=0$。

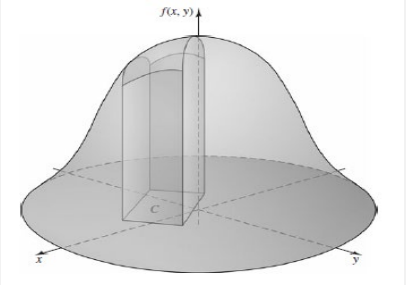


✧ 若 $p(x_1,\cdots,x_k)$ 在 $(x_1,\cdots x_k)'$ 处**连续**，记 $\delta(x_1,\cdots,x_k)$ 为 $(x_1,\cdots x_k)'$ 的邻域，则

(1) $\lim\limits_{\|\delta(x_1,\cdots,x_k)\|\to 0}\dfrac{P(X\in\delta(x_1,\cdots,x_k))}{\|\delta(x_1,\cdots,x_k)\|}=p(x_1,\cdots,x_k)$，其中$\|\cdot\|$ 表示邻域的“体积”；

(2) $\dfrac{\partial^k F(x_1,\cdots,x_k)}{\partial x_1\cdots\partial x_k}=p(x_1,\cdots,x_k)$；(对 j.d.f.可 k 阶偏导，可得到 j.p.d.f.)

(3) 当邻域足够小时，$P(\boldsymbol{X}\in\delta(x_1,\cdots,x_k))\approx p(x_1,\cdots,x_k)\cdot\|\delta(x_1,\cdots,x_k)\|$；

(4) 写成微分形式 $P(x_1<X_1\le x_1+dx_1,\cdots,x_k<X_k\le x_k+dx_k)\approx p(x_1,\cdots,x_k)\cdot dx_1\cdots dx_k$。

直观而言，$p(x_1,\cdots,x_k)$ 表示 r.vec. 密集在点$(x_1,\cdots,x_k)'$周围的可能性程度。$p(x_1,\cdots,x_k)$越大，说明 r.vec.落在 $(x_1,\cdots,x_k)'$ 附近的概率越大。

**例 3.1.6** 设 $(X,Y)'$ 的 j.p.d.f. 为

$$p(x,y)=\begin{cases}ce^{-2x-y}, & x>0,y>0,\\ 0, & \text{otherwise.}\end{cases}$$

求：(1) 参数 $c$；　(2) $(X, Y)'$ 的 j.d.f.；　(3) $P(X<1, Y>1)$；　(4) $P(X>Y)$。

**解：**

(1) $c$ 应使联合密度函数满足非负性、规范性，故 $c \geq 0$ 且

$$1=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}p(x,y)dxdy=\int_{0}^{\infty}\int_{0}^{\infty}ce^{-2x-y}dxdy=c\cdot\left[-\frac{1}{2}e^{-2x}\Big|_{0}^{\infty}\right]\left[-e^{-y}\Big|_{0}^{\infty}\right]=\frac{1}{2}c,$$

因此， $c=2$ 。

(2) $\forall (x,y)'\in\mathbb{R}^2$,

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}p(u,v)dvdu=\begin{cases}0, & x\leq 0 \text{ or } y\leq 0,\\ 2\int_{0}^{x}e^{-2u}du\cdot\int_{0}^{y}e^{-v}dv, & x>0 \text{ and } y>0.\end{cases}$$

$$=\begin{cases}0, & x\leq 0 \text{ or } y\leq 0,\\ \left(1-e^{-2x}\right)\left(1-e^{-y}\right), & x>0 \text{ and } y>0.\end{cases}$$

(3)

$$P(X<1,Y>1)=\iint\limits_{\{(x,y):x<1,y>1\}}p(x,y)dxdy$$

$$=\int_{0}^{1}\int_{1}^{\infty}2e^{-2x-y}dxdy=(1-e^{-2})e^{-1}.$$

(4)

$$P(X>Y)=\iint\limits_{\{(x,y):x>y\}} p(x,y)dxdy=\int_0^{\infty}\left(\int_0^{x}2e^{-2x-y}dy\right)dx$$

$$=\int_0^{\infty}2e^{-2x}(1-e^{-x})dx=1-\frac{2}{3}=\frac{1}{3}.$$

**常用连续型多元分布**

(1) **均匀分布**。设 $D\in\mathcal{B}_{\mathbb{R}^k}$，其“体积” $\|D\|=\int\cdots\int_D dx_1\cdots dx_k\in(0,\infty)$。若 r. vec. $\boldsymbol{X}=(X_1,\cdots,X_k)'$

具有 jpdf

$$p(x_1,\cdots,x_k)=\frac{1}{\|D\|}I_D(x_1,\cdots,x_k),$$

则称 $\boldsymbol{X}\sim \mathrm{U}(D)$。

均匀分布是一维均匀分布的推广，描述的是几何概率。

**例 3.1.7** 设 $D$ 是平面上以原点为圆心、以 $r$ 为半径的圆内区域。$(X,Y)' \sim \mathrm{U}(D)$。求：

1) $(X,Y)'$ 的联合密度函数；

2) $P(|X| \le r/2)$。

(2) **多元正态分布**。设 $\boldsymbol{\mu} = (\mu_1, \cdots, \mu_k)'$ 是 $k$ 维实向量，$\Sigma$ 是 $k$ 阶正定矩阵。称具有 jpdf

$$p(\boldsymbol{x}) = (2\pi)^{-k/2} |\Sigma|^{-1/2} \exp\left[-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})'\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right], \quad \boldsymbol{x} \in \mathbb{R}^k$$

的 r. vec. $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \Sigma)$。

注：

- 这是一个 j.p.d.f.。密度等高线是同心($x = \boldsymbol{\mu}$ 处)、同轴(取决于 $\Sigma$ 的特征向量)的椭球。j.p.d.f.在 $\boldsymbol{\mu}$ 处最大，如倒扣之草帽形。
- $k=1$ 时，即一元正态分布。

➢ $k=2$时，若记 $\Sigma=\begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2\\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}$，其中 $\sigma_1>0,\ \sigma_2>0,\ |\rho|<1$，则二元正态分布也常记为 $N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$。其 jpdf 可写成

$$p(x_1,x_2)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2-\frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}+\left(\frac{x_2-\mu_2}{\sigma_2}\right)^2\right]\right\}$$

$$=\frac{1}{\sqrt{2\pi}\sigma_1}e^{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}}\cdot\frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{\left[x_2-\left(\mu_2+\rho\frac{\sigma_2}{\sigma_1}(x_1-\mu_1)\right)\right]^2}{2\sigma_2^2(1-\rho^2)}\right\}$$

$$=\frac{1}{\sqrt{2\pi}\sigma_2}e^{-\frac{(x_2-\mu_2)^2}{2\sigma_2^2}}\cdot\frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}}\exp\left\{-\frac{\left[x_1-\left(\mu_1+\rho\frac{\sigma_1}{\sigma_2}(x_2-\mu_2)\right)\right]^2}{2\sigma_1^2(1-\rho^2)}\right\}$$

( jpdf 图形可参见 http://personal.kenyon.edu/hartlaub/MellonProject/Bivariate2.html )

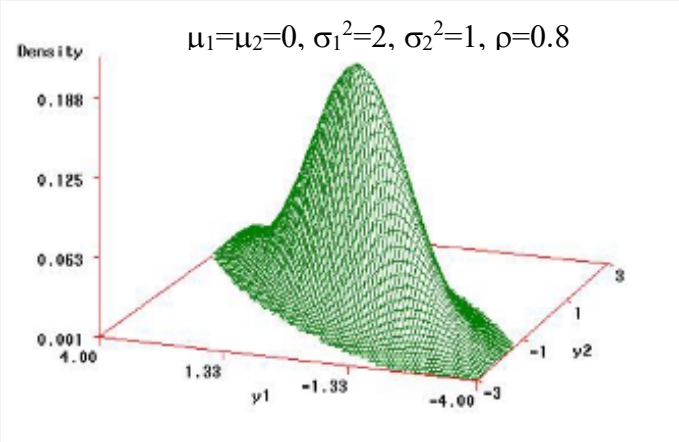
$\mu_1=\mu_2=0,\ \sigma_1^2=2,\ \sigma_2^2=1,\ \rho=0.8$
Density
0.188
0.125
0.063
0.001
4.00
1.33
y1
-1.33
-4.00
-3
-1
1
3
y2

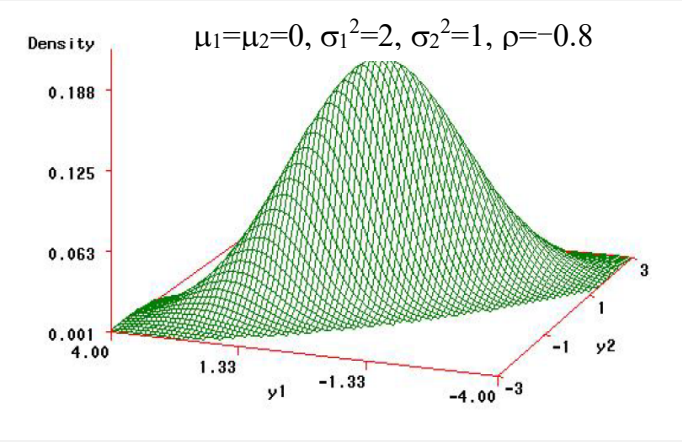
$\mu_1=\mu_2=0,\ \sigma_1^2=2,\ \sigma_2^2=1,\ \rho=-0.8$
Density
0.188
0.125
0.063
0.001
4.00
1.33
y1
-1.33
-4.00
-3
-1
1
3
y2

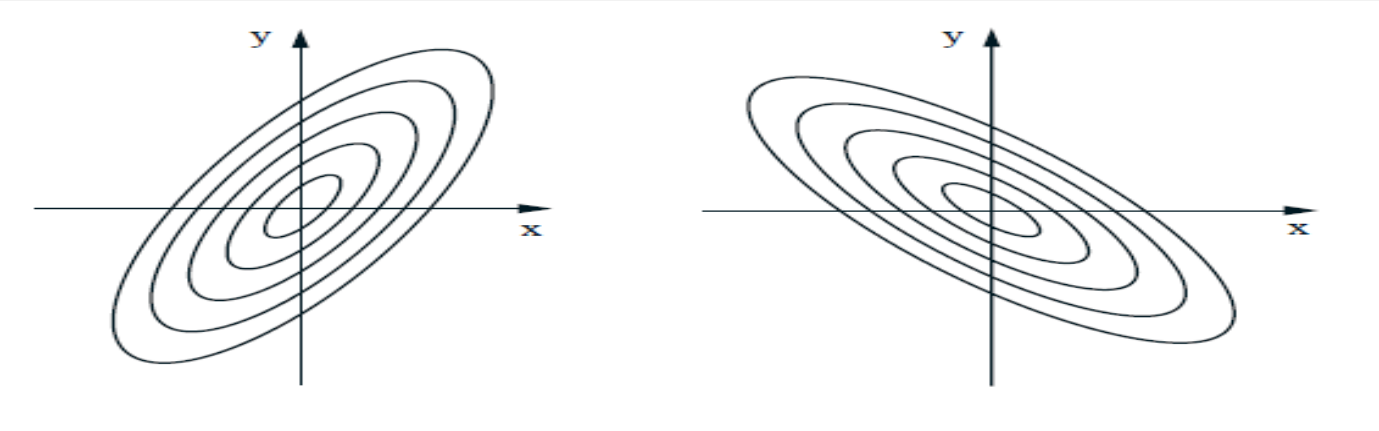
y
x
y
x

$\mu_1=\mu_2=0,\ \sigma_1^2=\sigma_2^2=1,\ \rho=0$

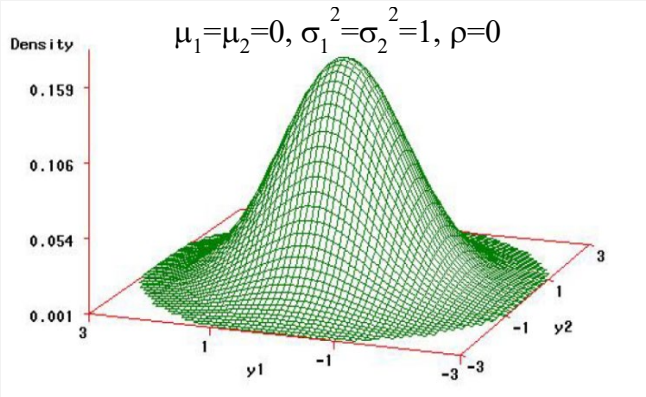


$\mu_1=\mu_2=0,\ \sigma_1^2=\sigma_2^2=4,\ \rho=0.5$

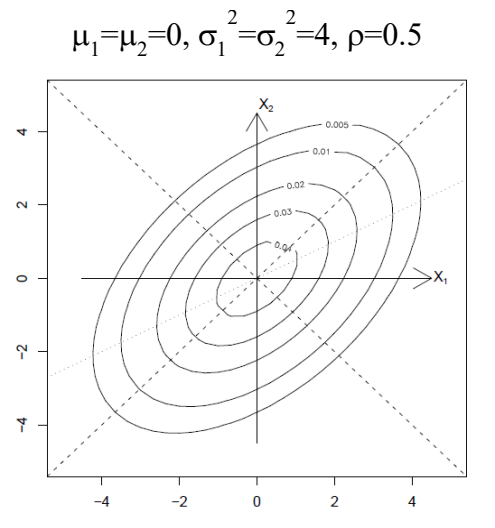

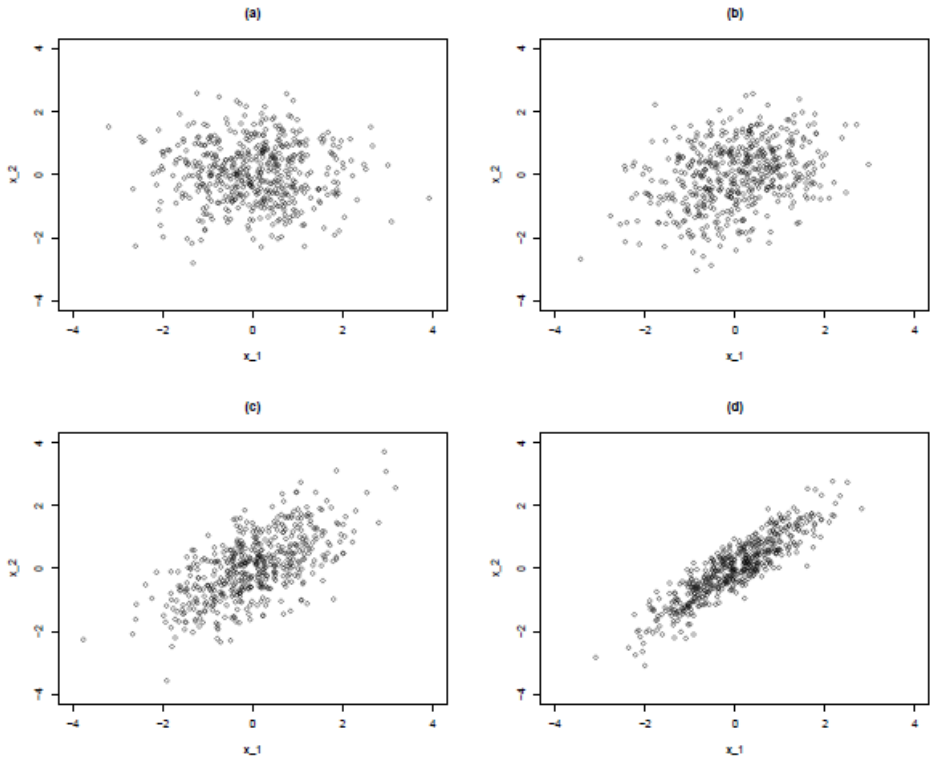


Figure 2: Simulation from standard bivariate normal distribution, $n = 500$: (a) $\rho = 0$, (b) $\rho = 0.3$, (c) $\rho = 0.6$ and (d) $\rho = 0.9$.

**(3) Dirichlet 分布**。若 r.vec. $(X_1,\cdots,X_k)'$ 满足 $\sum_{j=1}^{k} X_j = 1$，且其任意 $k-1$ 维子向量（比如 $(X_1,\cdots,X_{k-1})'$）的 j.p.d.f.为

$$p(x_1,\cdots,x_k) = \frac{\Gamma(\alpha_1+\cdots+\alpha_k)}{\prod_{j=1}^{k}\Gamma(\alpha_j)} \prod_{j=1}^{k} x_j^{\alpha_j-1} I_{S_{k-1}}((x_1,\cdots,x_k)),$$

其中 $\alpha_j > 0, j=1,\cdots,k$ 是参数，$S_{k-1} = \{(x_1,\cdots,x_k): \sum_{j=1}^{k} x_j = 1, \text{且 } x_j \ge 0, j=1,\cdots,k\}$ 是 $k-1$ 维标准单纯形 (standard simplex)，则称 $(X_1,\cdots,X_k)'$ 服从参数为 $(\alpha_1,\cdots,\alpha_k)$ 的 Dirichlet 分布，记为 $(X_1,\cdots,X_k)' \sim \mathrm{Dir}(\alpha_1,\cdots,\alpha_k)$。

注：

✧ Dirichlet 分布是 Beta 分布的多元推广，也称多元 Beta 分布。其 j.p.d.f.的正则化常数的倒数 $\mathrm{B}(\alpha_1,\cdots,\alpha_k) = \dfrac{\prod_{j=1}^{k}\Gamma(\alpha_j)}{\Gamma(\alpha_1+\cdots+\alpha_k)}$ 也称为多元 Beta 函数。

✧ $(X_1,\cdots,X_k)'$ 分布的支撑是嵌在$\mathbb{R}^k$中的$k-1$维标准单纯形$S_{k-1}$，关于 $k$ 维 Lebesgue 测度奇异的概率测度。它的任意$k-1$维子向量的分布，都是$k-1$维连续型分布，j.p.d.f.形式上是 $k$ 元的，实质上都是$k-1$的，比如$(X_1,\cdots,X_{k-1})'$的 j.p.d.f. 应将$x_k$替换为$1-\sum_{j=1}^{k-1}x_j$。

✧ Dirichlet 分布常用于对成分数据(compositional data)、混料比例建模，在贝叶斯分析中常用作多项分布参数$p_1,\cdots,p_k$的先验分布。

## 四、其他类型的随机向量

现实问题中，经常还需要研究各种非离散型、非连续型的随机向量，常见的有：

➢ 部分分量是连续型的、部分分量是离散型的。

例：描述超市一天营业状况的随机向量$(X,Y)'$，$X$ 表示顾客数，$Y$ 表示营业额；

描述一笔保单理赔状况的随机向量$(X,Y)'$，$X$ 为理赔次数，$Y$ 为理赔总额；等等。

➢ 高维随机向量的所有取值都落在一个低维空间上。

例：随机向量 $(X,Y)'$ 在半径为 1 的圆周上均匀分布。

- 更复杂的情况。

例：海关根据进口涤纶布报关单申报的数重比(长度与重量之比) $R_c$ 来决定是否抽验相应的货物。为制定抽验策略，需研究进口涤纶布的实际数重比 $R_t$ 与 $R_c$ 的联合分布。若诚实申报，则 $R_c = R_t$，否则 $R_c$ 在 $(0,R_t)$ 上分布。设诚实申报的概率为 $1-\pi$。因此，$(R_c,R_t)'$ 落在直线 $y=x$ 上的概率为 $1-\pi$，在此直线外连续型分布。

**如何描述这些随机向量的联合分布？**

- 联合分布函数依然是全面描述联合分布的理论工具。
- 实际中，常用边际分布、条件分布、数字特征等工具从不同侧面描述联合分布，这些特征往往比联合分布容易获得，也更容易理解、处理。

# § 3.2 边际分布与随机变量的独立性

与命题3.1.1同理可知，随机向量的每一个一维或多维分量还是随机变量或者随机向量，也各有概率分布。为强调随机向量分量的分布与其联合分布的关系，常称分量的分布为边际分布(*marginal distribution*)。设 $\boldsymbol{X}=(X_1,\cdots,X_k)'$ 是 $k$ 维 r. vec.，$\boldsymbol{Y}$ 是 $\boldsymbol{X}$ 的一个 $m$ 维子向量，$m=1,2,\cdots,$ 或 $k-1$，则称 $\boldsymbol{Y}$ 的分布是 $\boldsymbol{X}$ 的边际分布。

描述边际分布的工具：边际分布函数；边际分布列；边际密度函数；等。

联合分布能够决定所有边际分布，反之不然。

边际分布能够反映联合分布的部分信息，但不能决定联合分布。对于很多随机向量，容易描述其边际分布，但不易描述其联合分布。

## 一、边际分布函数 (m.d.f.)与 j.d.f.的关系

- $k$=2。设 $(X_1,X_2)'$的 j.d.f. 为 $F(x_1,x_2)$，则 $X_1$ 的 m.d.f. 为

$$F_1(x_1)=P(X_1\le x_1)=P(X_1\le x_1,X_2<\infty)=\lim_{x_2\to\infty}F(x_1,x_2)\hat{=}F(x_1,\infty),\ x_1\in\mathbb{R}.$$

  同理，$X_2$的 m.d.f. 为 $F_2(x_2)=F(\infty,x_2),\ x_2\in\mathbb{R}.$

- $k$=3。设 $(X_1,X_2,X_3)'$ 的 j.d.f. 为 $F(x_1,x_2,x_3)$，则

  $X_1$的 m.d.f.：$F_1(x)=F(x,\infty,\infty),\ x\in\mathbb{R}.$

  $X_2$的 m.d.f.：$F_2(x)=F(\infty,x,\infty),\ x\in\mathbb{R}.$

  $X_3$的 m.d.f.：$F_3(x)=F(\infty,\infty,x),\ x\in\mathbb{R}.$

  $(X_1,X_2)'$的 m.d.f.：$F_{12}(x_1,x_2)=F(x_1,x_2,\infty),\ \ (x_1,x_2)'\in\mathbb{R}^2.$

  $(X_1,X_3)'$的 m.d.f.：$F_{13}(x_1,x_3)=F(x_1,\infty,x_3),\ \ (x_1,x_3)'\in\mathbb{R}^2.$

  $(X_2,X_3)'$的 m.d.f.：$F_{23}(x_2,x_3)=F(\infty,x_2,x_3),\ \ (x_2,x_3)'\in\mathbb{R}^2.$

- $k$>3 的情况依此类推。

**例 3.2.1** 记 $F(x,y)=\begin{cases}1-e^{-x}-e^{-y}+e^{-x-y-\lambda xy}, & \text{if } x>0, y>0,\\ 0, & \text{else.}\end{cases}$ 其中参数 $\lambda\in[0,1]$。

(1) 可验证，当 $\lambda\in[0,1]$ 时 $F(x,y)$ 是一个二元 j.d.f.。称此 j.d.f.描述的分布为**二维指数分布**。

(2) 对 $F(x,y)$ 求二阶导，得

$$p(x,y)=\frac{\partial^2 F(x,y)}{\partial x\partial y}=\begin{cases}[(1+\lambda x)(1+\lambda y)-\lambda]e^{-x-y-\lambda xy}, & \text{if } x>0, y>0,\\ 0, & \text{else.}\end{cases}$$

可验证这是一个 j.p.d.f.。因此 $F(x,y)$ 是连续型的 j.d.f.， $p(x,y)$ 其 j.p.d.f.。

(3) 设 r.vec. $(X,Y)'\sim F(x,y)$，则 $X$、$Y$ 的边际分布函数分别为

$$F_X(x)=F(x,\infty)=(1-e^{-x})I_{(0,\infty)}(x),$$
$$F_Y(y)=F(\infty,y)=(1-e^{-y})I_{(0,\infty)}(y).$$

可见，这两个边际分布都与参数 $\lambda$ 无关，而联合分布随 $\lambda>0$ 不同而不同。这说明边际分布不能决定联合分布。

## 二、边际分布列

设离散型随机向量 $(X_1,\cdots,X_k)'$ 的联合分布列为

$$p(x_1,\cdots,x_k)\triangleq P(X_1=x_1,\cdots,X_k=x_k),\ (x_1,\cdots,x_k)'\in S_X,$$

则 $X_j$ 的边际分布列与联合分布列的关系为

$$p_j(x_j)=P(X_j=x_j)=\sum_{(t_1,\cdots,t_k)'\in S_X\text{ 且 }t_j=x_j}p(t_1,\cdots,t_k),$$

$(X_i,X_j)'$ 的边际分布列与联合分布列的关系为

$$p_{ij}(x_i,x_j)=P(X_i=x_i,X_j=x_j)=\sum_{(t_1,\cdots,t_k)'\in S_X\text{ 且 }t_i=x_i,\,t_j=x_j}p(t_1,\cdots,t_k)。$$

其他边际分布列与联合分布列的关系依此类推。

**例 3.2.2** 从一个装有 2 个白球、3 个黑球的袋中随机地取球两次，每次一个。记第 $i$ 次取得的白球数为 $X_i$，$i=1,2$。求 $(X_1,X_2)$ 的联合分布列及边际分布列。

(1) 有放回地取。

| $X_1$ \ $X_2$ | 0 | 1 | $X_1$ 的边际分布列 |
|---|---|---|---|
| 0 | $(3/5)^2$ | $(3/5)(2/5)$ | 3/5 |
| 1 | $(3/5)(2/5)$ | $(2/5)^2$ | 2/5 |
| $X_2$ 的边际分布列 | 3/5 | 2/5 | |

(2) 无放回地取。

| $X_1$ \ $X_2$ | 0 | 1 | $X_1$ 的边际分布列 |
|---|---|---|---|
| 0 | $(3/5)(2/4)$ | $(3/5)(2/4)$ | 3/5 |
| 1 | $(2/5)(3/4)$ | $(2/5)(1/4)$ | 2/5 |
| $X_2$ 的边际分布列 | 3/5 | 2/5 | |

**注：**这两种情况下，两个分量的边际分布相同，但联合分布不同！此例也说明，**边际分布不能决定联合分布。**

**例 3.2.3** $(X_1, X_2, \cdots, X_r)' \sim MN(n; p_1, p_2, \cdots, p_r)$。求其边际分布列。

## 三、边际密度函数

- $k$=2。设$(X_1,X_2)'$的 jdf 为 $F(x_1,x_2)$，j.p.d.f. 为 $p(x_1,x_2)$。则

  $X_1$的 m.d.f. 为

$$F_1(x)=P(X_1\le x,X_2<\infty)=\int_{-\infty}^{x}\left(\int_{-\infty}^{\infty}p(t_1,t_2)dt_2\right)dt_1,\ x\in\mathbb{R}.$$

  因此，

$$f_1(x)=\int_{-\infty}^{\infty}p(x,x_2)dx_2,\ x\in\mathbb{R}$$

  是 $X_1$ 的 m.p.d.f.。同理，

$$f_2(x)=\int_{-\infty}^{\infty}p(x_1,x)dx_1,\ x\in\mathbb{R}$$

  是 $X_2$ 的 m.p.d.f.。

- 一般情形。设$(X_1,\cdots,X_k)'$的 j.p.d.f.为 $p(x_1,\cdots,x_k)$。则

$X_j$的 m.p.d.f. 为

$$p_j(x_j)=\int_{\mathbb{R}^{k-1}} p(t_1,\cdots,x_j,\cdots,t_k)\prod_{l=1,l\neq j}^{k} dt_l,\ x_j\in\mathbb{R}.$$

对于$1\le i<j\le k$，$(X_i,X_j)'$ 的 m.p.d.f. 为

$$p_{ij}(x_i,x_j)=\int_{\mathbb{R}^{k-2}} p(t_1,\cdots x_i,\cdots x_j,\cdots,t_k)\prod_{l=1,l\notin\{i,j\}}^{k} dt_l,\ (x_i,x_j)\in\mathbb{R}^2.$$

其他边际密度与联合密度之间的关系依此类推。

**例 3.2.4** 设 $(X,Y)$’ 具有 j.p.d.f.

$$p(x,y)=\begin{cases}1, & 0<x<1,\ |y|<x,\\ 0, & \text{otherwise.}\end{cases}$$

求：(1) 边际密度函数; (2) $P(Y>1/2)$。

**例 3.2.5** 多元正态分布的边际分布。

(1) 设 $(X,Y)' \sim N_2(\boldsymbol{\mu},\Sigma)$，其中 $\boldsymbol{\mu}=\begin{pmatrix}\mu_1\\ \mu_2\end{pmatrix}, \Sigma=\begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2\\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}$，$\sigma_1>0,\ \sigma_2>0,\ |\rho|<1$。则：

边际分布为 $X \sim N(\mu_1,\sigma_1^2),\ Y \sim N(\mu_2,\sigma_2^2)$，与 $\rho$ 无关！这又说明**边际分布不能决定联合分布**。

(2) 设 $\boldsymbol{X} \sim N_k(\boldsymbol{\mu},\Sigma)$，$\boldsymbol{X}=\begin{pmatrix}\boldsymbol{X}_1\\ \boldsymbol{X}_2\end{pmatrix}$，$\boldsymbol{\mu}=\begin{pmatrix}\boldsymbol{\mu}_1\\ \boldsymbol{\mu}_2\end{pmatrix}$，$\Sigma=\begin{pmatrix}\Sigma_{11} & \Sigma_{12}\\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}$，其中 $\boldsymbol{X}_j,\boldsymbol{\mu}_j$ 都是 $k_j$ 维分量，$\Sigma_{jj}$ 是 $k_j\times k_j$ 阶方阵，$j=1,2$，$k_1+k_2=k$。则：$\boldsymbol{X}_j$ 的边际分布为 $N_{k_j}(\boldsymbol{\mu}_j,\Sigma_{jj}),\ j=1,2$。

这里用到对分块矩阵求逆、求行列式的技巧。

$$\begin{pmatrix}\Sigma_{11} & \Sigma_{12}\\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}^{-1}=\begin{pmatrix}\Sigma_{11}^{-1} & 0\\ 0 & 0\end{pmatrix}+\begin{pmatrix}-\Sigma_{11}^{-1}\Sigma_{12}\\ I_{k_2}\end{pmatrix}\Sigma_{22.1}^{-1}\left(-\Sigma_{21}\Sigma_{11}^{-1}\ I_{k_2}\right)=\begin{pmatrix}0 & 0\\ 0 & \Sigma_{22}^{-1}\end{pmatrix}+\begin{pmatrix}I_{k_1}\\ -\Sigma_{22}^{-1}\Sigma_{21}\end{pmatrix}\Sigma_{11.2}^{-1}\left(I_{k_1}-\Sigma_{21}\Sigma_{22}^{-1}\right),$$

其中 $\Sigma_{22.1}=\Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}$，$\Sigma_{11.2}=\Sigma_{11}-\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$，$|\Sigma|=|\Sigma_{11}|\cdot|\Sigma_{22.1}|=|\Sigma_{22}|\cdot|\Sigma_{11.2}|$。

## 四、随机变量/向量的独立性

**定义 3.2.1** 设 $\boldsymbol{X}_j$ 是概率空间 $(\Omega,\mathcal{F},P)$ 上的 $k_j$ 维 r.v./r.vec.， $j=1,\cdots,r$。若有

$$P\left(\bigcap_{j=1}^{r}\{\boldsymbol{X}_j\in A_j\}\right)=\prod_{j=1}^{r}P(\boldsymbol{X}_j\in A_j),\quad \forall A_j\in\mathcal{B}_{\mathbb{R}^{k_j}},\ j=1,\cdots,r,$$

则称 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立。

**注：**

- 按定义 1.5.4，r.v./r.vec. $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立等价于：$\mathcal{F}$ 中的事件类 $\sigma(\boldsymbol{X}_1),\cdots,\sigma(\boldsymbol{X}_r)$ 相互独立，其中 $\sigma(\boldsymbol{X}_j)=\boldsymbol{X}_j^{-1}(\mathcal{B}_{\mathbb{R}^{k_j}}),\ j=1,\cdots,r$，是事件类相互独立概念的推广。
- $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立，也等价于：$\boldsymbol{X}=(\boldsymbol{X}_1',\cdots,\boldsymbol{X}_r')'$ 在 $(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})$ 上导出的概率测度 $P_{\boldsymbol{X}}(\cdot)$ 是 $P_{\boldsymbol{X}_j}(\cdot),j=1,\cdots,r$ 的乘积测度，$P_{\boldsymbol{X}_j}(\cdot)$ 为 $\boldsymbol{X}_j$ 在 $(\mathbb{R}^{k_j},\mathcal{B}_{\mathbb{R}^{k_j}})$ 上导出的概率测度，$k=\sum_{j=1}^{r}k_j$。参见定义 1.5.5/注。

**定理 3.2.1** (随机变量/向量独立性的判断方法)

(1) 设 r.v./r.vec. $\boldsymbol{X}_j$ 的分布函数为 $F_j(\cdot)$， $j=1,\cdots,r$。则 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立等价于：$(\boldsymbol{X}_1',\cdots,\boldsymbol{X}_r')'$ 的 j.d.f.

$$F(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)=\prod_{j=1}^{r}F_j(\boldsymbol{x}_j),\ \forall(\boldsymbol{x}_1',\cdots,\boldsymbol{x}_r')'\in\mathbb{R}^k。$$

(2) 设离散型 r.v./r.vec. $\boldsymbol{X}_j$ 的分布列为 $p_j(\boldsymbol{x}_j),\boldsymbol{x}_j\in S_j$， $j=1,\cdots,r$。则 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立等价于：$(\boldsymbol{X}_1',\cdots,\boldsymbol{X}_r')'$ 的联合分布列

$$p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)=\prod_{j=1}^{r}p_j(\boldsymbol{x}_j),\ \forall\boldsymbol{x}_j\in S_j,j=1,\cdots,r。$$

(3) 设连续型 r.v./r.vec. $\boldsymbol{X}_j$ 的 p.d.f. 是 $p_j(\cdot)$， $j=1,\cdots,r$。则 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立等价于：

$$\prod_{j=1}^{r}p_j(\boldsymbol{x}_j),\ \forall(\boldsymbol{x}_1',\cdots,\boldsymbol{x}_r')'\in\mathbb{R}^k$$

是 $(\boldsymbol{X}_1',\cdots,\boldsymbol{X}_r')'$ 的 j.p.d.f.。

**证明：**

(1) 记 $\mathcal{D}_j=\{(-\infty,\boldsymbol{x}_j]:\boldsymbol{x}_j\in\mathbb{R}^{k_j}\},\ j=1,\cdots,r$。因 $\boldsymbol{X}_j^{-1}(\mathcal{D}_j)$ 是 $\pi$ 类、$\sigma(\boldsymbol{X}_j)=\sigma(\boldsymbol{X}_j^{-1}(\mathcal{D}_j))$，而 $F(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)=\prod_{j=1}^{r}F_j(\boldsymbol{x}_j),\ \forall(\boldsymbol{x}_1',\cdots,\boldsymbol{x}_r')'\in\mathbb{R}^k$ 等价于事件类 $\boldsymbol{X}_j^{-1}(\mathcal{D}_j),\ j=1,\cdots r$ 之间相互独立。由性质 1.5.3 知，这等价于事件类 $\sigma(\boldsymbol{X}_j^{-1}),\ j=1,\cdots r$ 之间相互独立，即 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立。

(2), (3) 均由 (1) 证明。

**注：**

✧ 因连续型分布的 j.p.d.f.不唯一，故若 $p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)$ 是 $(\boldsymbol{X}_1',\cdots,\boldsymbol{X}_r')'$ 的 j.p.d.f.，则 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立等价于 $p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)=\prod_{j=1}^{r}p_j(\boldsymbol{x}_j)\ a.e.\ \lambda_k$，而不是 $p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)=\prod_{j=1}^{r}p_j(\boldsymbol{x}_j)$，其中 $\lambda_k$ 是 $k$ 维 Lebesgue 测度，这等价于 $\int_{\mathbb{R}^n}\left|p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)-\prod_{j=1}^{r}p_j(\boldsymbol{x}_j)\right|d\boldsymbol{x}_1\cdots d\boldsymbol{x}_r=0$。

✧ 若 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立，则它们的联合分布由各边际分布确定。

✧ 判断 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 不相互独立的方法：

1) 找到一点 $(\boldsymbol{x}_1',\cdots,\boldsymbol{x}_r')'\in\mathbb{R}^k$，使得 $F(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)\neq\prod_{j=1}^{r}F_j(\boldsymbol{x}_j)$。

2) 对离散型 r.vec.，找一组 $\boldsymbol{x}_j\in S_j, j=1,\cdots,r$，使 $p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)\neq\prod_{j=1}^{r}p_j(\boldsymbol{x}_j)$。

3) 对连续型 r.vec.，或者证明 $D$ 的“体积”大于 0，或者找到 $A\in\mathcal{B}_{\mathbb{R}^k}$，使得

$$\int_A\cdots\int p(\boldsymbol{x}_1,\cdots,\boldsymbol{x}_r)d\boldsymbol{x}_1\cdots d\boldsymbol{x}_r\neq\int_A\cdots\int\prod_{j=1}^{r}p_j(\boldsymbol{x}_j)d\boldsymbol{x}_1\cdots d\boldsymbol{x}_r\text{。}$$

**定理 3.2.2** 设 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立。

(1) 设 $g_j(\boldsymbol{x}_j)$ 是 $(\mathbb{R}^{k_j},\mathcal{B}_{\mathbb{R}^{k_j}})$ 上的可测函数，$j=1,\cdots,r$，则 $Y_j=g_j(\boldsymbol{X}_j), j=1,\cdots,r$ 相互独立。

(2) 从 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 中任取 $2\le m<r$ 个 r.v./r.vec.也相互独立。

(3) 把 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 分割成 $m\ge 2$ 个组，把每组内的 r.v./r.vec.合成一个 r.vec.，这 $m$ 个合成的 r.vec. 也相互独立。

**例 3.2.6** (1) **续例 3.2.2** 有放回情形下 $X_1$, $X_2$ 相互独立，无放回情形下不独立。

由定理 3.2.1/(2)知，两个离散型随机变量相互独立等价于它们的联合分布列的各行成比例，或者各列成比例。

(2) 设 $(X_1,X_2)' \sim \mathrm{U}(D)$。当 $D$ 是 $\mathbb{R}^2$ 中的矩形时，$X_1, X_2$ 相互独立；反之，不独立。

**定理 3.2.3** (多元正态分量之间的独立性)

(1) 设 $(X,Y)' \sim N_2(\boldsymbol{\mu},\Sigma)$，其中 $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$。则 $X, Y$ 相互独立等价于 $\rho = 0$。

(2) 设 $\boldsymbol{X} \sim N_k(\boldsymbol{\mu},\Sigma)$，$\boldsymbol{X} = \begin{pmatrix} \boldsymbol{X}_1 \\ \boldsymbol{X}_2 \end{pmatrix}$, $\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}$, $\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$，则 $\boldsymbol{X}_1, \boldsymbol{X}_2$ 相互独立等价于 $\Sigma_{12} = 0$。

充分性易证。必要性到 §3.5 再证。

**例 3.2.7** 随机变量两两独立，是它们相互独立的必要条件，不是充分条件。反例：若 $(X_1, X_2, X_3)$ 具有如下分布列

| $X_1$ | $X_2$ | $X_3$ | $P$ |
|---|---|---|---|
| 1 | 1 | 1 | 1/4 |
| 1 | 2 | 2 | 1/4 |
| 2 | 1 | 2 | 1/4 |
| 2 | 2 | 1 | 1/4 |

则 $X_1, X_2, X_3$ 两两独立，但三者不相互独立。

**例 3.2.8** 设 $(X,Y)'$ 的 j.p.d.f.为

$$p(x,y)=\begin{cases}8xy, & \text{if } 0\le x\le y\le 1,\\ 0, & \text{else.}\end{cases}$$

判断随机变量 $X$ 与 $Y$ 是否独立。

**解：**

$X$ 与 $Y$ 的 m.p.d.f.分别为

$$p_X(x)=\int_{-\infty}^{\infty}p(x,y)dy=\begin{cases}\int_x^1 8xydy=4x(1-x^2), & \text{if } x\in[0,1],\\ 0, & \text{else.}\end{cases}$$

$$p_Y(x)=\int_{-\infty}^{\infty}p(x,y)dx=\begin{cases}\int_0^y 8xydx=4y^3, & \text{if } y\in[0,1],\\ 0, & \text{else.}\end{cases}$$

显然在 $D=\{(x,y):0<y<x<1\}$ 上，$0=p(x,y)\neq p_X(x)p_Y(y)>0$。由于 $\iint_D dxdy=\frac{1}{2}>0$，

或者 $0=\iint_D p(x,y)dxdy\neq\iint_D p_X(x)p_Y(y)dxdy>0$，故 $X$ 与 $Y$ 不独立。

# § 3.3 条件分布

条件分布(conditional distribution)是条件概率概念的推广，常用于描述随机向量的联合分布、描述随机向量各分量之间的关系，在贝叶斯统计、回归分析等领域有广泛应用。

设 $\boldsymbol{X}$ 是 $(\Omega,\mathcal{F},P)$ 上的 $m$ 维 r.vec.， $B\in\mathcal{F}$ 且 $P(B)>0$，则常称

$$P(\boldsymbol{X}\in A\,|\,B)=P(\boldsymbol{X}^{-1}(A)\,|\,B),\ \forall A\in\mathcal{B}_{\mathbb{R}^m}$$

为给定 $B$ 发生条件下 $\boldsymbol{X}$ 的条件概率分布，简称条件分布。显然，该条件分布就是 $(\Omega,\mathcal{F})$ 上的条件概率测度 $P(\cdot\,|\,B)$ 由 $\boldsymbol{X}$ 导出的概率分布。

设 $(\boldsymbol{X}',\boldsymbol{Y}')'$ 是 $k$ 维随机向量，为描述其联合分布，常需要考察：对 $\forall\boldsymbol{y}\in S_{\boldsymbol{Y}}$ ($\boldsymbol{Y}$ 分布的支撑)，在给定 $\boldsymbol{Y}=\boldsymbol{y}$ 条件下 $m$ 维子向量 $\boldsymbol{X}$ 的条件分布

$$P(\boldsymbol{X}\in A\,|\,\boldsymbol{Y}=\boldsymbol{y}),\ \forall A\in\mathcal{B}_{\mathbb{R}^m}\text{。}$$

若 $P(\boldsymbol{Y}=\boldsymbol{y})>0,\forall\boldsymbol{y}\in S_{\boldsymbol{Y}}$，如 $\boldsymbol{Y}$ 为离散型 r.vec.时，这一系列的条件分布由条件概率直接可得。但若 $\exists\boldsymbol{y}\in S_{\boldsymbol{Y}},\ni P(\boldsymbol{Y}=\boldsymbol{y})=0$，如 $\boldsymbol{Y}$ 为连续型 r.vec.，条件分布则无法直接由条件概率定义。

## 一、离散型分布的条件分布

***k*=2 的情形。**

**定义 3.3.1** 设离散型 r.vec. $(X,Y)'$ 的联合分布列为 $\{p(x,y):(x,y)'\in S\subset\mathbb{R}^2\}$，$X$、$Y$ 的边际分布列分别为 $\{p_X(x):x\in S_X\},\{p_Y(y):y\in S_Y\}$。称 $\{p_{Y|X}(y|x):y\in S_Y\}$ 为给定 $X=x$ 条件下 $Y$ 的条件分布列，其中

$$p_{Y|X}(y|x)\triangleq P(Y=y|X=x)=\frac{P(X=x,Y=y)}{P(X=x)}=\frac{p(x,y)}{p_X(x)}。$$

称 $\{p_{X|Y}(x|y):x\in S_X\}$ 为给定 $Y=y$ 条件下 $X$ 的条件分布列，其中

$$p_{X|Y}(x|y)\triangleq P(X=x|Y=y)=\frac{P(X=x,Y=y)}{P(Y=y)}=\frac{p(x,y)}{p_Y(x)}。$$

显然，联合分布列

$$p(x,y)=p_{Y|X}(y|x)p_X(x)=p_{X|Y}(x|y)p_Y(y),\ \forall(x,y)\in S_X\times S_Y, \tag{3.3.1}$$

其中若$(x,y)\in S_X\times S_Y-S$则$p_{X|Y}(x|y)=p_{Y|X}(y|x)=p(x,y)=0$。此式说明，若给定$X$的边际分布列及**所有**给定$X$时$Y$的条件分布列，或者给定$Y$的边际分布列及**所有**给定$Y$时$X$的条件分布列，也就确定了$(X,Y)$的联合分布列。

由定理 3.2.1 及条件分布列的定义易知，下列三个命题等价：

(1) $X$，$Y$相互独立；

(2) 条件分布列 $\{p_{Y|X}(y|x):y\in S_Y\}=\{p_Y(y):y\in S_Y\}$， $\forall x\in S_X$；

(3) 条件分布列 $\{p_{X|Y}(x|y):x\in S_X\}=\{p_X(x):x\in S_X\}$， $\forall y\in S_Y$。

由(3.3.1)式易得下列两式，它们实际上就是性质 1.4.3 中的全概率公式：

$$p_Y(y)=\sum_{x\in S_X}p(x,y)=\sum_{x\in S_X}p_{Y|X}(y|x)p_X(x),\ \forall y\in S_Y,$$

$$p_X(x)=\sum_{y\in S_Y}p(x,y)=\sum_{y\in S_Y}p_{X|Y}(x|y)p_Y(y),\ \forall x\in S_X。$$

统计分析通常根据随机变量 $Y$ 的观测数据去推断研究或决策所需的不可直接观测的量 $X$。有关 $X$ 的信息常包括两部分：一、来自历史资料、背景知识、主观判断等方面的带有不确定性的先验信息(prior)；二、蕴藏于随机变量 $Y$ 的观测数据中的信息。

在贝叶斯统计中，视 $X$ 为 r.v.，取一个概率分布概括其先验信息，称为先验分布；用给定 $X$ 条件下 $Y$ 的条件分布刻画 $Y$ 与 $X$ 之间的联系。**这实质上就是用边际分布加条件分布对 $(X,Y)$ 的联合分布建模**。将 $Y$ 的观测数据 $y$ 代入条件分布形成似然(likelihood)——即不同的 $x$ 产生相同 $y$ 的可能性；再用 Bayes 公式计算 $X$ 的后验分布(posterior)，将有关 $X$ 的两部分信息综合起来用于推断、决策。

由(3.3.1)得如下 Bayes 公式，即在 $Y=y\in S_Y$ 条件下，$X$ 的后验分布列为

$$p_{X|Y}(x\,|\,y)=\frac{p_{Y|X}(y\,|\,x)p_X(x)}{\sum_{\tilde{x}\in S_X}p_{Y|X}(y\,|\,\tilde{x})p_X(\tilde{x})},\quad \forall x\in S_X。\tag{3.3.2}$$

**这是 $(X,Y)$ 的另一组条件分布之一**，反映观测到 $Y=y$ 之后对 $X$ 取各值可能性大小的新认识。

**多维情形。**设 $\boldsymbol{X},\boldsymbol{Y}$ 分别是 $k_1,k_2$ 维的离散型r.vec.，其联合分布列为 $\{p(\boldsymbol{x},\boldsymbol{y}):(\boldsymbol{x}',\boldsymbol{y}')'\in S\}$。那么，下述概念与结论：

给定 $\boldsymbol{X}=\boldsymbol{x}$ 时 $\boldsymbol{Y}$ 的条件分布、给定 $\boldsymbol{Y}=\boldsymbol{y}$ 条件下 $\boldsymbol{X}$ 的条件分布；

联合分布与条件分布、边际分布的关系；

独立性与条件分布的关系；

全概率公式、Bayes 公式

都可以从 $k$=2 的情形推广得到，而且形式上与 $k$=2 的情形一致。

**例 3.3.1** (续例 3.2.2)

(1) 有放回情形。由例 3.2.2 中的联合分布列知，给定 $X_2$ 时 $X_1$ 的条件分布列为

$$p_{X_1|X_2}(i\,|\,0)=\frac{p(i,0)}{p_{X_2}(0)}=\begin{cases}3/5, & i=0,\\ 2/5, & i=1.\end{cases}\qquad p_{X_1|X_2}(i\,|\,1)=\frac{p(i,1)}{p_{X_2}(1)}=\begin{cases}3/5, & i=0,\\ 2/5, & i=1.\end{cases}$$

可见，已知 $X_2$ 取值的情况下，不论 $X_2=0$ 还是 1，$X_1$ 的条件分布都相同，且都与其边际分布相同。这说明 $X_1$ 与 $X_2$ 之间没有关系。

(2) 无放回情形。

| $X_1$ \ $X_2$ | 0 | | 1 | $X_1$ 的边际分布列 | $X_2$=0 时 $X_1$ 的条件分布 | $X_2$=1 时 $X_1$ 的条件分布 |
|---|---|---|---|---|---|---|
| 0 | (3/5)(2/4) | | (3/5)(2/4) | 3/5 | 1/2 | 3/4 |
| 1 | (2/5)(3/4) | | (2/5)(1/4) | 2/5 | 1/2 | 1/4 |
| $X_2$ 的边际分布列 | 3/5 | | 2/5 | | | |

可见，已知 $X_1$ 的条件分布随 $X_2$ 取值不同而不同。这说明两者之间有关系。

**例 3.3.2** 已知某动物产卵数 $X \sim \mathrm{Poi}(\lambda)$，每个卵的存活率为 $p$，因而在产卵数 $X=x$ 条件下，存活卵数 $Y \mid X=x \sim B(x,p)$。求：(1) $(X,Y)$ 的联合分布；(2) $Y$ 的边际分布；(3)观测到存活卵数 $Y=y$ 情况下，$X$ 的后验分布。

## 二、一般情况下的条件分布

若 r.vec. $(\boldsymbol{X}',\boldsymbol{Y}')'$ 的分量 $\boldsymbol{Y}$ 非离散型的，因 $\exists \boldsymbol{y}\in S_Y, \ni P(\boldsymbol{Y}=\boldsymbol{y})=0$ 而无法直接由条件概率定义：给定 $\boldsymbol{Y}=\boldsymbol{y}$ 条件下 $\boldsymbol{X}$ 的条件分布 $P(\boldsymbol{X}\in A\,|\,\boldsymbol{Y}=\boldsymbol{y}),\ \forall A\in\mathcal{B}_{\mathbb{R}^m}$。此时可以借助极限的概念来处理。更严格地，可用测度论中的 Radon-Nikodym 导数处理。

**$k$=2 的情形。**设 $(X,Y)$ 是二维 r.vec.。将事件 $\{Y=y\}$ 理解为某个极小的 $\varepsilon>0$ 对应的事件 $\{Y\in(y-\varepsilon,y+\varepsilon)\}$ 合乎情理。对于 $y\in S_Y$， $P(Y\in(y-\varepsilon,y+\varepsilon))>0,\forall\varepsilon>0$，且

$$P(X\le x,Y\in(y-\varepsilon,y+\varepsilon))\le P(Y\in(y-\varepsilon,y+\varepsilon)),\ \forall x\in\mathbb{R}\text{。}$$

因此下列条件概率是 0/0 型的且有界，极限往往存在：

$$\lim_{\varepsilon\to0+}P(X\le x\,|\,Y\in(y-\varepsilon,y+\varepsilon))=\lim_{\varepsilon\to0+}\frac{P(X\le x,Y\in(y-\varepsilon,y+\varepsilon))}{P(Y\in(y-\varepsilon,y+\varepsilon))}\text{。}\tag{3.3.3}$$

直观上可以此极限形成的 $x$ 的函数为**给定 $Y=y$ 条件下 $X$ 的条件分布函数**，记为 $F_{X|Y}(x\,|\,y)$。

**定义 3.3.2** 设 $Y$ 的边际分布函数为 $F_Y(y)$，$(X,Y)$的 j.d.f.为 $F(x,y)$。若存在 $(\mathbb{R}^2,\mathcal{B}_{\mathbb{R}^2})$ 上的可测函数 $F_{X|Y}(x\,|\,y)$，同时满足：

1) 对于每一个 $x\in\mathbb{R}$，

$$F(x,y)=\int_{-\infty}^{y}F_{X|Y}(x\,|\,v)dF_Y(v),\ \forall y\in\mathbb{R}\,; \tag{3.3.4}$$

2) 对于每一个给定的 $y\in S_Y$，若视 $F_{X|Y}(x\,|\,y)$ 为 $x$ 的函数，它必是 d.f.。

则称此 $F_{X|Y}(x\,|\,y)$ 为给定 $Y$ 条件下 $X$ 的条件分布函数。

根据测度论中 Radon-Nikodym 定理，对于每一个 $x\in\mathbb{R}$，满足(3.3.4)的 $F_{X|Y}(x\,|\,y)$ 存在且 a.s.$P$ 确定。而且，其中必有同时满足 2)的 $F_{X|Y}(x\,|\,y)$。这样的 $F_{X|Y}(x\,|\,y)$ 往往可由(3.3.3)给出。因此，定义 3.3.2 是合理的，且说明：**$(X,Y)$的联合分布可以由 $Y$ 的边际分布 $F_Y(y)$ 及所有给定 $Y$ 条件下 $X$ 的条件分布 $\{F_{X|Y}(x\,|\,y):y\in S_Y\}$ 确定，无论联合分布是哪一种类型。**对于给定的 $x\in\mathbb{R}$，

$$F(x,\infty)=\int_{-\infty}^{\infty}F_{X|Y}(x\,|\,y)dF_Y(y)$$

是全概率公式的推广。

对于离散型的联合分布，根据分布列与分布函数、条件分布列与条件分布函数之间的关系可证，上一小节中的概念、结论与这里一致，没有冲突。

对于条件分布函数 $F_{X|Y}(x\,|\,y)$，对于 $Y=y$ 若存在非负函数 $p_{X|Y}(x\,|\,y)$，使得

$$F_{X|Y}(x\,|\,y)=\int_{-\infty}^{x}p_{X|Y}(u\,|\,y)du,\ \forall x\in\mathbb{R},$$

这说明给定 $Y=y$ 时 $X$ 的条件分布是连续型的，称 $p_{X|Y}(x\,|\,y)$ 为**给定 $Y=y$ 条件下 $X$ 的条件密度函数**。

上述概念、结论可以推广到多维 r.vec. $(\boldsymbol{X}',\boldsymbol{Y}')'$ 的情形。

## 1. 连续型随机向量的条件分布

**定理 3.3.1** 设$(\boldsymbol{X}',\boldsymbol{Y}')'$是 j.p.d.f.为$p(\boldsymbol{x},\boldsymbol{y})$的$k$维连续型 r.vec.。$\boldsymbol{X},\boldsymbol{Y}$分别是$m,k-m$维子向量，m.p.d.f.分别为$p_X(\boldsymbol{x}), p_Y(\boldsymbol{y})$。则：给定$\boldsymbol{Y}=\boldsymbol{y}$条件下$\boldsymbol{X}$的条件密度函数为

$$p_{X|Y}(\boldsymbol{x}\,|\,\boldsymbol{y})=\frac{p(\boldsymbol{x},\boldsymbol{y})}{p_Y(\boldsymbol{y})}I(p_Y(\boldsymbol{y})>0),\ \ \boldsymbol{x}\in\mathbb{R}^m;$$

给定$\boldsymbol{X}=\boldsymbol{x}$条件下$\boldsymbol{Y}$的条件密度函数为

$$p_{Y|X}(\boldsymbol{y}\,|\,\boldsymbol{x})=\frac{p(\boldsymbol{x},\boldsymbol{y})}{p_X(\boldsymbol{x})}I(p_X(\boldsymbol{x})>0),\ \ \boldsymbol{y}\in\mathbb{R}^{k-m}。$$

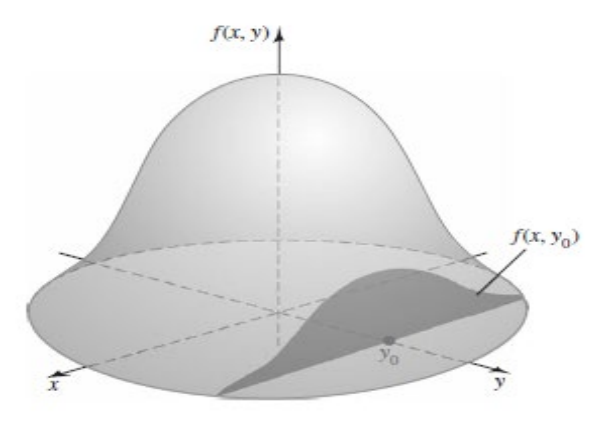


**注：**

✧ 定理 3.3.1 说明连续型 r.vec.的条件分布都是连续型的。与(3.3.1)式类似，j.p.d.f.

$$p(\boldsymbol{x},\boldsymbol{y}) = p_{\boldsymbol{X}}(\boldsymbol{x})p_{\boldsymbol{Y}|\boldsymbol{X}}(\boldsymbol{y}\,|\,\boldsymbol{x}) = p_{\boldsymbol{Y}}(\boldsymbol{y})p_{\boldsymbol{X}|\boldsymbol{Y}}(\boldsymbol{x}\,|\,\boldsymbol{y}) \quad a.e.\,\lambda_k\,, \tag{3.3.5}$$

其中 $\lambda_k$ 是 $k$ 维 Lebesgue 测度。即 j.p.d.f 可由 m.p.d.f 及条件 p.d.f.确定。

✧ 由定理 3.2.1 及定理 3.3.1 知，对于连续型 r.vec. $(\boldsymbol{X}',\boldsymbol{Y}')'$ 下列命题等价：

(1) $\boldsymbol{X},\boldsymbol{Y}$ 相互独立；

(2) $p_{\boldsymbol{X}}(\boldsymbol{x}) = p_{\boldsymbol{X}|\boldsymbol{Y}}(\boldsymbol{x}\,|\,\boldsymbol{y})\ \ a.e.\,\lambda_k$；

(3) $p_{\boldsymbol{Y}}(\boldsymbol{y}) = p_{\boldsymbol{Y}|\boldsymbol{X}}(\boldsymbol{y}\,|\,\boldsymbol{x}),\ a.e.\,\lambda_k$。

✧ Bayes 公式：设 $p_{\boldsymbol{X}}(\boldsymbol{x})$ 为 $\boldsymbol{X}$ 的先验密度，给定 $\boldsymbol{Y}=\boldsymbol{y}\in S_Y\subset\mathbb{R}^{k-m}$ 条件下 $\boldsymbol{X}$ 的后验密度为

$$p_{\boldsymbol{X}|\boldsymbol{Y}}(\boldsymbol{x}\,|\,\boldsymbol{y}) = \frac{p_{\boldsymbol{Y}|\boldsymbol{X}}(\boldsymbol{y}\,|\,\boldsymbol{x})p_{\boldsymbol{X}}(\boldsymbol{x})}{\int_{\boldsymbol{u}\in\mathbb{R}^{k-m}} p_{\boldsymbol{Y}|\boldsymbol{X}}(\boldsymbol{y}\,|\,\boldsymbol{u})p_{\boldsymbol{X}}(\boldsymbol{u})d\boldsymbol{u}},\quad \forall\boldsymbol{x}\in\mathbb{R}^m\text{。} \tag{3.3.6}$$

**例 3.3.3** 设 $(X,Y)$ 服从圆 $\{(x,y):\ x^2+y^2\le 1\}$ 内的均匀分布，求条件密度。

**解：** $(X,Y)$ 的 jpdf 为 $f(x,y)=\dfrac{1}{\pi}I(x^2+y^2\le 1)$。$X$ 的 mpdf 为

$$f_X(x)=\int_{-\infty}^{\infty}f(x,y)dy=\int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}}\frac{1}{\pi}dy\cdot I_{(-1,1)}(x)=\frac{2}{\pi}\sqrt{1-x^2}I_{(-1,1)}(x).$$

故 $x\in(-1,1)$ 时 $f_X(x)>0$。给定 $X=x\ (x\in(-1,1))$ 条件下 $Y$ 的条件密度函数为

$$f_{Y|X}(y\,|\,x)=\frac{f(x,y)}{f_X(x)}=\frac{1}{2\sqrt{1-x^2}}I_{(-\sqrt{1-x^2},\sqrt{1-x^2})}(y).$$

同理可得，给定 $Y=y\ (y\in(-1,1))$ 条件下 $X$ 的条件密度函数为

$$f_{X|Y}(x\,|\,y)=\frac{f(x,y)}{f_Y(y)}=\frac{1}{2\sqrt{1-y^2}}I_{(-\sqrt{1-y^2},\sqrt{1-y^2})}(x).$$

可见，mpdf $f_X(x)$ 与条件 p.d.f. $f_{X|Y}(x\,|\,y)$ 是不同的。这说明 $X$ 与 $Y$ 是有关系的。

问题：(1) 给定 $X=x\ (x\in(-1,1))$ 条件下 $Y$ 的条件分布函数是什么？

(2) 给定 $X>0$ 条件下 $Y$ 的条件分布又是怎样的？

**例 3.3.4** 多元正态分布的条件分布。

(1) 设 $(X,Y)\sim N_2(\boldsymbol{\mu},\Sigma)$，其中 $\boldsymbol{\mu}=\begin{pmatrix}\mu_1\\ \mu_2\end{pmatrix},\Sigma=\begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2\\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}$，$\sigma_1>0,\ \sigma_2>0,\ |\rho|<1$。

则由§3.1 及例 3.2.5 知，给定 $Y=y$ 条件下 $X$ 的条件密度为

$$p_{X|Y}(x\,|\,y)=\frac{p(x,y)}{p_Y(y)}=\frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}}\exp\left\{-\frac{(x-\mu_{1|2})^2}{2\sigma_1^2(1-\rho^2)}\right\},$$

即 $X\,|\,Y=y\sim N(\mu_{1|2},\sigma_1^2(1-\rho^2))$，其中 $\mu_{1|2}=\mu_1+\rho\dfrac{\sigma_1}{\sigma_2}(y-\mu_2)$。同理，给定 $X=x$ 条件下 $Y$ 的条件密度为

$$p_{Y|X}(y\,|\,x)=\frac{p(x,y)}{p_X(x)}=\frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{(y-\mu_{2|1})^2}{2\sigma_2^2(1-\rho^2)}\right\},$$

即 $Y\,|\,X=x\sim N(\mu_{2|1},\sigma_2^2(1-\rho^2))$，其中 $\mu_{2|1}=\mu_2+\rho\dfrac{\sigma_2}{\sigma_1}(x-\mu_1)$。

(2) 设$\boldsymbol{X} \sim N_k(\boldsymbol{\mu},\Sigma)$，$\boldsymbol{X}=\begin{pmatrix}\boldsymbol{X}_1\\ \boldsymbol{X}_2\end{pmatrix}$，$\boldsymbol{\mu}=\begin{pmatrix}\boldsymbol{\mu}_1\\ \boldsymbol{\mu}_2\end{pmatrix}$，$\Sigma=\begin{pmatrix}\Sigma_{11} & \Sigma_{12}\\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}$，其中$\boldsymbol{X}_j,\boldsymbol{\mu}_j$都是$k_j$维分量，$\Sigma_{jj}$是$k_j \times k_j$阶方阵，$j=1,2$，$k_1+k_2=k$。则由例 3.2.5 知

$\boldsymbol{X}_1 \mid \boldsymbol{X}_2=\boldsymbol{x}_2 \sim N_{k_1}(\boldsymbol{\mu}_{1|2},\Sigma_{11.2})$，其中 $\boldsymbol{\mu}_{1|2}=\boldsymbol{\mu}_1+\Sigma_{12}\Sigma_{22}^{-1}(\boldsymbol{x}_2-\boldsymbol{\mu}_2), \Sigma_{11.2}=\Sigma_{11}-\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$；

$\boldsymbol{X}_2 \mid \boldsymbol{X}_1=\boldsymbol{x}_1 \sim N_{k_2}(\boldsymbol{\mu}_{2|1},\Sigma_{22.1})$，其中 $\boldsymbol{\mu}_{2|1}=\boldsymbol{\mu}_2+\Sigma_{21}\Sigma_{11}^{-1}(\boldsymbol{x}_1-\boldsymbol{\mu}_1), \Sigma_{22.1}=\Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}$。

**例 3.3.5** 在对寿命数据的贝叶斯分析中，常用指数分布-Gamma 分布建模。设某产品的使用寿命$X \mid \lambda \sim \mathrm{Exp}(\lambda)$，而$\lambda$的先验信息可用$\mathrm{Ga}(\alpha,\beta^{-1})$描述。则可由 Bayes 公式(3.3.6)求出：$X=x$条件下$\lambda$的后验密度。由此知$\lambda$的后验分布为$\lambda \mid X=x \sim \mathrm{Ga}(\alpha+1,x+\beta^{-1})$。

**2. 混合型随机向量的条件分布**

考虑 ***k*=2 的情形**。设$(X,Y)$是一个二维随机向量，其中 $X$ 是离散型 r.v.，$Y$ 是连续型 r.v.。

**情况 2.1** 已知 $X$ 的分布列为 $\{p_X(x): x \in S_X\}$；对于$\forall x \in S_X$，给定 $X = x$时 $Y$ 的条件分布是连续型的，条件密度为 $p_{Y|X}(y|x)$。

记

$$F_{Y|X}(y|x) = P(Y \le y | X = x) = \int_{-\infty}^{y} p_{Y|X}(v|x)dv,\ \forall y \in \mathbb{R}, x \in S_X。$$

由 $p_{Y|X}(y|x)$ 的定义及全概率公式易验证，$F_{Y|X}(y|x)$ 是满足定义 3.2.2 要求的条件分布函数，因此，$(X,Y)$的联合分布可由$\{p_X(x): x \in S_X\}$及 $p_{Y|X}(y|x)$ 确定。此时，也可称

$$p(x,y) = p_{Y|X}(y|x)p_X(x),\ y \in \mathbb{R}, x \in S_X$$

为$(X,Y)$的联合密度。**注意**，这个密度既非连续型的，也非离散型的。

再考察 $Y$ 的边际分布。其 m.d.f.为

$$F_Y(y)=P(Y\le y)=\sum_{x\in S_X}P(X=x,Y\le y)=\sum_{x\in S_X}P(Y\le y\mid X=x)P(X=x)$$

$$=\sum_{x\in S_X}\int_{-\infty}^{y}p_{Y|X}(v\mid x)dv\cdot p_X(x)=\int_{-\infty}^{y}\sum_{x\in S_X}p_{Y|X}(v\mid x)p_X(x)dv,$$

其中最后一个等式求和与积分可交换，由级数在整个积分区间上绝对收敛保证。测度论中由 Fubini 定理可得。由此可知，$Y$ 的边际分布也是连续型的，m.p.d.f.为

$$p_Y(y)=\sum_{x\in S_X}p_{Y|X}(y\mid x)p_X(x)。$$

最后推导 Bayes 公式，即求给定 $Y=y$ 时 $X$ 的条件分布。因 $X$ 离散型分布，只需求条件分布列。因 $P(Y=y)=0$，故 $p_{X|Y}(x\mid y)$ 应理解为 $\lim\limits_{\varepsilon\to 0+}P(X=x\mid Y\in(y-\varepsilon,y+\varepsilon))$。对

$$P(X=x\mid Y\in(y-\varepsilon,y+\varepsilon))=\frac{P(Y\in(y-\varepsilon,y+\varepsilon)\mid X=x)P(X=x)}{P(Y\in(y-\varepsilon,y+\varepsilon))}=\frac{\dfrac{1}{2\varepsilon}\displaystyle\int_{y-\varepsilon}^{y+\varepsilon}p_{Y|X}(v\mid x)dv\cdot p_X(x)}{\dfrac{1}{2\varepsilon}\displaystyle\int_{y-\varepsilon}^{y+\varepsilon}p_Y(v)dv}$$

在 $p_Y(y)>0$ 且连续的 $y$ 处，即 $y\in S_Y$，求极限得

$$p_{X|Y}(x\,|\,y)=\frac{p_{Y|X}(y\,|\,x)p_X(x)}{p_Y(y)}=\frac{p_{Y|X}(y\,|\,x)p_X(x)}{\sum_{\tilde{x}\in S_X}p_{Y|X}(y\,|\,\tilde{x})p_X(\tilde{x})},\ x\in S_X\text{。}\tag{3.3.7}$$

**例 3.3.6** 设 $X=1$ 表示一个人患有某种疾病，$X=0$ 表示不患此疾病。$Y$ 表示某种血液检测指标。统计资料表明：

$$P(X=1)=\pi=1-P(X=0)\text{，}\ Y\,|\,X=1\sim N(\mu_1,\sigma_1^2)\text{，}\ Y\,|\,X=0\sim N(\mu_0,\sigma_0^2)\text{。}$$

现测得某人的血液指标为 $Y=y_0$，求其患此疾病的概率。

由 Bayes 公式(3.3.7)知，给定 $Y=y_0$ 时 $X$ 的后验分布列为

$$p_{X|Y}(1\,|\,y_0)=\frac{p_{Y|X}(y_0\,|\,1)p_X(1)}{p_Y(y_0)}=\frac{\dfrac{1}{\sqrt{2\pi}\sigma_1}e^{-\frac{(y_0-\mu_1)^2}{2\sigma_1^2}}\cdot\pi}{\dfrac{\pi}{\sqrt{2\pi}\sigma_1}e^{-\frac{(y_0-\mu_1)^2}{2\sigma_1^2}}+\dfrac{1-\pi}{\sqrt{2\pi}\sigma_0}e^{-\frac{(y_0-\mu_0)^2}{2\sigma_0^2}}}=1-p_{X|Y}(0\,|\,y_0)\text{。}$$

**情况 2.2** 已知 $Y$ 的 m.p.d.f.为 $p_Y(y)$，以及 $\forall y \in S_Y$，给定 $Y=y$ 时 $X$ 的条件分布列为

$$p_{X|Y}(x\,|\,y) \triangleq \lim_{\varepsilon \to 0+} P(X=x\,|\,Y \in (y-\varepsilon, y+\varepsilon)), x \in S_X。$$

这里 $S_Y, S_X$ 分别是 $Y, X$ 边际分布的支撑；给定 $Y=y$ 时 $X$ 的条件分布列的支撑是 $S_X$ 的子集，因而 $p_{X|Y}(x\,|\,y)$ 的有些值可能为 0。这从另一个侧面给出了对混合型联合分布的描述。此时，也称

$$p(x,y) = p_{X|Y}(x\,|\,y)p_Y(y),\ y \in \mathbb{R}, x \in S_X$$

为(X,Y)的联合密度。**注意**，这个密度也是既非连续型、也非离散型的。

由上述 $X$ 的条件分布列的定义，由 Riemann 积分的定义直观可知，

$$P(Y \le y, X=x) = \int_{-\infty}^{y} p_{X|Y}(x\,|\,t)p_Y(t)dt,\ \forall y \in \mathbb{R}, \forall x \in S_X，$$

而 $X$ 的边际分布列应为

$$p_X(x) \triangleq P(X=x) = \int_{-\infty}^{\infty} p_{X|Y}(x\,|\,y)p_Y(y)dy,\ x \in S_X。$$

由测度论中的 Fubini 定理知（积分与求和可交换次序）

$$\sum_{x\in S_X}\int_{\mathbb{R}} p_{X|Y}(x\,|\,y)p_Y(y)dy=\int_{\mathbb{R}}[\sum_{x\in S_X} p_{X|Y}(x\,|\,y)]p_Y(y)dy=\int_{\mathbb{R}} p_Y(y)dy=1,$$

及 $p_X(x)\ge 0$，说明这确实是一个分布列。

再由

$$P(Y\le y\,|\,X=x)=\frac{P(Y\le y,X=x)}{P(X=x)}=\int_{-\infty}^{y}\frac{p_{X|Y}(x\,|\,t)p_Y(t)}{p_X(x)}dt,\ \forall y\in\mathbb{R}$$

知，给定 $X=x\in S_X$ 时 $Y$ 的条件分布是连续型的，其条件密度为

$$p_{Y|X}(y\,|\,x)=\frac{p_{X|Y}(x\,|\,y)p_Y(y)}{p_X(x)}=\frac{p_{X|Y}(x\,|\,y)p_Y(y)}{\int_{-\infty}^{\infty}p_{X|Y}(x\,|\,v)p_Y(v)dv},\ y\in\mathbb{R}。\tag{3.3.8}$$

这是混合型联合分布的另一种 Bayes 公式。

**例 3.3.7** 某 Bernoulli 试验成功率$\theta$的先验分布为$\mathrm{Beta}(\alpha,\beta)$。给定$\theta$条件下独立重复 $n$ 次试验，成功次数 $X$ 的条件分布 $X\,|\,\theta \sim \mathrm{B}(n,\theta)$。那么，在观测到 $X=x$ 的条件下，用 Bayes 公式(3.3.8)可求得$\theta$的后验密度，由此知$\theta\,|\,X=x \sim \mathrm{Beta}(x+\alpha,\beta+n-x)$。

上述有关混合型随机向量条件分布的概念、结论也可进一步推广到多维、更复杂的情况，在贝叶斯分析等相关领域会根据需要作详细讨论。这里无法穷尽。

从前面的叙述可见，若离散型的分布列、连续型的 p.d.f. 用统一的形式表述，那么，无论离散型、连续型还是混合型分布，联合密度、边际密度、条件密度的形式显得比较一致，(3.3.2)、(3.3.6)~(3.3.8) 四个 Bayes 公式形式也一致。这样的表述可以带来许多方便。但是，离散与连续这两种密度，本质上、用于概率及数字特征计算时，还是有区别的，必须注意。

## 三、条件期望与条件方差

给定$\boldsymbol{Y}=\boldsymbol{y}$条件下 r.v. $X$ 的条件分布，如同普通的一维概率分布一样，也可以采用期望、方差、分位点等工具概括其特征。例如，贝叶斯分析中常用这些数字特征概括后验分布，回归分析中常用条件分布的期望、分位点等数字特征作预测。

这里，针对前面讨论的条件分布，考察最常用的两个数字特征——期望和方差的性质。虽然它们的数学定义与普通概率分布期望、方差的定义没什么不同，但为强调它们描述的是条件分布，故常称它们为条件期望、条件方差。

给定$\boldsymbol{Y}=\boldsymbol{y}$条件下 r.v. $X$ 的条件期望常记为$E(X\mid\boldsymbol{Y}=\boldsymbol{y})$。按定义 2.5.1~2.5.3，

$$E(X\mid\boldsymbol{Y}=\boldsymbol{y})=\begin{cases}\sum_{x\in S_X}xp_{X|\boldsymbol{Y}}(x\mid\boldsymbol{y}), & \text{if } X\mid\boldsymbol{Y}=\boldsymbol{y}\text{ 离散型分布；}\\ \int_{-\infty}^{\infty}xp_{X|\boldsymbol{Y}}(x\mid\boldsymbol{y})dx, & \text{if } X\mid\boldsymbol{Y}=\boldsymbol{y}\text{ 连续型分布；}\\ \int_{-\infty}^{\infty}xdF_{X|\boldsymbol{Y}}(x\mid\boldsymbol{y})dx, & \text{一般情况。}\end{cases}$$

定理 2.5.1、推论 2.5.1 也适用于$\boldsymbol{Y}=\boldsymbol{y}$条件下$g(X)$的条件期望，即

$$E(g(X)\,|\,\boldsymbol{Y}=\boldsymbol{y})=\begin{cases}\sum_{x\in S_X} g(x)p_{X|\boldsymbol{Y}}(x\,|\,\boldsymbol{y}), & \text{if } X\,|\,\boldsymbol{Y}=\boldsymbol{y}\text{ 离散型分布；}\\ \int_{-\infty}^{\infty} g(x)p_{X|\boldsymbol{Y}}(x\,|\,\boldsymbol{y})dx, & \text{if } X\,|\,\boldsymbol{Y}=\boldsymbol{y}\text{ 连续型分布；}\\ \int_{-\infty}^{\infty} g(x)dF_{X|\boldsymbol{Y}}(x\,|\,\boldsymbol{y})dx, & \text{一般情况。}\end{cases}$$

由此，按定义 2.6.1，给定 $\boldsymbol{Y}=\boldsymbol{y}$ 条件下 r.v. $X$ 的条件方差为

$$\operatorname{var}(X\,|\,\boldsymbol{Y}=\boldsymbol{y})=E\left[\left(X-E(X\,|\,\boldsymbol{Y}=\boldsymbol{y})\right)^2\,|\,\boldsymbol{Y}=\boldsymbol{y}\right]=E(X^2\,|\,\boldsymbol{Y}=\boldsymbol{y})-\left[E(X\,|\,\boldsymbol{Y}=\boldsymbol{y})\right]^2\text{。}$$

显然，$E(X\,|\,\boldsymbol{Y}=\boldsymbol{y})$ 是 $\boldsymbol{y}$ 的函数，记之为 $g(\boldsymbol{y})=E(X\,|\,\boldsymbol{Y}=\boldsymbol{y})$，常用 $E(X\,|\,\boldsymbol{Y})$ 表示 $g(\boldsymbol{Y})$。同理，$\operatorname{var}(X\,|\,\boldsymbol{Y}=\boldsymbol{y})$ 也是 $\boldsymbol{y}$ 的函数，记之为 $h(\boldsymbol{y})=\operatorname{var}(X\,|\,\boldsymbol{Y}=\boldsymbol{y})$，常用 $\operatorname{var}(X\,|\,\boldsymbol{Y})$ 表示 $h(\boldsymbol{Y})$。

**定理 3.3.2** $X,Y$ 都是 r.v.。两个重要的公式：

$$E(X)=E\left[E(X\,|\,Y)\right],$$
$$\operatorname{var}(X)=E\left[\operatorname{var}(X\,|\,Y)\right]+\operatorname{var}\left[E(X\,|\,Y)\right].$$

**例 3.3.8** 设 $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix})$，求给定 $X = x$ 时 $Y$ 的条件期望、条件方差。

**解：** 因为 $Y \mid X = x \sim N(\mu_2 + \rho\dfrac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1-\rho^2))$，故

$$E(Y \mid X = x) = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x - \mu_1),$$

$$\mathrm{var}(Y \mid X = x) = \sigma_2^2(1-\rho^2)。$$

由此条件期望、条件方差，及 $X \sim N(\mu_1, \sigma_1^2)$ 可验证

$$E[E(Y \mid X)] = E[\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(X - \mu_1)] = \mu_2 = E(Y);$$

$$\mathrm{var}[E(Y \mid X)] = \rho^2\frac{\sigma_2^2}{\sigma_1^2}\mathrm{var}(X) = \rho^2\sigma_2^2, \quad E[\mathrm{var}(Y \mid X)] = \sigma_2^2(1-\rho^2),$$

故 $\mathrm{var}[E(Y \mid X)] + E[\mathrm{var}(Y \mid X)] = \mathrm{var}(Y)$。

# § 3.4 随机向量函数的分布

第二章讨论过随机变量函数的概率分布。这里进一步讨论随机向量函数的概率分布。设 $\boldsymbol{X}=(X_1,\cdots,X_k)'$ 是一个 $k$ 维随机向量，分布已知，$g(\cdot)$ 是已知的 $(\mathbb{R}^k,\mathcal{B}_{\mathbb{R}^k})\to(\mathbb{R}^m,\mathcal{B}_{\mathbb{R}^m})$ $(m\le k)$ 的可测映照。记 $\boldsymbol{Y}=g(\boldsymbol{X})$，那么，$\boldsymbol{Y}$ 是一个 $m$ 维的随机向量。用§2.4/第 2 章课件 p70 类似的方法可证明，$\boldsymbol{Y}$ 的概率分布可由 $\boldsymbol{X}$ 的概率分布导出。本节讨论根据 $\boldsymbol{X}$ 的概率分布求 $\boldsymbol{Y}$ 的概率分布一些常用方法。

$g(\cdot)$ 不必在 $\mathbb{R}^k$ 上都有定义。设 $\exists\mathcal{X}\in\mathcal{B}_{\mathbb{R}^k}$，$P(\boldsymbol{X}\in\mathcal{X})=1$，$g(\cdot)$ 在 $\mathcal{X}$ 上都有定义。记

$$\mathcal{Y}=\{\boldsymbol{y}:\boldsymbol{y}=g(\boldsymbol{x}),\ \boldsymbol{x}\in\mathcal{X}\}$$

因 $g^{-1}(\mathcal{Y})=\mathcal{X}$，$P(\boldsymbol{Y}\in\mathcal{Y})=P(\boldsymbol{X}\in g^{-1}(\mathcal{Y})=\mathcal{X})=1$，故求 $\boldsymbol{Y}$ 的概率分布只需考虑 $\boldsymbol{Y}$ 在 $\mathcal{Y}$ 上的分布。$\mathcal{X}$ 最小只需要是 $\boldsymbol{X}$ 的某个广义支撑即可。

## 一、$X$ 是离散型分布的情况

设 $\boldsymbol{X}$ 是离散型 r. vec.，分布列为 $\{p_{\boldsymbol{X}}(\boldsymbol{x}):\boldsymbol{x}\in S_{\boldsymbol{X}}\}$。则 $\boldsymbol{Y}=g(\boldsymbol{X})$ 也是一个离散型 r. vec.，其分布列的计算步骤为：

1) 计算 $S_{\boldsymbol{Y}}=\{\boldsymbol{y}=g(\boldsymbol{x}):\boldsymbol{x}\in S_{\boldsymbol{X}}\}$；

2) 计算 $p_{\boldsymbol{Y}}(\boldsymbol{y})=P(\boldsymbol{Y}=\boldsymbol{y})=\sum\limits_{\{\boldsymbol{x}\in S_{\boldsymbol{X}}:g(\boldsymbol{x})=\boldsymbol{y}\}}p_{\boldsymbol{X}}(\boldsymbol{x}),\ \forall \boldsymbol{y}\in S_{\boldsymbol{Y}}.$

(即相同的 $g(\boldsymbol{x})$ 合并，对应的概率相加)。

**例 3.4.1** 教材 p162/例 3.3.1。$(X,Y)$ 的联合分布列为

| $X$ \ $Y$ | -1 | 1 | 2 |
|---|---|---|---|
| -1 | 5/20 | 2/20 | 6/20 |
| 2 | 3/20 | 3/20 | 1/20 |

求：(1) $Z_1=X+Y$，(2) $Z_2=XY$，(3) $Z_3=\max\{X,Y\}$ 的分布列。

**例 3.4.2** (1) **(Poisson 分布的独立可加性)** 设 $X_j \sim \mathrm{Poi}(\lambda_j),\ j=1,2$，且 $X_1, X_2$ 相互独立，则

$Y = X_1 + X_2 \sim \mathrm{Poi}(\lambda_1 + \lambda_2)$。

**解：** 显然，$Y$ 分布的支撑为非负整数。对于 $k = 0,1,2,\cdots$，

$$
\begin{aligned}
P(Y=k) &= P\left(\sum_{i=0}^{k}\{X_1 = i, X_2 = k-i\}\right) \\
&= \sum_{i=0}^{k} P\{X_1 = i, X_2 = k-i\} \quad \text{(卷积公式)} \\
&= \sum_{i=0}^{k} P(X_1 = i)P(X_2 = k-i) \ \text{(独立性)} = \frac{1}{k!}(\lambda_1+\lambda_2)^k e^{-(\lambda_1+\lambda_2)},
\end{aligned}
$$

所以 $Y \sim \mathrm{Poi}(\lambda_1 + \lambda_2)$。进一步可证：若 $X_j \sim \mathrm{Poi}(\lambda_j),\ j=1,\cdots,n$，且 $X_1,\cdots,X_n$ 相互独立，则 $Y = \sum_{j=1}^{n} X_j \sim \mathrm{Poi}(\sum_{j=1}^{n}\lambda_j)$。

(2) **(二项分布的独立可加性)** 若 $X_j \sim \mathrm{B}(n_j, p),\ j=1,2,\cdots,m$，且 $X_1, X_2,\cdots, X_m$ 相互独立，则 $Y = \sum_{j=1}^{m} X_j \sim \mathrm{B}(\sum_{j=1}^{m} n_j, p)$。

## 二、$X$ 是连续型分布的情况

### 1. 一一对应变换

**定理 3.4.1** 设连续型 r.vec. $\boldsymbol{X}=(X_1,\cdots,X_k)'$ 的 j.p.d.f. 为 $p_{\boldsymbol{X}}(x_1,\cdots,x_k)$，$\exists\mathcal{X}\in\mathcal{B}_{\mathbb{R}^k}$ 使

$P(\boldsymbol{X}\in\mathcal{X})=1$。$\begin{cases} y_1=g_1(x_1,\cdots,x_k) \\ \cdots\cdots \\ y_k=g_k(x_1,\cdots,x_k)\end{cases}$ 为 $\mathcal{X}\to\mathcal{Y}$ 的一一对应变换，逆变换为 $\begin{cases} x_1=h_1(y_1,\cdots,y_k) \\ \cdots\cdots \\ x_k=h_k(y_1,\cdots,y_k)\end{cases}$，

Jacobi 行列式 $J=\dfrac{\partial(x_1,\cdots,x_k)}{\partial(y_1,\cdots,y_k)}$ 存在。令 $\begin{cases} Y_1=g_1(X_1,\cdots,X_k) \\ \cdots\cdots \\ Y_k=g_k(X_1,\cdots,X_k)\end{cases}$，则 r.vec. $\boldsymbol{Y}=(Y_1,\cdots,Y_k)'$ 的

j.p.d.f. 为

$$p_{\boldsymbol{Y}}(y_1,\cdots,y_k)=\begin{cases} p_{\boldsymbol{X}}(h_1(y_1,\cdots,y_k),\cdots,h_k(y_1,\cdots,y_k))\cdot|J|, & \text{if } (y_1,\cdots,y_k)'\in\mathcal{Y}, \\ 0, & \text{else.}\end{cases}$$

**推论 3.4.1** 设 $k$ 维连续型 r.vec. $\boldsymbol{X}$ 的 j.p.d.f. 为 $p_{\boldsymbol{X}}(\boldsymbol{x})$，$A$ 为 $k$ 阶非退化常数矩阵，$\boldsymbol{b}$ 为 $k$ 维常数向量，则 $\boldsymbol{Y}=A\boldsymbol{X}+\boldsymbol{b}$ 的 j.p.d.f. 为 $p_{\boldsymbol{Y}}(\boldsymbol{y})=p_{\boldsymbol{X}}(A^{-1}(\boldsymbol{y}-\boldsymbol{b}))|\det A|^{-1}$。

**例 3.4.3** r.vec. $(X_1,X_2)'$ 具有 jpdf $f(x_1,x_2)=\begin{cases}4x_1x_2, & \text{for } 0<x_1<1, 0<x_2<1,\\ 0, & \text{otherwise.}\end{cases}$

令 $Y_1=\dfrac{X_1}{X_2}$, $Y_2=X_1X_2$。求 $(Y_1,Y_2)'$ 的 jpdf。

**解：**

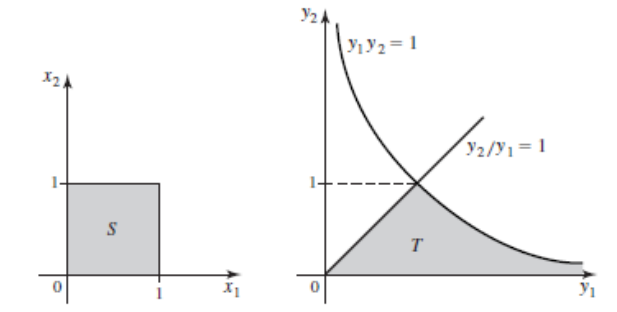


变换 $\begin{cases}y_1=x_1/x_2\\ y_2=x_1x_2\end{cases}$ 在 $\mathcal{X}=(0,1)^2$ 上一一对应，逆变换为

$\begin{cases}x_1=\sqrt{y_1y_2}\\ x_2=\sqrt{y_2/y_1}\end{cases}$，$\mathcal{Y}=\{(y_1,y_2)':0<y_2<1, y_2<y_1<y_2^{-1}\}$，

Jacobi 行列式为 $J=\begin{vmatrix}\partial x_1/\partial y_1 & \partial x_1/\partial y_2\\ \partial x_2/\partial y_1 & \partial x_2/\partial y_2\end{vmatrix}=\dfrac{1}{2y_1}$。由定理 3.4.1 知，$(Y_1,Y_2)'$ 的 jpdf 为

$$p(y_1,y_2)=f(\sqrt{y_1y_2},\sqrt{y_2/y_1})\left|\frac{1}{2y_1}\right|=\begin{cases}2y_2/y_1, & \text{for } (y_1,y_2)'\in\mathcal{Y},\\ 0, & \text{otherwise.}\end{cases}$$

**2. “多对一”的变换**

**定理 3.4.2** 设连续型 r. vec. $\boldsymbol{X}=(X_1,\cdots X_k)'$ 的 j.p.d.f.为 $p_{\boldsymbol{X}}(x_1,\cdots,x_k)$。$\mathcal{X}_0,\mathcal{X}_1,\cdots,\mathcal{X}_r$ 是 $\mathbb{R}^k$ 的一个可测分割，其中 $P(\boldsymbol{X}\in\mathcal{X}_0)=0$。对于 $i=1,\cdots,r$，当 $(x_1,\cdots,x_k)'\in\mathcal{X}_i$ 时，变换

$$\begin{cases}y_1=g_1(x_1,\cdots,x_k)\\ y_2=g_2(x_1,\cdots,x_k)\\ \quad\cdots\ \cdots\\ y_k=g_k(x_1,\cdots,x_k)\end{cases}\text{一一对应，逆变换为}\begin{cases}x_1=h_{i1}(y_1,\cdots,y_k)\\ x_2=h_{i2}(y_1,\cdots,y_k)\\ \quad\cdots\ \cdots\\ x_k=h_{ik}(y_1,\cdots,y_k)\end{cases}(y_1,\cdots,y_k)'\in\mathcal{Y}_i\text{，变换的 Jacobi}$$

行列式记为 $J_i$。设 $Y_j=g_j(X_1,\cdots,X_k)$，$j=1,\cdots,k$，则随机向量 $(Y_1,\cdots,Y_k)'$ 的 j.p.d.f. 为

$$p_{\boldsymbol{Y}}(y_1,\cdots,y_k)=\sum_{i=1}^{r}p_{\boldsymbol{X}}(h_{i1}(y_1,\cdots,y_k),\cdots,h_{ik}(y_1,\cdots,y_k))\cdot|J_i|I_{\mathcal{Y}_i}((y_1,\cdots,y_k)')\text{。}$$

**例 3.4.4** r.vec. $(X_1,X_2)'$服从单位圆内的均匀分布。令 $R=\sqrt{X_1^2+X_2^2}, V=X_1/X_2$。求 $(R,V)'$ 的 jpdf。

**3. 降维的变换 ($m<k$)**

**方法一，补一些变换，构造成一一对应变换，然后通过边际分布求得。**

**方法二，先求分布函数，再求 pdf。**

**3.1 求随机变量和的分布。** 设$(X_1,X_2)'\sim p_X(x_1,x_2)$，求 $Y=X_1+X_2$ 的分布。

方法一、先求$\begin{cases} Y_1=X_1 \\ Y=X_1+X_2 \end{cases}$的 j.p.d.f.，然后由其 m.p.d.f.得 $Y$ 的 p.d.f.。

变换$\begin{cases} y_1=x_1 \\ y=x_1+x_2 \end{cases}$在$\mathbb{R}^2\to\mathbb{R}^2$上一一对应，逆变换为$\begin{cases} x_1=y_1 \\ x_2=y-y_1 \end{cases}$，Jacobi 行列式$J=1$。由

定理 3.4.1 得，

$$p_{Y_1,Y}(y_1,y)=p_X(x_1(y_1,y),x_2(y_1,y))\,|J|=p_X(y_1,y-y_1)\,,$$

因此，$Y$ 的 p.d.f.为（卷积公式）

$$p_Y(y)=\int_{-\infty}^{\infty}p_X(y_1,y-y_1)dy_1\text{。}$$

若上述变换中取 $Y_1=X_2$，同理可得

$$p_Y(y)=\int_{-\infty}^{\infty}p_X(y-y_2,y_2)dy_2\text{。}$$

由这两个卷积公式所得 $Y$ 的 p.d.f.相同。

若 $X_1,X_2$ 相互独立，则其 j.p.d.f.是 m.p.d.f.的乘积，故计算 $Y$ p.d.f.的卷积公式为

$$p_Y(y)=\int_{-\infty}^{\infty}p_{X_1}(y_1)p_{X_2}(y-y_1)dy_1=\int_{-\infty}^{\infty}p_{X_1}(y-y_2)p_{X_2}(y_2)dy_2\text{。}$$

方法二、先求 $Y$ 的 d.f.：

$$F_Y(y)=P(Y\le y)=P(X_1+X_2\le y)=\iint\limits_{\{(x_1,x_2):x_1+x_2\le y\}} p_X(x_1,x_2)dx_1dx_2$$

$$=\int_{-\infty}^{\infty}\left[\int_{-\infty}^{y-x_1} p_X(x_1,x_2)dx_2\right]dx_1 \overset{let\ t=x_2+x_1}{=} \int_{-\infty}^{\infty}\left[\int_{-\infty}^{y} p_X(x_1,t-x_1)dt\right]dx_1$$

$$=\int_{-\infty}^{y}\left[\int_{-\infty}^{\infty} p_X(x_1,t-x_1)dx_1\right]dt,\ \forall y\in\mathbb{R}.$$

因而 $Y$ 的 p.d.f.为 $p_Y(y)=\int_{-\infty}^{\infty} p_X(x_1,y-x_1)dx_1$，即得上面第一个卷积公式。若将重积分化为先积 $x_1$ 再积 $x_2$ 的累次积分，则得上面第二个卷积公式 $p_Y(y)=\int_{-\infty}^{\infty} p_X(y-x_2,x_2)dx_2$。

**例 3.4.5**

(1) (独立正态分布之和) 设 $X_j\sim N(\mu_j,\sigma_j^2),\ j=1,\cdots,n$，且 $X_1,\cdots,X_n$ 相互独立，则 $Z=\sum_{j=1}^{n}X_j\sim N(\sum_{j=1}^{n}\mu_j,\sum_{j=1}^{n}\sigma_j^2)$。

(2) (独立 Gamma 分布之和) 设 $X_i\sim \mathrm{Ga}(\alpha_i,\lambda), i=1,\cdots,k$，且 $X_1,\cdots,X_k$ 相互独立，则 $Y=\sum_{i=1}^{k}X_i\sim \mathrm{Ga}(\sum_{i=1}^{k}\alpha_i,\lambda)$。

反复使用由卷积公式，即可证得结论。此例的两个结论在概率统计中很常用。

**定理 3.4.3 (多元正态的线性变换)** 设 $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \Sigma)$, $\boldsymbol{Y} = A\boldsymbol{X} + \boldsymbol{b}$，其中 $A$ 是 $m \times k$ 阶**行满秩**常数矩阵，$\boldsymbol{b}$ 是 $m$ 维常数列向量，$m \le k$，则 $\boldsymbol{Y} \sim N_m(A\boldsymbol{\mu} + \boldsymbol{b}, A\Sigma A')$。

**证明：**

1) 若 $m = k$，即 $A$ 是 $k$ 阶非退化方阵，则由推论 3.4.1 即得 $\boldsymbol{Y} \sim N_k(A\boldsymbol{\mu} + \boldsymbol{b}, A\Sigma A')$。

2) 若 $m < k$，则任取 $(k-m) \times k$ 阶常数矩阵 $B$，使 $C = \begin{pmatrix} A \\ B \end{pmatrix}$ 为 $k$ 阶非退化方阵，取 $\tilde{\boldsymbol{b}} = (\boldsymbol{b}'\ \boldsymbol{0}')'$，令 $\begin{pmatrix} \boldsymbol{Y} \\ \boldsymbol{Z} \end{pmatrix} = C\boldsymbol{X} + \tilde{\boldsymbol{b}}$，由 1)及例 3.2.5 即得 $\boldsymbol{Y} \sim N_m(A\boldsymbol{\mu} + \boldsymbol{b}, A\Sigma A')$。

由定理 3.4.3 易得多元正态分布的任意边际分布。设 $\boldsymbol{X} \sim N_k(\boldsymbol{\mu}, \Sigma)$，$\boldsymbol{Y} = (X_{i_1}, \cdots, X_{i_m})'$ 是由 $\boldsymbol{X}$ 的 $m$ 个分量组成的向量。因 $\boldsymbol{Y} = A\boldsymbol{X}$，其中 $A = (e_{i_1}, \cdots, e_{i_m})'$，$e_{i_j}$ 是第 $i_j$ 个元素为 1 其余元素为 0 的 $k$ 维单位向量，则由定理 3.4.3 即得 $\boldsymbol{Y} \sim N_m(A\boldsymbol{\mu} + \boldsymbol{b}, A\Sigma A')$。

**3.2 求随机变量商的分布。**设$(X_1,X_2)'\sim p_X(x_1,x_2)$，求 $U=X_1/X_2$ 的分布。

方法一、先求 $\begin{cases}U=X_1/X_2\\V=X_2\end{cases}$ 的 j.p.d.f.，然后由其 m.p.d.f.得 $U$ 的 p.d.f.。

变换$\begin{cases}u=x_1/x_2\\v=x_2\end{cases}$在$\{(x_1,x_2)\in\mathbb{R}^2:x_2\neq 0\}$上一一对应，逆变换为$\begin{cases}x_1=uv\\x_2=v\end{cases}$，$v\neq 0$，Jacobi 行列式为 $J=v$。由定理 3.4.1 得，

$$p_{U,V}(u,v)=p_X(x_1(u,v),x_2(u,v))\,|J|\,I(v\neq 0)=p_X(uv,v)\,|v|\,I(v\neq 0),$$

因此，$U$ 的 p.d.f.为

$$p_U(u)=\int_{-\infty}^{\infty}p_X(uv,v)\,|v|\,dv\text{。}$$

若上述变换中取$V=X_1$，则同理可得 $U$ 的 p.d.f.为

$$p_U(u)=\int_{-\infty}^{\infty}p_X(w,\frac{w}{u})\,|\frac{w}{u^2}|\,dw\text{。}$$

由这两个公式计算得到的 p.d.f. 相同。

方法二、先求 $U$ 的分布函数：

$$F_U(u)=\iint\limits_{x/y\le u} p_X(x,y)dxdy=\int_{-\infty}^{0}\left[\int_{uy}^{\infty}p_X(x,y)dx\right]dy+\int_{0}^{\infty}\left[\int_{-\infty}^{uy}p_X(x,y)dx\right]dy$$

$$\overset{let\ t=x/y}{=}\int_{-\infty}^{0}\left[\int_{-\infty}^{u}p_X(ty,y)\,|\,y\,|\,dt\right]dy+\int_{0}^{\infty}\left[\int_{-\infty}^{u}p_X(ty,y)ydt\right]dy$$

$$=\int_{-\infty}^{\infty}\left[\int_{-\infty}^{u}p_X(ty,y)\,|\,y\,|\,dt\right]dy=\int_{-\infty}^{u}\left[\int_{-\infty}^{\infty}p_X(ty,y)\,|\,y\,|\,dy\right]dt,\quad \forall u\in\mathbb{R}.$$

所以 $U$ 的密度函数为

$$p_U(u)=\int_{-\infty}^{\infty}p_X(uy,y)\,|\,y\,|\,dy,$$

即上面第一个商的密度公式。若将重积分化为先积 $y$ 再积 $x$ 的累次积分，则同理可得求 $U$ p.d.f.的另一个公式

$$p_U(u)=\int_{-\infty}^{\infty}p_X(w,\frac{w}{u})\,|\,\frac{w}{u^2}\,|\,dw。$$

**例 3.4.6 (*t* 分布与 *F* 分布的密度函数)**

(1) 设 $X \sim N(0,1), Y \sim \chi^2(n)$，且 $X,Y$ 相互独立，则称 $T = \dfrac{X}{\sqrt{Y/n}}$ 的分布为自由度为 $n$ 的 $t$ 分布，记作 $t(n)$，其 p.d.f.为

$$p_T(t) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}}(1+\frac{t^2}{n})^{-\frac{n+1}{2}},\ t \in (-\infty,\infty)。$$

自由度为 1 的 $t$ 分布 $t(1)$ 即 Cauchy 分布。

(2) 设 $X \sim \chi^2(m), Y \sim \chi^2(n)$，且 $X,Y$ 相互独立，则称 $F = \dfrac{X/m}{Y/n}$ 的分布为自由度为 $m,n$ 的 $F$ 分布，记作 $F(m,n)$，其 p.d.f.为

$$p_F(z) = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})}(\frac{m}{n})^{\frac{m}{2}} z^{\frac{m}{2}-1}(1+\frac{m}{n}z)^{-\frac{m+n}{2}} I_{(0,\infty)}(z)。$$

**3.3 求多个独立随机变量最大值、最小值的分布。**

设 $X_1,\cdots,X_n$ 是相互独立的**连续型** r.v.，且 $X_i$ 的 p.d.f. 、d.f.分别为 $f_i(x),F_i(x),i=1,\cdots,n$。

则 $Y=\min(X_1,\cdots,X_n)$ 的分布函数为

$$F_Y(y)=P(Y\le y)=P(\min\{X_1,\cdots,X_n\}\le y)=1-P(\min\{X_1,\cdots X_n\}>y)$$

$$=1-P(\bigcap_{i=1}^{n}\{X_i>y\})=1-\prod_{i=1}^{n}P(X_i>y)=1-\prod_{i=1}^{n}\left[1-F_i(y)\right],\ \forall y\in\mathbb{R},$$

对其求导可得 $Y$ 的 p.d.f.。

$Z=\max(X_1,\cdots,X_n)$ 的分布函数为

$$F_Z(z)=P(Z\le z)=P(\max\{X_1,\cdots,X_n\}\le z)=P(\bigcap_{i=1}^{n}\{X_i\le z\})=\prod_{i=1}^{n}F_i(z),\ \forall z\in\mathbb{R},$$

对其求导可得 $Z$ 的 p.d.f.。

当 $X_1,\cdots,X_n$ i.i.d. 即 $F_i(x)=F(x),f_i(x)=f(x),i=1,\cdots,n$ 时，$Y,Z$ 的 p.d.f.分别为

$$f_Y(y)=n\left[1-F(y)\right]^{n-1}f(y),\ y\in\mathbb{R};\qquad f_Z(z)=n\left[F(z)\right]^{n-1}f(z),\ z\in\mathbb{R}。$$

**定理 3.4.4** (数理统计学中的重要定理) 设 $X_1,\cdots,X_n$ i.i.d. $N(\mu,\sigma^2)$，记 $\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$，

$S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2$。则

1) $\bar{X}\sim N(\mu,\frac{\sigma^2}{n})$，$\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$；

2) $\bar{X}$ 与 $S^2$ 相互独立；

3) $T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1)$。

**证明：**

由 $X_1,\cdots,X_n$ i.i.d. $N(\mu,\sigma^2)$ 知，$(X_1,\cdots,X_n)'\sim N_n(\mu\mathbf{1}_n,\sigma^2 I_n)$。考虑正交变换 $\boldsymbol{y}=\Gamma\boldsymbol{x}$，其中 $\Gamma'=(\boldsymbol{l}_1,\cdots,\boldsymbol{l}_n)$ 是 $n$ 阶正交矩阵，且 $\boldsymbol{l}_1=(\frac{1}{\sqrt{n}},\cdots,\frac{1}{\sqrt{n}})'$。由定理 3.4.3 知，$\boldsymbol{Y}=\Gamma\boldsymbol{X}\sim N_n(\mu\Gamma\mathbf{1}_n,\sigma^2 I_n)$，其中 $\mu\Gamma\mathbf{1}_n=\mu(\boldsymbol{l}_1'\mathbf{1}_n,\cdots,\boldsymbol{l}_n'\mathbf{1}_n)'=(\sqrt{n}\mu,0,\cdots,0)'$。这说明：

i) $Y_1,\cdots,Y_n$ 相互独立； ii) $Y_1=\boldsymbol{l}_1'\boldsymbol{X}=\sqrt{n}\bar{X}\sim N(\sqrt{n}\mu,\sigma^2)$， $Y_2,\cdots,Y_n$ i.i.d. $N(0,\sigma^2)$。

又由 $\boldsymbol{Y}'\boldsymbol{Y}=\boldsymbol{X}'\Gamma'\Gamma\boldsymbol{X}=\boldsymbol{X}'\boldsymbol{X}$ 知，

$$\sum_{i=2}^{n}Y_i^2=\sum_{i=1}^{n}X_i^2-Y_1^2=\sum_{i=1}^{n}X_i^2-n\bar{X}^2=\sum_{i=1}^{n}(X_i-\bar{X})^2=(n-1)S^2\text{。}$$

由 ii)知

$$\bar{X}=\frac{1}{\sqrt{n}}Y_1\sim N(\mu,\frac{\sigma^2}{n}),\ \frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}=\frac{Y_1-\sqrt{n}\mu}{\sigma}\sim N(0,1)\text{；}$$

$$\frac{1}{\sigma}Y_2,\cdots,\frac{1}{\sigma}Y_n\ \ i.i.d.\ \ N(0,1)\text{。}$$

由例 2.4.4 及例 3.4.5(2)知

$$\frac{(n-1)S^2}{\sigma^2}=\sum_{i=2}^{n}(\frac{Y_i}{\sigma})^2\sim \mathrm{Ga}(\frac{n-1}{2},\frac{1}{2})=\chi^2(n-1)\text{。}$$

由 i)及定理 3.2.2 知， $\bar{X}$ 与 $S^2$ 相互独立。再由例 3.4.6 知， $T=\dfrac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1)$。

**4. 次序统计量的分布**

设 $X_1,\cdots,X_n$ 是 i.i.d.的 r.v.（是一个来自某总体的简单随机样本），将它们从小到大排序的结果记为 $X_{(1)}\le\cdots\le X_{(n)}$，常称 $(X_{(1)},\cdots,X_{(n)})$ 为 $X_1,\cdots,X_n$ 的次序统计量(order statistic)，称 $X_{(r)}$ 为第 $r$ 个次序统计量。有的文献中也将次序统计量记为 $(X_{1:n},\cdots,X_{n:n})$。显然，

$$X_{(1)}=\min(X_1,\cdots,X_n),\ X_{(n)}=\max(X_1,\cdots,X_n)。$$

当总体分布(即 $X_1$ 的分布)为**连续型**时，若已知 $X_1$ 的 p.d.f. 、d.f.分别为 $f(x),F(x)$，那么单个次序统计量的分布、多个次序统计量的联合分布都可精确求出。

**定理 3.4.5** 设 $X_1,\cdots,X_n$ 是 i.i.d.的连续型 r.v.，已知 $X_1$ 的 p.d.f. 、d.f.分别为 $f(x),F(x)$。

(1) 次序统计量 $(X_{(1)},\cdots,X_{(n)})$ 的联合分布是连续型的，j.p.d.f.为

$$p(x_1,\cdots,x_n)=n!\prod_{i=1}^{n}f(x_i)\cdot I(x_1<\cdots<x_n)。$$

(2) 第 $r$ 个次序统计量 $X_{(r)}$ 的 p.d.f.为

$$p_r(x)=\frac{n!}{(r-1)!(n-r)!}[F(x)]^{r-1}[1-F(x)]^{n-r}f(x)。$$

(3) 设 $0=i_0<i_1<\cdots<i_{r+1}=n+1, r\le n$，则 $(X_{(i_1)},\cdots,X_{(i_r)})$ 的 j.p.d.f.为

$$p_{i_1,\cdots,i_r}(x_1,\cdots,x_r)=\frac{n!}{\prod_{j=1}^{r+1}(i_j-i_{j-1}-1)!}[F(x_1)]^{i_1-1}\prod_{j=1}^{r-1}\left\{[F(x_{j+1}-F(x_j)]^{i_{j+1}-i_j-1}\right\}$$

$$\cdot[1-F(x_r)]^{n-i_r}\prod_{j=1}^{r}f(x_j)\cdot I(x_1<\cdots<x_r).$$

**证明：**

(1) $(x_1,\cdots,x_n)\to(x_{(1)},\cdots,x_{(n)})$ 是 $\mathbb{R}^n\to\mathbb{R}^n$ 上多对 1 的变换。设 $(i_1,\cdots,i_n)$ 是 $(1,\cdots,n)$ 的排列，记 $\mathcal{R}_{(i_1,\cdots,i_n)}=\{(x_1,\cdots,x_n):x_{i_1}<\cdots<x_{i_n}\}$，则 $(x_1,\cdots,x_n)\to(x_{(1)},\cdots,x_{(n)})$ 是 $\mathcal{R}_{(i_1,\cdots,i_n)}\to\mathcal{R}_{(1,\cdots,n)}$ 一一对应的，逆变换为 $(x_1,\cdots,x_n)'=(e_{i_1},\cdots,e_{i_n})(x_{(1)},\cdots,x_{(n)})'$，Jacobi 行列式为 $\pm1$。而

$$\mathbb{R}^n=\sum_{(i_1,\cdots,i_n)\text{是}(1,\cdots,n)\text{的排列}}\mathcal{R}_{(i_1,\cdots,i_n)}+\mathcal{R}_0,$$

且 $P((X_1,\cdots,X_n)\in\mathbb{R}^n-\mathcal{R}_0)=1$。$(X_1,\cdots,X_n)$的 j.p.d.f.为

$$f_X(x_1,\cdots,x_n)=f(x_1)\cdots f(x_n)。$$

由定理 3.4.2 知，次序统计量$(X_{(1)},\cdots,X_{(n)})$的 j.p.d.f.为

$$p(x_1,\cdots x_n)=\sum_{(i_1,\cdots,i_n)\text{是}(1,\cdots,n)\text{的排列}} f_X((e_{i_1},\cdots,e_{i_n})(x_1,\cdots,x_n)')I((x_1,\cdots x_n)\in\mathcal{R}_{(1,\cdots,n)})$$

$$=n!\prod_{i=1}^n f(x_i)\cdot I(x_1<\cdots<x_n).$$

因次序统计量$(X_{(1)},\cdots,X_{(n)})$是连续型分布的，故其任意边际分布都是连续型的。

(2) 方法一、先求 d.f.。显然，事件$\{X_{(r)}\le x\}=\{\sum_{i=1}^n I_{(-\infty,x]}(X_i)\ge r\}$。因$I_{(-\infty,x]}(X_1),\cdots,I_{(-\infty,x]}(X_n)$ i.i.d. $B(1,F(x))$，故 $\sum_{i=1}^n I_{(-\infty,x]}(X_i)\sim B(n,F(x))$，因此$X_{(r)}$的 d.f.为

$$F_r(x)=P(X_{(r)}\le x)=P(\sum_{i=1}^n I_{(-\infty,x]}(X_i)\ge r)=\sum_{k=r}^n\binom{n}{k}F^k(x)(1-F(x))^{n-k}。$$

对$F_r(x)$求导得$X_{(r)}$的 p.d.f.为

$$p_r(x)=\left[\sum_{k=r}^{n}\binom{n}{k}kF^{k-1}(x)(1-F(x))^{n-k}-\sum_{k=r}^{n-1}\binom{n}{k}(n-k)F^{k}(x)(1-F(x))^{n-k-1}\right]f(x)$$

$$=\left[\sum_{k=r}^{n}\frac{n!}{(k-1)!(n-k)!}F^{k-1}(x)(1-F(x))^{n-k}\right.$$

$$\left.\text{(let } k'=k+1\text{)}\quad -\sum_{k'=r+1}^{n}\frac{n!}{(k'-1)!(n-k')!}F^{k'}(x)(1-F(x))^{n-k'}\right]f(x)$$

$$=\frac{n!}{(r-1)!(n-r)!}F^{r-1}(x)(1-F(x))^{n-r}f(x).$$

方法二、概率元法。

$$p_r(x)=\lim_{\varepsilon\to 0+}\frac{1}{\varepsilon}P(X_{(r)}\in(x-\frac{\varepsilon}{2},x+\frac{\varepsilon}{2}))$$

$$=\lim_{\varepsilon\to 0+}\frac{1}{\varepsilon}\left[P\left(X_{(r)}\in(x-\frac{\varepsilon}{2},x+\frac{\varepsilon}{2}),\sum_{i=1}^{n}I_{(x-\frac{\varepsilon}{2},x+\frac{\varepsilon}{2})}(X_i)=1\right)+o(\varepsilon)\right].$$

(3) 概率元法。

# § 3.5 数字特征

## 一、随机向量函数的数学期望

若 $(X_1,\cdots,X_k)'$ 是一个 r.vec.，$Y=g(X_1,\cdots,X_k)$，那么求 $E(Y)$ 有两条途径：1) 先求出 $Y$ 的概率分布，再求出 $E(Y)$；2) 根据下面的定理来求。

**定理 3.5.1** 设$(X_1,\cdots,X_k)'$是一个 r.vec.，$g(\cdot)$是一个已知的 $k$ 元函数，$Y=g(X_1,\cdots,X_k)$。假定 $E(Y)$存在，那么

(1) 若$(X_1,\cdots,X_k)$具有离散型分布，联合分布列为$\{p(x_1,\cdots,x_k):(x_1,\cdots,x_k)\in S_X\}$，则

$$E(Y)=E[g(X_1,\cdots,X_k)]=\sum_{(x_1,\cdots,x_k)\in S_X} g(x_1,\cdots,x_k)p(x_1,\cdots,x_k)。$$

(2) 若$(X_1,\cdots,X_k)$具有连续型分布，j.p.d.f.为 $p(x_1,\cdots,x_k)$，则

$$E(Y)=E[g(X_1,\cdots X_k)]=\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} g(x_1,\cdots,x_k)p(x_1,\cdots,x_k)dx_1\cdots dx_k。$$

特别地，若取 $Y = X_j$，则

$$E(X_j) = \begin{cases} \sum_{(x_1,\cdots,x_k)\in S_X} x_j p(x_1,\cdots,x_k), & \text{if } (X_1,\cdots,X_k)' \text{ 离散型分布;} \\ \int_{\mathbb{R}^k} x_j p(x_1,\cdots,x_k)dx_1\cdots dx_k, & \text{if } (X_1,\cdots,X_k)' \text{ 连续型分布。} \end{cases}$$

**注意：**此定理中的积分为 $k$-重积分。

**例 3.5.1** 设 $X_1, X_2$ i.i.d. $\mathrm{Exp}(\lambda)$, $Y = \max(X_1, X_2)$，则

$$\begin{aligned} E(Y) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \max(x_1,x_2)p(x_1)p(x_2)dx_1dx_2 \\ &= \int_0^{\infty}\left[\int_0^{x_1} x_1 p(x_1)p(x_2)dx_2\right]dx_1 + \int_0^{\infty}\left[\int_{x_1}^{\infty} x_2 p(x_1)p(x_2)dx_2\right]dx_1 \\ &= \frac{3}{2\lambda}. \end{aligned}$$

此例亦可先求出 $Y$ 的 p.d.f.，再求其数学期望。

**期望的性质**

(1) $E(X+Y)=E(X)+E(Y)$。由此可得：

- 一般地，$E\left(\sum_{i=1}^{n}X_i\right)=\sum_{i=1}^{n}E(X_i)$；
- $E\left[ag_1(\boldsymbol{X})+bg_2(\boldsymbol{X})+c\right]=aEg_1(\boldsymbol{X})+bEg_2(\boldsymbol{X})+c$，其中 $\boldsymbol{X}$ 为 $k$ 维随机向量，$g_1(\cdot),g_2(\cdot)$ 为 $\mathbb{R}^k\to\mathbb{R}$ 的函数，$a,b,c$ 表示常数。

(2) 若 r.v. $X,Y$ 相互独立，则 $E(XY)=E(X)E(Y)$。

一般地，若 $\boldsymbol{X}_1,\cdots,\boldsymbol{X}_r$ 相互独立，$\boldsymbol{X}_j$ 的维数为 $k_j$，$f_j(\cdot):\mathbb{R}^{k_j}\to\mathbb{R}$，$j=1,\cdots,r$，则

$$E\left[f_1(\boldsymbol{X}_1)\cdots f_r(\boldsymbol{X}_r)\right]=Ef_1(\boldsymbol{X}_1)\cdots Ef_r(\boldsymbol{X}_r)。$$

## 二、协方差与相关系数

协方差与相关系数是刻划两个 r.v. 之间线性相关程度的数字特征。

**定义 3.5.1** 若 $E\left[(X-EX)(Y-EY)\right]$ 存在，则称之为 r.v. $X$ 与 $Y$ 的协方差 (Covariance)，记为 $\mathrm{Cov}(X,Y)$。

**定义 3.5.2** 若 $\mathrm{var}(X)\cdot\mathrm{var}(Y)>0$，则称 $\dfrac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{var}(X)\mathrm{var}(Y)}}$ 为 $X$ 与 $Y$ 的相关系数 (Coefficient of Correlation)，记为 $\mathrm{Corr}(X,Y)$。

**注：**

- $\mathrm{Cov}(X,Y)(or\ \ \mathrm{Corr}(X,Y))\begin{cases}>0, & \text{称 } X,Y \text{ 正相关;}\\ =0, & \text{称 } X,Y \text{ 不相关;}\\ <0, & \text{称 } X,Y \text{ 负相关.}\end{cases}$
- 设 $X^*,Y^*$ 分别是 r.v. $X, Y$ 的标准化，则 $\mathrm{Cov}(X^*,Y^*)=\mathrm{Corr}(X,Y)=\mathrm{Corr}(X^*,Y^*)$。
- 协方差的计算方法

$$\mathrm{Cov}(X,Y)=\begin{cases}\sum_{(x,y)\in\mathcal{X}}[x-E(X)][y-E(Y)]P(X=x,Y=y), & \text{if } (X,Y)\text{离散型分布;}\\ \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}[x-E(X)][y-E(Y)]p(x,y)dxdy, & \text{if } (X,Y)\text{ 连续型分布.}\end{cases}$$

**性质**

1. $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$； $\mathrm{Corr}(X,Y)=\mathrm{Corr}(Y,X)$。

2. $\mathrm{Cov}(X,Y)=E(XY)-E(X)\cdot E(Y)$。

3. $\mathrm{Cov}(X,X)=\mathrm{var}(X)$; $\mathrm{Cov}(X,c)=0,\forall$常数$c$。

4. $\mathrm{Cov}(aX+b,cY+d)=ac\mathrm{Cov}(X,Y)$； $\mathrm{Corr}(aX+b,cY+d)=\mathrm{sign}(ac)\mathrm{Corr}(X,Y)$ (if $ac\neq 0$)。

5. $\mathrm{Cov}(X_1+X_2,Y)=\mathrm{Cov}(X_1,Y)+\mathrm{Cov}(X_2,Y)$。

6. 与方差的关系： $\mathrm{var}(X+Y)=\mathrm{var}(X)+\mathrm{var}(Y)+2\mathrm{Cov}(X,Y)$。

   一般地， $\mathrm{var}(\sum_{i=1}^{n}a_iX_i)=\sum_{i=1}^{n}a_i^2\mathrm{var}(X_i)+2\sum_{i<j}a_ia_j\mathrm{cov}(X_i,X_j)$。

   若 $X_1,\cdots,X_n$ 两两不相关，则 $\mathrm{var}(\sum_{i=1}^{n}a_iX_i)=\sum_{i=1}^{n}a_i^2\mathrm{var}(X_i)$。

**例 3.5.2** (1) $X_1,\cdots,X_n$ i.i.d. $B(1,p)$，则 $X=\sum_{i=1}^{n}X_i\sim B(n,p)$。因 $E(X_1)=p,\ \mathrm{var}(X_1)=p(1-p)$,故

$$E(X)=E(\sum_{i=1}^{n}X_i)=\sum_{i=1}^{n}E(X_i)=np,$$

$$\mathrm{var}(X)=\mathrm{var}(\sum_{i=1}^{n}X_i)=\sum_{i=1}^{n}\mathrm{var}(X_i)=np(1-p).$$

(2) $X_1,\cdots,X_r$ i.i.d. $\mathrm{Ge}(p)$，则 $X=\sum_{i=1}^{r}X_i\sim \mathrm{NB}(r,p)$。因 $E(X_1)=\dfrac{1}{p},\ \mathrm{var}(X_1)=\dfrac{1-p}{p^2}$，故

$$E(X)=E(\sum_{i=1}^{r}X_i)=\sum_{i=1}^{r}E(X_i)=\frac{r}{p},$$

$$\mathrm{var}(X)=\mathrm{var}(\sum_{i=1}^{r}X_i)=\sum_{i=1}^{r}\mathrm{var}(X_i)=r\frac{1-p}{p^2}.$$

(3) 从装有 $M$ 个白球、$N-M$ 个黑球的袋子中随机不放回地摸出 $n$ 个，摸出的白球数 $X\sim \mathrm{HG}(n;N,M)$。记 $X_i$ 为第 $i$ 次摸出的白球数，$i=1,\cdots,n$，则 $X=\sum_{i=1}^{n}X_i$，且 $X_i\sim B(1,p),\ p=M/N$，$E(X_iX_j)=P(X_i=X_j=1)=M(M-1)/[N(N-1)],\ \forall i\neq j$。

因此，

$$E(X)=\sum_{i=1}^{n}E(X_i)=n\cdot M/N,$$

$$\mathrm{var}(X)=\mathrm{var}(\sum_{i=1}^{n}X_i)=\sum_{i=1}^{n}\mathrm{var}(X_i)+2\sum_{i<j}\mathrm{cov}(X_i,X_j)=np(1-p)(N-n)/(N-1).$$

7. (独立与不相关) 若 $X, Y$ 独立，则 $\mathrm{Cov}(X,Y)=0$；反之不成立。

即不相关是独立的必要条件，但不充分。因而可由 $\mathrm{Cov}(X,Y)\neq 0$ 知 $X, Y$ 不独立。

**例 3.5.3** 设 $(X,Y)'$ 服从单位圆内的均匀分布，则 $\mathrm{Cov}(X,Y)=0$，但两者不独立。

**例 3.5.4** 设 $(X,Y)'$ 服从二元正态分布，则 $X$ 与 $Y$ 相互独立等价于 $\mathrm{Cov}(X,Y)=0$。

8. (Cauchy-Schwarz 不等式) 对任意随机变量 $X,Y$ 有 $\left[E(XY)\right]^2 \le EX^2 \cdot EY^2$；等号成立当且仅当存在不全为 0 的 $a, b,$ 使得 $P(aX+bY=0)=1$。

**推论 1.** $\left[\mathrm{Cov}(X,Y)\right]^2 \le \mathrm{var}(X)\cdot \mathrm{var}(Y)$；等号成立当且仅当存在不全为 0 的 $a, b,$ 使得 $P(aX+bY=c)=1$。

**推论 2.** $\forall X,Y,\ |\mathrm{Corr}(X,Y)|\le 1$。且 $\mathrm{Corr}(X,Y)=\pm 1 \Longleftrightarrow$

$\exists a\ne 0, b,\ni P(Y=aX+b)=1;$ 且当 $a>0$ 时 $\mathrm{Corr}(X,Y)=1,$ 当 $a<0$ 时 $\mathrm{Corr}(X,Y)=-1.$

**注：** $|\mathrm{Corr}(X,Y)|$ 越大，说明 $X,Y$ 之间的线性关系越强；反之，越弱。但 $|\mathrm{Cov}(X,Y)|$ 的绝对值大小无法衡量线性关系的强弱。

## 三、协方差矩阵与相关矩阵

**定义 3.5.3** 设 r. vec. $\boldsymbol{X}=(X_1,\cdots,X_n)'$ 每个分量的期望都存在，则称 $E(\boldsymbol{X})=(E(X_1),\cdots,E(X_n))'$ 为 $\boldsymbol{X}$ 的期望向量；记 $b_{ij}=\mathrm{Cov}(X_i,X_j)$，称 $(b_{ij})_{n\times n}\triangleq\mathrm{Cov}(\boldsymbol{X},\boldsymbol{X})$ 为 $\boldsymbol{X}$ 的协方差矩阵；记 $r_{ij}=\mathrm{Corr}(X_i,X_j)$，称 $(r_{ij})_{n\times n}\triangleq\mathrm{Corr}(\boldsymbol{X},\boldsymbol{X})$ 为 $\boldsymbol{X}$ 的相关系数矩阵。

**性质：**

$\mathrm{Cov}(\boldsymbol{X},\boldsymbol{X})=E[(\boldsymbol{X}-E(\boldsymbol{X})(\boldsymbol{X}-E(\boldsymbol{X}))']$；

$\mathrm{Cov}(\boldsymbol{X},\boldsymbol{X})=\Lambda\cdot\mathrm{Corr}(\boldsymbol{X},\boldsymbol{X})\cdot\Lambda$，其中 $\Lambda=\mathrm{diag}(\mathrm{std}(X_1),\cdots,\mathrm{std}(X_n))$；

若 $\mathrm{Cov}(X_i,X_j),i,j=1,\cdots,n$ 存在，则 $\mathrm{Cov}(\boldsymbol{X},\boldsymbol{X}),\ \mathrm{Corr}(\boldsymbol{X},\boldsymbol{X})$ 非负定。

**例 3.5.5** 若 $\boldsymbol{X}\sim N_k(\boldsymbol{\mu},\Sigma)$，则

(1) $E(\boldsymbol{X})=\boldsymbol{\mu};\ \ \mathrm{Cov}(\boldsymbol{X},\boldsymbol{X})=\Sigma;$

(2) $X_1,\cdots,X_k$ 两两不相关等价于 $X_1,\cdots,X_k$ 相互独立.

## 四、矩母函数

性质（续§2.6）：

(4) 若 r.v. $X_1,\cdots,X_n$ 相互独立，且 $\exists h>0$，使得对 $\forall t\in(-h,h)$ 矩母函数 $E(e^{tX_i}), i=1,\cdots,n$ 都存在，则 $S_n=X_1+\cdots+X_n$ 的矩母函数存在，为

$$M_{S_n}(t)=E(e^{tS_n})=E\left(e^{t(X_1+\cdots+X_n)}\right)=\prod_{i=1}^{n}M_{X_i}(t),\ \forall t\in(-h,h)。$$

**定义 3.5.4 (随机向量的矩母函数)** 若在 $\exists\varepsilon>0$，当 $\boldsymbol{t}\in U(\boldsymbol{0},\varepsilon)=\{\boldsymbol{t}\in\mathbb{R}^k:\boldsymbol{t}'\boldsymbol{t}<\varepsilon^2\}$ 时，$E(e^{\boldsymbol{t}'\boldsymbol{X}})$ 都存在，则称

$$M_{\boldsymbol{X}}(\boldsymbol{t})=E(e^{\boldsymbol{t}'\boldsymbol{X}}),\boldsymbol{t}=(t_1,\cdots,t_k)'\in U(\boldsymbol{0},\varepsilon)\subset\mathbb{R}^k$$

为 $k$ 维 r.vec. $\boldsymbol{X}$ 的矩母函数。