第二章　随机变量及其概率分布

提　纲

§2.1　随机变量及其概率分布

§2.2　离散型随机变量

§2.3　连续型随机变量

§2.4　随机变量函数的分布

§2.5　数学期望

§2.6　方差及其他数字特征

§ 2.1 随机变量及其概率分布

第一章介绍了概率的公理化定义及其性质，这是迄今为止人们所发现的用于描述随机现象数学上最完善、应用面最广的一套模型框架。在此基础上，研究随机现象的各种技术方法迅速发展起来，非常丰富，而且应用广泛。

在实际应用中，研究随机现象往往主要关注其中某些数量属性的表现。这就产生了随机变量 (random variable, r. v.) 的概念。引进随机变量，有助于人们借助数学工具对随机现象进行量化研究。

一、 随机变量的定义

随机变量，直观来说就是用来记录随机试验出现的基本结果 (outcome) 的某一方面数量属性的一个实值变量。由于随机试验可能出现的基本结果不止一种，出现哪种结果事先不确定、随机会而定，因而描述结果数量属性的变量值也随机会而定，故称为随机变量。

若随机试验可用样本空间Ω描述，那么，随机变量就是从Ω到实数集 $\mathbb{R}$ 的映射，也即定义在Ω上的实值函数：设 $X(\omega)$ 为Ω上的 r.v.，即 $\forall \omega \in \Omega, \exists$ 唯一的 $x \in \mathbb{R}, \ni X(\omega) = x$。

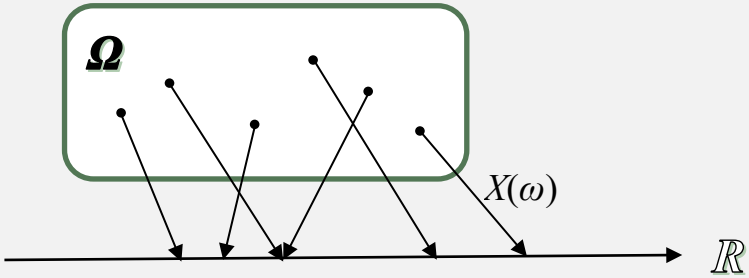

例 2.1.1

(1) 掷一枚骰子，观察出现的点数。样本空间可取为 $\Omega = \{1,2,3,4,5,6\}$。

a) 记出现的点数为随机变量 X，则 $X(\omega) = \omega$；

b) 也可引进别的随机变量，如 $Y(\omega) = \begin{cases} 1, & \text{if } \omega = 1,2,3, \\ 0, & \text{else.} \end{cases}$

(2) 随机抽取 n 个产品，逐个检验是否合格。样本点 $\boldsymbol{\omega}=(\omega_1,\cdots,\omega_n)$ 为依次记录各个产品合格与否形成的数组，其中 ω_i 取 0、1 分别表示第 i 个产品合格、不合格。样本空间

$$\Omega=\{\boldsymbol{\omega}=(\omega_1,\cdots,\omega_n):\omega_i=0,1,i=1,\cdots,n\}。$$

令 r.v. X_i 为第 i 个产品中的不合格品数，$i=1,\cdots,n$，r.v. X 为 n 个产品中的不合格品数，则 $X_i(\boldsymbol{\omega})=\omega_i, i=1,\cdots,n$， $X(\boldsymbol{\omega})=\sum_{i=1}^{n}\omega_i$。显然 $X(\boldsymbol{\omega})=\sum_{i=1}^{n}X_i(\boldsymbol{\omega})$。

(3) 观察某大卖场一天内来到的顾客数及其营业额。样本空间可取为

$$\Omega=\{\omega=(x,y):\ x=0,1,2,\cdots,\ y\in[0,\infty)\}。$$

a) 记到达的顾客数为随机变量 X，则 $X(\omega)=x$；

b) 记营业额为随机变量 Y，则 $Y(\omega)=y$；

c) 记人均消费额为随机变量 Z，则 $Z(\omega)=\begin{cases} y/x, & \text{if } x>0, \\ 0, & \text{if } x=0. \end{cases}$

(4) 观测一只股票一个交易日内每时每刻的价格。样本空间取

$$\Omega = \{\omega : \omega = x(t), t \in [0,T] \text{是非负连续函数}\}。$$

则 $\forall t \in [0,T]$ 时刻的股票价格 X_t 都是 r.v.，显然 $X_t(\omega) = x(t)$。还可以定义其他随机变量，如：日内最高价 $H(\omega) = \max\limits_{t\in[0,T]} x(t)$，最低价 $L(\omega) = \min\limits_{t\in[0,T]} x(t)$，等等。

(5) 观测上交所一个交易日内所有股票的交易情况。人们往往关注上证指数日内的最高点 X_1、最低点 X_2、收盘价 X_3、成交量 X_4 等等。这些变量都可被视为 r.v.，它们分别从不同角度反映上交所股票日交易状况 ω 的部分数量属性，它们的值随 ω 随机地变化。这里的样本点 ω、样本空间 Ω 过于复杂，人们常常不会刻意去描述，而只是通过上述 r.v. 去研究其某些局部的信息。但在概念上，仍应视这些 r.v.为 $\Omega \to \mathbb{R}$ 的函数。

r.v.常用大写英文字母表示，如 $X, Y, Z, X_1, X_2, \ldots$。其值常用小写字母表示，如 $x, y, z, \ldots$。

通过 r.v.研究随机现象，首先要刻画 r.v.的统计规律。若把观测 r.v.的值视为一个随机试验，那么自然地，可以 r.v.的取值为样本点，以$\mathbb{R}$或$\mathbb{R}$的某个子集为样本空间，由此建立一个合适的概率空间来描述 r.v.的统计规律。

r.v.的取值有多种情况。有的随机变量只可能取有限个值，如例 2.1.1/(1)、(2)中的 X, Y, $X_1,\cdots,X_n$ 等；有的随机变量可能取无限可列个值，如例 2.1.1/(3)中的 X；有的随机变量的取值可能充满某个区间，如例 2.1.1/(3)、(4)、(5)中的 Y,Z,X_t,H,L,X_1,X_2,X_3 等。研究不同类型 r.v. 的方法自然有所不同，但也有一些共性。基于这些共性，理论上就可能建立一套统一的、研究 r.v.的数学工具。

为此，概率论中常采用尽可能通用的可测空间$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$描述 r.v.，用$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的概率测度描述 r.v.的统计规律。即统一用$\mathbb{R}=(-\infty,\infty)$作为 r.v.的样本空间，允许考察 r.v. 落在每一个 Borel 可测集上的概率。

有的书中也讨论取广义实值 (即允许取 $-\infty,+\infty$) 的 r.v.，或取复数值的 r.v.。这些情况实际用处不多，这里不讨论。

研究 r.v. 最终是为研究它所描述的随机现象。因而，需要重视 r.v.所表述的事件与原始样本空间中事件之间的联系。要求“r.v.落在任一 Borel 可测集”所表述的都是原始样本空间中的可测集（即事件），这是一个很自然的要求。数学上称此要求为“可测”。直观而言，一个 r.v.实际上是了解原始概率空间 $(\Omega,\mathcal{F},P(\cdot))$ 的一个“窗口”。

随机变量的严格定义及其基本性质，涉及以下一些概念。

定义 2.1.1 (映照) 若每一个 $\omega_1\in\Omega_1$ 都存在唯一的 $\omega_2\in\Omega_2$ 与之对应，记 $\omega_2=f(\omega_1)$，则称对应关系 f 为 $\Omega_1\to\Omega_2$ 的映照(mapping)。对于 $A\subset\Omega_2$，称 $f^{-1}(A)=\{\omega_1\in\Omega_1:f(\omega_1)\in A\}$ 为 A 的原像。对于集合类 $\mathcal{C}\subset 2^{\Omega_2}$，称 $f^{-1}(\mathcal{C})=\{f^{-1}(A):A\in\mathcal{C}\}$ 为 $\mathcal{C}$ 的原像。

命题 2.1.1 设 f 为 $\Omega_1 \to \Omega_2$ 的映照，则

1) $f^{-1}(\Omega_2)=\Omega_1$， $f^{-1}(\varnothing)=\varnothing$；

2) 若 $A\subset\Omega_2$，则 $f^{-1}(A^c)=[f^{-1}(A)]^c$；

3) 若 $A_i\subset\Omega_2, i\in\mathcal{I}$，则 $f^{-1}(\bigcap\limits_{i\in\mathcal{I}}A_i)=\bigcap\limits_{i\in\mathcal{I}}f^{-1}(A_i)$， $f^{-1}(\bigcup\limits_{i\in\mathcal{I}}A_i)=\bigcup\limits_{i\in\mathcal{I}}f^{-1}(A_i)$。

即：原像与集合的余、交、并、差、直和等运算都可交换次序，且不限于可列运算。

命题 2.1.2 设 f 为 $\Omega_1 \to \Omega_2$ 的映照，则

1) 若 $\mathcal{G}$ 是 Ω_2 上的σ域，则 $f^{-1}(\mathcal{G})$ 是 Ω_1 上的σ域；

2) 若 $\mathcal{C}\subset 2^{\Omega_2}$，则 $f^{-1}(\sigma_{\Omega_2}(\mathcal{C}))=\sigma_{\Omega_1}(f^{-1}(\mathcal{C}))$。

定义 2.1.2 (可测映照) 设 $(\Omega_i,\mathcal{F}_i), i=1,2$ 是两个可测空间，f 为 $\Omega_1 \to \Omega_2$ 的映照，若 $f^{-1}(\mathcal{F}_2)\subset\mathcal{F}_1$，则称 f 为 $(\Omega_1,\mathcal{F}_1)\to(\Omega_2,\mathcal{F}_2)$ 的可测映照。此时常记 $\sigma(f)=f^{-1}(\mathcal{F}_2)$，是由 f 生成的 $\mathcal{F}_1$ 的子σ域。

定理 2.1.1 设 $(\Omega_i,\mathcal{F}_i), i=1,2,3$ 都是可测空间。

1) 若 $\mathcal{C}\subset 2^{\Omega_2}$，则 f 为 $(\Omega_1,\mathcal{F}_1)\to(\Omega_2,\sigma(\mathcal{C}))$ 的可测映照的充要条件为 $f^{-1}(\mathcal{C})\subset\mathcal{F}_1$。

2) 设 g 为 $(\Omega_1,\mathcal{F}_1)\to(\Omega_2,\mathcal{F}_2)$ 的可测映照、f 为 $(\Omega_2,\mathcal{F}_2)\to(\Omega_3,\mathcal{F}_3)$ 的可测映照，则复合映照 $f\circ g(\omega_1)=f(g(\omega_1))$ 是 $(\Omega_1,\mathcal{F}_1)\to(\Omega_3,\mathcal{F}_3)$ 的可测映照。

定义 2.1.3(可测函数/随机变量) 若 f 为 $(\Omega,\mathcal{F})\to(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 的可测映照，则称 f 为 $(\Omega,\mathcal{F})$ 上的可测函数；若 $(\Omega,\mathcal{F})$ 是描述随机现象的可测空间，则称 f 为 $(\Omega,\mathcal{F})$ 上的随机变量。

命题 2.1.3 设 f 为 $\Omega\to\mathbb{R}$ 的映照，$\mathcal{C}\subset 2^{\mathbb{R}}$ 且 $\mathcal{B}_{\mathbb{R}}=\sigma(\mathcal{C})$。则 f 是 $(\Omega,\mathcal{F})$ 上可测函数的充要条件为 $f^{-1}(\mathcal{C})\subset\mathcal{F}$。

由课件例 1.2.5 知，$\mathcal{B}_{\mathbb{R}}=\sigma(\{(-\infty,x]:x\in\mathbb{R}\})=\sigma(\{(-\infty,x]:x\in\mathbb{Q}\})$，因此，由命题 2.1.3 知，判断 f 是否 $(\Omega,\mathcal{F})$ 上的 r.v.，只需对 $\forall x\in\mathbb{R}$ 或 $\forall x\in\mathbb{Q}$ 验证 $f^{-1}((-\infty,x])\in\mathcal{F}$。

定理 2.1.2 本定理中所有可测函数都是可测空间$(\Omega,\mathcal{F})$上的。

(1) 若$f_n, n=1,2,\cdots$是一列可测函数，则 $\sup\limits_n f_n, \inf\limits_n f_n, \overline{\lim\limits_{n\to\infty}} f_n, \underline{\lim\limits_{n\to\infty}} f_n$ 都是可测函数。

(2) 记$\mathcal{E}$是由所有可测示性函数$I_A(\omega), A\in\mathcal{F}$张成的线性空间，即所有简单函数（或称可测阶梯函数）组成的集合。若$f,g\in\mathcal{E}$，则 $af+bg, f\cdot g, f\wedge g, f\vee g\in\mathcal{E}$。

(3) f是可测函数的充要条件是：存在简单函数列$f_n, n=1,2,\cdots$，使

$$f(\omega)=\lim_{n\to\infty} f_n(\omega), \forall\,\omega\in\Omega。$$

若f非负，则可取非负递增的$f_n, n=1,2,\cdots$；若$|f|\le M$则可取到 $|f_n|\le M, n=1,2,\cdots$。

(4) 若f, g 都是可测函数，则 $af+bg$, $f\cdot g$, f/g, f^+, f^-, $|f|$，$f\wedge g$，$f\vee g$ 都是可测函数。

定理 2.1.3 (Doob 定理) 设 f 是$(\Omega,\mathcal{F})\to(\mathrm{E},\mathcal{E})$的可测映照，$\sigma(f)=f^{-1}(\mathcal{E})\subset\mathcal{F}$。则 g 是$(\Omega,\sigma(f))$上的可测函数 $\Leftrightarrow$ $\exists\,(\mathrm{E},\mathcal{E})$上的可测函数$h$，使得 $g(\omega)=h\circ f(\omega)$。

二、随机变量的概率分布

前面说过，定义在可测空间$(\Omega,\mathcal{F})$上的 r.v. X 的统计规律可一般地用$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的某概率测度$P_X(\cdot)$描述。若 r.v. X 所描述的随机现象用概率空间$(\Omega,\mathcal{F},P(\cdot))$描述，则$P_X(\cdot)$应取决于$P(\cdot)$，而$P_X(\cdot)$反映的是$P(\cdot)$的部分信息。

定义 2.1.4 (概率分布) 设$(\Omega,\mathcal{F},P(\cdot))$ 是一个概率空间，$X(\omega)$是$(\Omega,\mathcal{F})$上的随机变量，令

$$P_X(A)=P(X^{-1}(A)),\ \forall A\in\mathcal{B}_{\mathbb{R}},$$

则$P_X(\cdot)$是由 r.v. X 在$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上导出的概率测度，称之为 r.v. X 的概率分布。

$\forall A\in\mathcal{B}_{\mathbb{R}}$，由 r.v. X 表述的Ω中的事件$X^{-1}(A)$，常表示为$\{X\in A\}$，相应的概率常写成

$$P(X\in A)=P(X^{-1}(A))。$$

当 A 为区间$[a,b],(a,b],[a,b),(a,b)$或单点集$\{a\}$时，相应的概率常写成

$$P(X\in[a,b]),\ P(X\in(a,b]),\ P(X\in[a,b)),\ P(X\in(a,b)),\ P(X\in\{a\}),$$

或者 $P(a\le X\le b),\ P(a<X\le b),\ P(a\le X<b),\ P(a<X<b),\ P(X=a)$ 等。

由于 $\mathcal{B}_{\mathbb{R}}=\sigma(\mathcal{C})$，其中 $\mathcal{C}=\{(-\infty,x]:x\in\mathbb{R}\}$ 是一个 π 类，由引理 1.2.1 知，$(\mathbb{R},B_{\mathbb{R}})$上的任一概率测度 $P_X(\cdot)$ 都取决于实函数

$$F(x)\triangleq P_X((-\infty,x]),\ x\in\mathbb{R}。$$

因此，任意 r.v.的概率分布都可以等价地用这样一个实函数来全面描述。这为研究 r.v. 提供了一个通用、有力的工具。

定义 2.1.5 (分布函数) 设 $P_X(\cdot)$ 是 $(\mathbb{R},B_{\mathbb{R}})$ 上的概率测度，称实函数

$$F(x)\triangleq P_X((-\infty,x]),\ x\in\mathbb{R}$$

为概率测度 $P_X(\cdot)$ 的分布函数(*distribution function*, d.f.) 或累积分布函数(*cumulative*

distribution function, c.d.f.)。若 $P_X(\cdot)$ 由 r.v. X 导出，则其分布函数

$$F(x)=P(X\le x),\ x\in\mathbb{R}$$

也称为 r.v. X 的分布函数，常记 $X\sim F(\cdot)$。“~”是“服从”、“遵从”的意思。

注：

由于 $\mathcal{B}_{\mathbb{R}}$ 也是由 π 类 $\mathcal{C}'=\{(-\infty,x):x\in\mathbb{R}\}$ 张成的最小 σ 域，由引理 1.2.1 知，$(\mathbb{R},B_{\mathbb{R}})$ 上的任一概率测度 $P_X(\cdot)$ 也可取决于实函数 $\tilde{F}(x)\triangleq P_X((-\infty,x)),\ x\in\mathbb{R}$。这是分布函数的另一种等价定义，李贤平《概率论基础（第三版）》等书中采用该定义。本课程采用更流行的定义 2.1.5。

定义 2.1.6 (同分布) 若 r.v. X 与 Y 的概率分布相同（或者等价地，它们的分布函数相同），则称 X 与 Y 同分布。常记为 $X\overset{d}{=}Y$。

同分布的 r.v. 各自描述的随机现象可以不同、没有任何联系。但这些随机现象的某些数量属性具有相同的统计规律，因而相应的 r.v.在 $(\mathbb{R}, B_{\mathbb{R}})$ 上有完全相同的概率分布。同分布的 r.v.可以采用相同的模型、方法研究。概率论主要研究 r.v.的概率分布，往往暂时忽略 r.v.与它描述的实际随机现象之间的联系，故常将 r.v.写成 X 而不常写成 $X(\omega)$。

三、分布函数的性质

下面分别是 Cauchy 分布（连续型）、只取 $-1,2,3$ 三值的离散型分布的分布函数图。

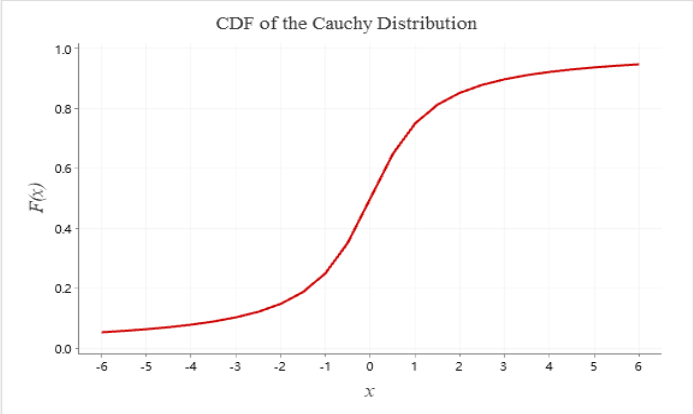

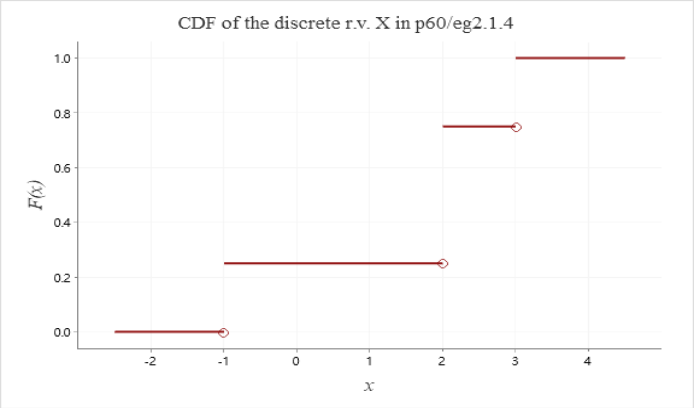

注：

- 通常用 F, G, H 等大写字母表示分布函数。注意，分布函数的自变量是实数，而不是事件或随机变量，写成“$F(X \le x)$、$F(X)$”都是不对的。
- 分布函数的来源：累积频率分布。
- r.v. X 的 d.f. 记录的是所有 $\{X \le x\}$, $x \in \mathbb{R}$ 这些事件的概率，但它能决定可由 X 表示的所有事件即 $\{X \in A\}, \forall A \in \mathcal{B}_{\mathbb{R}}$ 的概率。任意类型 r.v.的概率分布都可由其 d.f.全面刻划。
- 可用分布函数表示下列事件的概率

$$P(X > a) = 1 - P(X \le a) = 1 - F(a)$$

$$P(a < X \le b) = P(\{X \le b\} - \{X \le a\}) = F(b) - F(a)$$

$$P(X < a) = \lim_{x \to a-} F(x) = F(a-)，\quad P(X = a) = P(\{X \le a\} - \{X < a\}) = F(a) - F(a-)$$

$$P(X \ge a) = 1 - P(X < a) = 1 - F(a-)，\quad P(a \le X \le b) = F(b) - F(a-)$$

$$P(a \le X < b) = F(b-) - F(a-)，\quad P(a < X < b) = F(b-) - F(a)，\quad \dots\dots$$

定理 2.1.4 (分布函数的基本性质) 实函数 $F(\cdot)$ 是某 r.v.（或 $(\mathbb{R}, B_{\mathbb{R}})$ 上某概率测度）的 d.f.，当且仅当 $F(\cdot)$ 同时满足下列三个条件：

a) （单调性）$F(x)$ 在 $x \in \mathbb{R}$ 上单调非减，即 $\forall a < b,\ F(a) \le F(b)$；

b) （有界性）$\lim\limits_{x \to -\infty} F(x) = 0,\ \lim\limits_{x \to \infty} F(x) = 1$；

c) （右连续性）$F(x+) \triangleq \lim\limits_{\varepsilon \to 0+} F(x+\varepsilon) = F(x),\ \forall x \in \mathbb{R}$。

证明：

必要性：由第一章概率的基本性质证。

充分性：根据定理 1.2.2 Carathéodory 延拓定理，若实函数 $F(x)$ 满足上述三条性质，则在 $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ 上必存在唯一的概率测度 P_X，使得 $P_X((a,b]) = F(b) - F(a), \forall -\infty < a < b < \infty$。

注：

✧ 若定义 r.v. X 的 d.f.为：$\tilde{F}(x) = P(X < x),\ x \in \mathbb{R}$，则基本性质 a) b)不变，c)变为“左连续”。

✧ d.f.在每一点处的左右极限都存在，即 $F(x-)\le F(x)\le F(x+),\forall x\in\mathbb{R}$；且最多有可列个不连续点，即 $\{x:F(x-)<F(x+),x\in\mathbb{R}\}$ 最多是一个可列集。

例 2.1.2 请说明 $F(y)=\sum_{i=1}^{6}\frac{2i-1}{36}I_{[i,\infty)}(y)$ 是一个分布函数，并画其图像。设 r.v. $Y\sim F(y)$，求 Y 在哪些点上取值，取各值的概率。

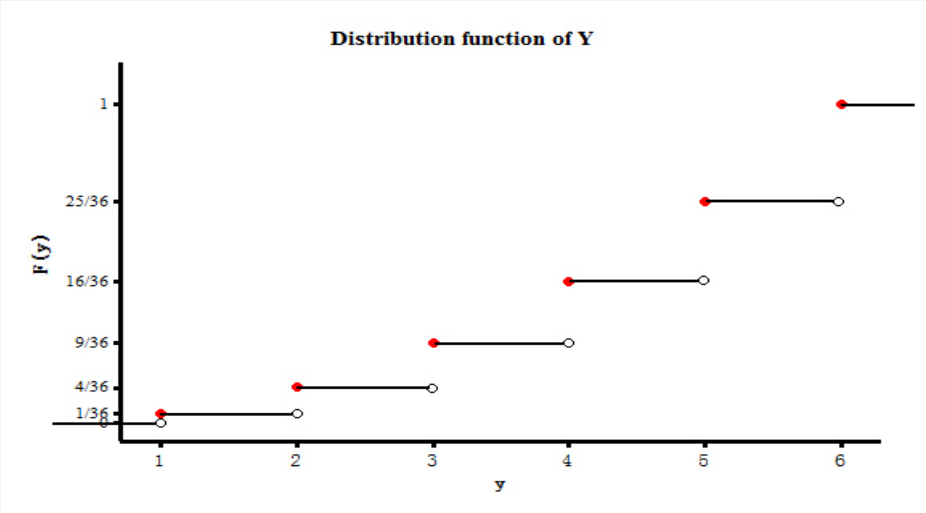

例 2.1.3 证明

$$F(x)=\begin{cases}0, & x\le 0,\\ x, & 0<x\le 1,\\ 1, & x>1.\end{cases}$$

是一个分布函数。设 r.v. $X\sim F(x)$，求 $P(X\in(a,b)), P(X\in[a,b]), P(X=x)$。

例 2.1.4 设 r.v. X 的分布函数为

$$F(x)=\begin{cases}0, & x<0,\\ 1/4, & 0\le x<1,\\ x/2, & 1\le x<2,\\ 1, & 2\le x.\end{cases}$$

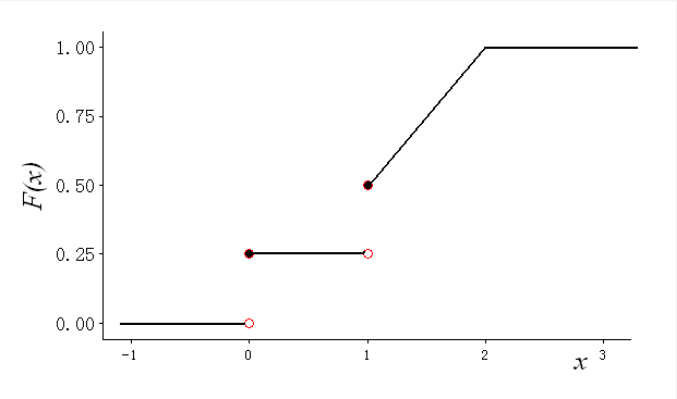

因此

1) $P(X<1)=F(1-)=1/4$。

2) $P(X=1)=F(1)-F(1-)=1/2-1/4=1/4$。

3) $P(\frac{1}{2}\le X<\frac{3}{2})=F(\frac{3}{2}-)-F(\frac{1}{2}-)=\frac{1}{2}\frac{3}{2}-\frac{1}{4}=\frac{1}{2}$。

4) $P(X=\frac{3}{2})=F(\frac{3}{2})-F(\frac{3}{2}-)=0$。

5) 求 c 使得 $P(X\le c)=\frac{2}{3}$。即求 c 使得 $F(c)=\frac{2}{3}$，解得 $c=\frac{4}{3}$。

6) 求 c 使得 $P(X\le c)=0.4$。 7) 求 c 使得 $P(X\le c)=0.25$。

四、分位点

定义 2.1.7 设 $F(x)$ 为分布函数。对于给定的 $p\in(0,1)$，若 a_p 满足

$$F(a_p-)\le p\le F(a_p),$$

则称 a_p 为 $F(x)$的 p 分位点(*quantile*)。

分位点 a_p 可视为 d.f.的反函数 $F^{-1}(p)$ 在 p 处的值。若 $F(\cdot)$ 连续、严增，则 $\forall p \in (0,1)$，$F^{-1}(p)$ 存在且唯一；反之，有些 p 处 $F^{-1}(p)$ 不存在或不唯一。因此，常统一地取

$$a_p = F^{-1}(p) = \inf\{x : F(x) \geq p\},\ p \in (0,1)。$$

这个 a_p 既符合定义 2.1.7，又避免了不唯一的情况。

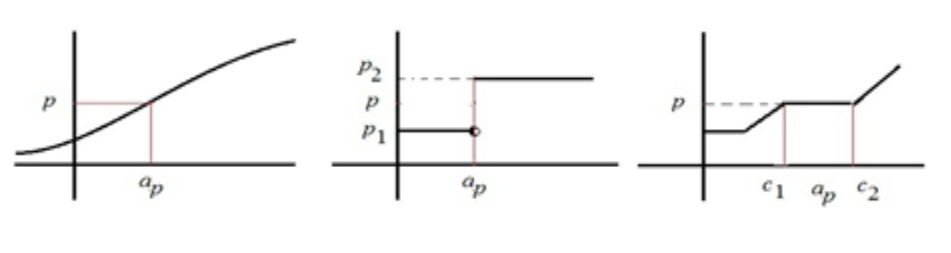

一些常用的分位点及其特殊名称：

$a_{0.5}$ 中位数 (median)，$a_{0.25}$ 第一四分位数(first quartile)，$a_{0.75}$ 第三四分位数(third quartile)

$a_{0.1}, a_{0.2}, \cdots, a_{0.9}$ 第一～第九十分位数 (first decile ～ ninth decile)

例 2.1.5 计算例 2.1.2~2.1.4 中各分布函数的第一、第三四分位数，第一~第九十分位数。

例 2.1.6 (Value at Risk, VaR) 金融风险管理中，人们常用 VaR 度量某一资产在一定时期内可能面临的最大损失。VaR 就是根据收益率的分位点定义的。它有两个参数：时间长度与置信水平。定义如下。

设一项资产的现值为 V_0，指定期末的未来值为 V_1 (r.v.)，该时期的收益率为 $R=(V_1-V_0)/V_0$，设 R 的信息可用 d.f. $F_R(x)$ 描述。取置信水平为 $1-\alpha$，则 VaR 值 $v^*=-V_0 r_\alpha$，其中 r_α 为 R 的 α 分位点。

其含义为：有 $1-\alpha$ 的把握说该资产至期末的损失不超过 v^*，或者等价地，该资产至期末的损失超过 v^* 的可能性为 α。因为 $P(V_0-V_1>v^*)=P(\frac{V_1-V_0}{V_0}<-\frac{v^*}{V_0})=P(R<r_\alpha)\le\alpha$。

§ 2.2 离散型随机变量

一、离散型 r.v.与离散型分布

定义 2.2.1 (离散型 r.v.与离散型分布) 若存在有限或可列集 $S=\{x_i : i=1,2,\cdots\}\subset\mathbb{R}$，使得 $P(X\in S)=1$，则称 X 为离散型 r.v.，称其概率分布为离散型分布，称 $\{(x_i,p_i):i=1,2,\cdots\}$ 为 X 的概率分布列，简称分布列，其中 $p_i=P(X=x_i)$。

注：

✧ 在表述定义或一般性结论时，我们都把离散型 r.v.的不同取值写成无限可列个的情况，如果 r.v.只取 n 个值，那应将 ∞ 改为 n。

✧ 离散型 r.v. 是一类最简单的 r.v.，常用于刻划随机现象的分类或计数特征。显然，$B_i \triangleq X^{-1}(\{x_i\}), i=1,2,\cdots$ 两两互斥且 $\sum_{i=1}^{\infty} B_i=\Omega$，故 $X(\omega)=\sum_{i=1}^{\infty} x_i I_{B_i}(\omega)$。

✧ 也常泛称 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上满足 $P(S)=1$ 的概率测度 P（未必由 r.v.导出）为离散型的，其中 $S\subset\mathbb{R}$ 至多可列，称 $\{(x,P(\{x\})):x\in S\}$ 为其分布列。

离散型分布取决于其分布列

若离散型 r.v. X 的分布列为 $\{(x_i, p_i), i=1,2,\cdots\}$，则其概率分布 $(\mathbb{R}, \mathcal{B}_{\mathbb{R}}, P_X(\cdot))$ 为

$$P_X(A) = P(X \in A) = \sum_{i=1}^{\infty} p_i I_A(x_i),\ \forall A \in \mathcal{B}_{\mathbb{R}},$$

其分布函数为

$$F(x) = P(X \le x) = \sum_{i=1}^{\infty} p_i I_{[x_i,\infty)}(x),\ \forall x \in \mathbb{R}。$$

离散型分布的分布函数必是单调非降的阶梯函数，各 x_i 为其跳跃点，跳跃幅度为

$$p_i = F(x_i) - F(x_i-),\ i=1,2,\cdots。$$

定理 2.2.1 (分布列的基本性质) 一个实数列 $p_i, i=1,2,\cdots$ 能用作某个离散型分布的分布列的充要条件为： a) （非负性） $p_i \ge 0,\ i=1,2,\cdots$； b) （规范性） $\sum_{i=1}^{\infty} p_i = 1$。

分布列的表示方法：

通项公式，如：$P(X=x)=f(x),\ x=x_1,x_2,\cdots$ （1、r.v. 取哪些值；2、取值概率）

列表、条形图等，适用于 r.v.只可能取有限个值的情况。

离散型分布的另一种描述方式——离散型概率密度函数(*discrete probability density function*，简称离散型密度函数，或称概率质量函数，*probability mass function,* p.m.f.)。

分布列为 $\{(x_i,p_i),i=1,2,\cdots\}$ 的离散型分布，其 p.m.f 为

$$f(x)=P(X=x)=\begin{cases} p_i, & \text{if } x=x_i, i=1,2,\cdots, \\ 0, & \text{else.} \end{cases}$$

显然 $f(x)=\sum_{i=1}^{\infty} p_i I_{\{x_i\}}(x),\ x\in\mathbb{R}$。

注： 离散型密度函数只是将分布列延拓成定义域为$(-\infty,\infty)$的函数，两者本质是一样的。它们都是研究离散型 r.v.的重要且实用的工具。

例 2.2.1 掷一枚质地均匀的骰子两次。以两次所得点数组成的有序数组为样本点，样本空间为 $\Omega=\{(a,b):a,b=1,2,\cdots,6\}$。假定各基本事件等概率。定义两个随机变量：$X$ 为两次所得点数之和，Y 为两次所得点数之大者。求 X，Y 的分布列。

解： 将随机变量 X，Y 与样本点的函数关系列于下表

$\omega=(a,b)$	X	Y	$\omega=(a,b)$	X	Y	$\omega=(a,b)$	X	Y
(1,1)	2	1	(3,1)	4	3	(5,1)	6	5
(1,2)	3	2	(3,2)	5	3	(5,2)	7	5
(1,3)	4	3	(3,3)	6	3	(5,3)	8	5
(1,4)	5	4	(3,4)	7	4	(5,4)	9	5
(1,5)	6	5	(3,5)	8	5	(5,5)	10	5
(1,6)	7	6	(3,6)	9	6	(5,6)	11	6
(2,1)	3	2	(4,1)	5	4	(6,1)	7	6
(2,2)	4	2	(4,2)	6	4	(6,2)	8	6
(2,3)	5	3	(4,3)	7	4	(6,3)	9	6
(2,4)	6	4	(4,4)	8	4	(6,4)	10	6
(2,5)	7	5	(4,5)	9	5	(6,5)	11	6
(2,6)	8	6	(4,6)	10	6	(6,6)	12	6

由上表可知，X 的可能取值为 2,3,…,12，其分布列为

x	2	3	4	5	6	7	8	9	10	11	12
$P(X=x)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

X 分布列可用如下通项公式表示：

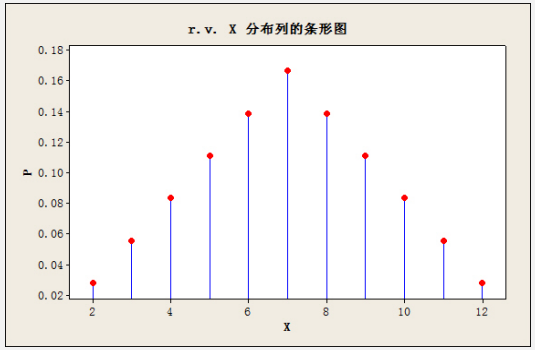

$$P(X=x)=\frac{6-|x-7|}{36},\ x=2,3,\cdots,12\,,$$

X 的 p.m.f. 为 $f_X(x)=\dfrac{6-|x-7|}{36}I_{\{2,3,\cdots,12\}}(x),\ x\in\mathbb{R}$。

Y 的可能取值为 1,2,…,6，其分布列为

y	1	2	3	4	5	6
$P(Y=y)$	1/36	3/36	5/36	7/36	9/36	11/36

Y 的 p.m.f. 为 $f_Y(y)=\dfrac{2y-1}{36}I_{\{1,\cdots,6\}}(y),\ y\in\mathbb{R}$。

Y 的 d.f. 为 $F_Y(y)=\sum_{i=1}^{6}\dfrac{2i-1}{36}I_{[i,\infty)}(y),\ y\in\mathbb{R}$，其图像如例 2.1.2 所示。

二、常用的离散型分布

1. 单点分布 以概率 1 取某个给定的值 (比如 a) 的离散型分布，称为单点分布，记为δ_a。

若 r.v. $X \sim \delta_a$，即 $P(X=a)=1$，其 p.m.f.为$f(x)=I_{\{a\}}(x)$，d.f.为 $F(x)=I_{[a,\infty)}(x)$。

2. 离散均匀分布 若 r.v. X 以相同的概率在$m\,(<\infty)$个不同的点$x_1,\cdots,x_m$上取值，称 X 服从$\{x_1,\cdots,x_m\}$上的离散均匀分布。其分布列为

$$P(X=x_i)=\frac{1}{m},\ i=1,\cdots,m\text{。}$$

p.m.f.为

$$f(x)=\frac{1}{m}I_{\{x_1,\cdots,x_m\}}(x),$$

d.f. 为

$$F(x)=\frac{1}{m}\sum_{i=1}^{m}I_{[x_i,\infty)}(x)\text{。}$$

3. Bernoulli 分布 若 r.v. X 只可能取 0，1 两个值，分布列为

$$P(X=x)=p^x(1-p)^{1-x}, x=0,1，其中 p\in(0,1)。$$

则称 X 服从参数为 p 的 *Bernoulli* 分布，记作 $X\sim B(1,p)$。其 p.m.f.为

$$f(x)=p^x(1-p)^{1-x}I_{\{0,1\}}(x)。$$

若 $p=0$，则 $B(1,p)$ 退化为单点分布 δ_0；若 $p=1$，则退化为 δ_1。

Bernoulli 分布描述的是 Bernoulli 试验中“成功”次数的统计规律。这是一类最简单的随机试验，其结果只有“成功”与“失败”两种，它由许多实际试验抽象而来。一般地，在任意一个随机试验中，某个指定事件发生次数的分布即为 Bernoulli 分布。例如：

- 检查一个产品，看它是否合格，可以把合格作为“成功”结果；
- 买一注彩票，看是否中奖，可把中奖作为“成功”结果；
- 判断明天股指是否上涨，可把上涨作为“成功”结果；等等。

4. 二项分布 (Binomial Distribution)

独立地重复进行 n 次“成功”概率为 p $(0<p<1)$ 的 Bernoulli 试验（n 重 Bernoulli 试验），记成功次数为 X，则称 X 服从参数为 n,p 的二项分布，记作 $X \sim \mathrm{B}(n,p)$。

分布列

X 可能取到的值为 0，1，…，n。$\{X=x\}$表示事件“n 次试验中恰有 x 次成功”，为 $\binom{n}{x}$ 个互斥事件之并，即

$$\{X=x\}=\sum_{a_i\in\{0,1\},i=1,\cdots,n\text{ 且 }\sum_{i=1}^{n}a_i=x} A_1^{a_1}\cdots A_n^{a_n},$$

其中 A_i^1 表示“第 i 次试验成功”，A_i^0 表示“第 i 次试验失败”。因各次试验相互独立、每次试验成功的概率为 p，故上式中

$$P(A_1^{a_1}\cdots A_n^{a_n})=P(A_1^{a_1})\cdots P(A_n^{a_n})=p^{\sum_{i=1}^{n}a_i}(1-p)^{n-\sum_{i=1}^{n}a_i}=p^x(1-p)^{n-x}。$$

再由概率的有限可加性可得 X 的分布列为

$$P(X=x)=\binom{n}{x}p^x(1-p)^{n-x},\quad x=0,1,\cdots,n\text{。}$$

显然，对于 $\forall p\in(0,1)$，$\binom{n}{x}p^x(1-p)^{n-x}\geq 0,\ x=0,1,\cdots,n$，且

$$\sum_{x=0}^{n}\binom{n}{k}p^x(1-p)^{n-x}=[p+(1-p)]^n=1,$$

因此，这确实是一个满足非负性与规范性的分布列，该分布列由二项式展开的各项构成，二项分布因此而得名。$B(n,p)$ 的 p.m.f. 为

$$f(x)=\binom{n}{x}p^x(1-p)^{n-x}I_{\{0,\cdots,n\}}(x)\text{。}$$

注：

- n=1 的二项分布就是 Bernoulli 分布。
- p=0 时，$B(n,p)$ 退化为单点分布 δ_0；p=1 时，$B(n,p)$ 退化为单点分布 δ_n。

二项分布的特点：

- $p<0.5$ 时分布右偏，$p=0.5$ 时分布对称，$p>0.5$ 时分布左偏。
- (对称性) 若 $X \sim B(n,p)$，则 $Y=n-X \sim B(n,1-p)$。
- 若记 X_i 为第 i 次 Bernoulli 试验中的成功次数，则 $X=\sum_{i=1}^{n} X_i$。

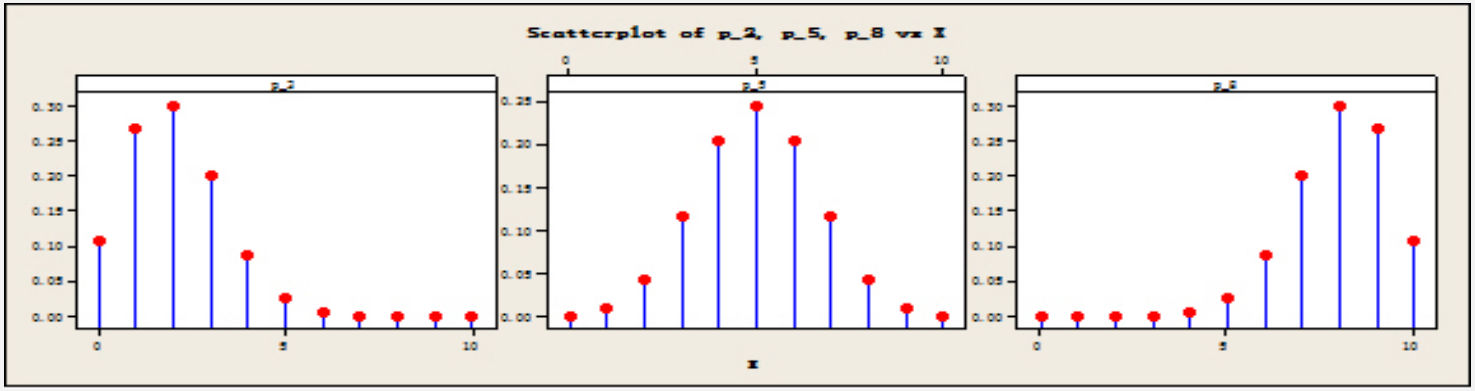

二项分布概率的计算：统计软件、查表。

例 2.2.2 买一注 35 选 7 的彩票，若投注的号码押中了 7 个开奖号中的 6 个，则中一等奖。

某人用随机选号方式购买了 100 注这样的彩票，求：其中至少有一注中一等奖的概率。

解：

买一注彩票看是否中一等奖，可视为一次 Bernoulli 试验。以中一等奖为“成功”结果，则一次试验中的成功概率为

$$p=\binom{7}{6}\binom{35-7}{1}\Big/\binom{35}{7}=0.000029147\text{。}$$

用随机选号方式买 100 注彩票，可视为独立地重复了 100 次成功概率为 p 的 Bernoulli 试验。因此，中一等奖的注数 $X\sim B(100,p)$。$\{X\geq 1\}$ 表示事件“至少有一注中一等奖”，

$$\begin{aligned}P(X\geq 1)&=1-P(X=0)\\&=1-\binom{100}{0}p^0(1-p)^{100}=1-(1-0.000029147)^{100}\\&\approx 0.0029147.\end{aligned}$$

5. 超几何分布 (Hypergeometric Distribution)

该分布源于对有限群体的**不放回**抽样。设一袋中共有 N 个球，其中白球 M 个。从中**不放回地**任取 n 个球，记抽中的白球数为 X。称 X 服从参数为 n,N,M 的超几何分布，记作 $X \sim \mathrm{HG}(n;N,M)$。

分布列

若对袋中球编号，用抽中球号的组合作为样本点，用古典概率描述上述试验，则由课件例 1.3.4 知，X 的分布列为

$$P(X=x)=\binom{M}{x}\binom{N-M}{n-x}\Big/\binom{N}{n},\ x=\max\{0,n-(N-M)\},\cdots,\min\{M,n\}。$$

由分布列的规范性可知

$$\sum_{x=\max\{0,n-(N-M)\}}^{\min\{M,n\}}\binom{M}{x}\binom{N-M}{n-x}=\binom{N}{n}。$$

与二项分布的关系

如果从袋中有放回地随机抽 n 个球，那么抽中的白球数 $X \sim B(n,\frac{M}{N})$。当 $n << N$ 且 $n < M$ 时，不放回抽球与有放回抽球非常接近，因此对 $X \sim \mathrm{HG}(n;N,M)$ 有

$$P(X=x) \approx \binom{n}{x}\left(\frac{M}{N}\right)^x\left(1-\frac{M}{N}\right)^{n-x},\ x=0,\cdots,n,$$

即 $X \dot{\sim} \mathrm{B}(n,\frac{M}{N})$。

6. 几何分布 (Geometric Distribution)

独立地重复“成功”概率为 p $(0<p<1)$ 的 Bernoulli 试验，记首次成功时的试验次数为 X。称 X 服从参数为 p 的几何分布，记为 $X \sim \mathrm{Ge}(p)$。

分布列

首次成功可以发生在第 1、2、…次，直至无穷多次试验中，所以应将 X 视为定义在由可列个独立的“成功”概率为 p 的 Bernoulli 试验生成的乘积概率空间上的 r.v.。X 的可能取值为 $1,2,\cdots$， 事件

$$\{X=x\}=A_1^0\cdots A_{x-1}^0A_x^1。$$

其中 A_i^1 表示“第 i 次试验成功”，A_i^0 表示“第 i 次试验失败”。因各次试验相互独立、每次试验的“成功”概率都为 p，故上式中

$$P(A_1^0\cdots A_{x-1}^0A_x^1)=P(A_1^0)\cdots P(A_{x-1}^0)P(A_x^1)=(1-p)^{x-1}p。$$

因此，X 的分布列为

$$P(X=x)=(1-p)^{x-1}p,\ x=1,2,\cdots。$$

该分布列的非负性、规范性显然。几何分布因其分布列由几何级数的各项构成而得名。

几何分布的特点：无记忆性。

设 $X\sim \mathrm{Ge}(p)$，对于任意整数 $k>0,s\geq 0$，有

$$P(X=k+s\mid X>s)=\frac{P(X=k+s)}{P(X>s)}=\frac{(1-p)^{k+s-1}p}{\sum_{l=s+1}^{\infty}(1-p)^{l-1}p}=(1-p)^{k-1}p=P(X=k)。$$

该等式说明，独立 Bernoulli 试验在已失败 s 次的情况下，再经 k 次首获成功的条件概率与从 0 开始经 k 次首获成功的无条件概率相同。这个试验机制对于失败似乎没有记忆。

注：

- p=1 时，$\mathrm{Ge}(p)$ 退化为单点分布 δ_1；p=0 时，$P(X=\infty)=1$。
- 也常称首次成功前失败的试验次数 Y 服从参数为 p 的几何分布，显然 $Y=X-1$。

7. 负二项分布 (Negative Binomial Distribution / Pascal Distribution)

独立地重复进行“成功”概率为 p 的 Bernoulli 试验，记第 r 次成功时的试验次数为 X。称 X 服从参数为 r,p 的负二项分布，记为 $X\sim\mathrm{NB}(r,p)$。显然，$\mathrm{NB}(1,p)$ 即为 $\mathrm{Ge}(p)$。

分布列

与几何分布类似，第 r 次成功可发生在第 $r, r+1, \cdots$ 次，直至无穷多次试验中，所以也应将 X 视为定义在由可列个独立的“成功”概率为 p 的 Bernoulli 试验生成的乘积概率空间上的 r.v.。X 的可能取值为 $r, r+1, \cdots$，事件 $\{X=x\}$ 为 $\binom{x-1}{r-1}$ 个互斥事件之并，即

$$\{X=x\}=\sum_{a_i\in\{0,1\},i=1,\cdots,x-1\text{ 且 }\sum_{i=1}^{x-1}a_i=r-1}(A_1^{a_1}\cdots A_{x-1}^{a_{x-1}}A_x^1),$$

其中 A_i^1 表示第 i 次试验“成功”，A_i^0 表示第 i 次试验“失败”。因各次试验相互独立、每次试验的“成功”概率都为 p，故上式中

$$P(A_1^{a_1}\cdots A_{x-1}^{a_{x-1}}A_x^1)=P(A_1^{a_1})\cdots P(A_{x-1}^{a_{x-1}})P(A_1^1)=p^{\sum_{i=1}^{x-1}a_i+1}(1-p)^{x-1-\sum_{i=1}^{x-1}a_i}=(1-p)^{x-r}p^r,$$

因此 X 的分布列为

$$P(X=x)=\binom{x-1}{r-1}(1-p)^{x-r}p^r,\quad x=r,r+1,\cdots。$$

由

$$\sum_{x=r}^{\infty}\binom{x-1}{r-1}(1-p)^{x-r}p^{r}\overset{令y=x-r,q=1-p}{=}\sum_{y=0}^{\infty}\binom{y+r-1}{y}q^{y}p^{r}=(1-q)^{-r}p^{r}=1,$$

可见该分布列的非负性、规范性。此分布列由负二项式$(1-q)^{-r}$的 Maclaurin 展开式中的各项构成，负二项分布因此而得名。

注：

- $\mathrm{NB}(1,p)$ 即 $\mathrm{Ge}(p)$。
- 若记第$i-1$次成功之后至第 i 次成功时的试验次数为X_i，$i=1,2,\cdots,r$，则 $X_1,\cdots,X_r$ 相互独立（随机变量的独立性在第三章定义）且都服从$\mathrm{Ge}(p)$，而 $X=\sum_{i=1}^{r}X_i$。

例 2.2.3 甲、乙两赌徒按某种方式赌博，约定先胜 t 局者赢得全部赌注。当赌博进行到甲胜 r 局、乙胜 s 局时因故中断，$r<t,s<t$。Pascal、Fermat 等人研究了上述情况下的赌注

分配问题，他们提出：设想赌博继续下去，以甲、乙各自最终先胜 t 局的概率来分配赌注。负二项分布的来历与此赌注分配问题有关。

设每局中甲胜的概率为 p、乙胜的概率为 $1-p$，各局的赌博结果相互独立。在设想的后续赌博中事件 A “甲最终先胜 t 局”等价于“甲胜 $t-r$ 局前负少于 $t-s$ 局”。若记在设想的后续赌博中，甲胜第 $t-r$ 局时恰赌了 X 局，则 $X \sim \mathrm{NB}(t-r,p)$，因此

$$P(A)=P(X-(t-r)<t-s)=\sum_{x=t-r}^{2t-s-r-1}\binom{x-1}{t-r-1}(1-p)^{x-(t-r)}p^{t-r}\text{。}$$

若记在设想的后续赌博中，乙胜（甲负）第 $t-s$ 局时恰赌了 Y 局，则 $Y \sim \mathrm{NB}(t-s,1-p)$，因此

$$P(A)=P(Y-(t-s)\geq t-r)=\sum_{y=2t-r-s}^{\infty}\binom{y-1}{t-s-1}p^{y-(t-s)}(1-p)^{t-s}\text{。}$$

8. Poisson 分布

若离散型 r.v. X 的分布列为

$$P(X=x)=\frac{\lambda^x}{x!}e^{-\lambda},\quad x=0,1,2,\cdots$$

其中参数 $\lambda>0$，则称 X 服从参数为 λ的 Poisson 分布，记作 $X\sim \mathrm{Poi}(\lambda)$。

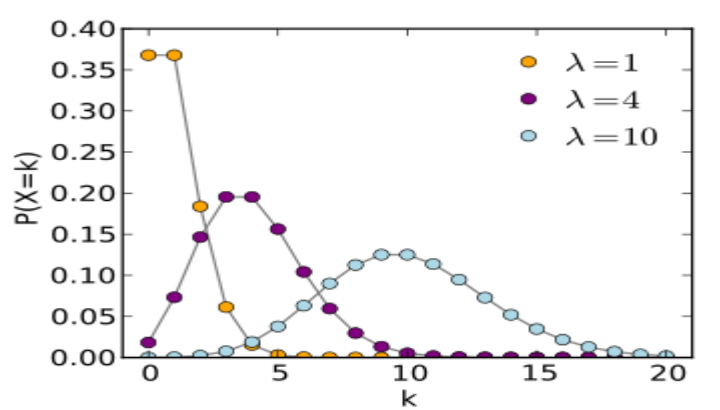

由 $\frac{\lambda^x}{x!}e^{-\lambda}>0,\ x=0,1,\cdots$ 及 $\sum_{x=0}^{\infty}\frac{\lambda^x}{x!}e^{-\lambda}=e^{\lambda}e^{-\lambda}=1$ 可知，该分布列满足非负性及规范性。

当 $\lambda=0$ 时，$\mathrm{Poi}(\lambda)$ 退化为单点分布 δ_0。

Poisson 分布的来历：二项分布概率的近似计算。

定理 2.2.2 (Poisson) 在独立重复 Bernoulli 试验中，单次试验中的成功概率 p_n 与试验次数 n 有关。若当 $n\to\infty$ 时 $np_n\to\lambda$，则对给定较小的 x 有

$$\binom{n}{x}p_n^x(1-p_n)^{n-x}\to\frac{\lambda^x}{x!}e^{-\lambda}。$$

证明：由

$$\begin{aligned}\binom{n}{x}p_n^x(1-p_n)^{n-x}&=\frac{1}{x!}\frac{n(n-1)\cdots(n-x+1)}{n^x}(np_n)^x(1-\frac{np_n}{n})^{n-x}\\&=\frac{1}{x!}1\cdot(1-\frac{1}{n})\cdots(1-\frac{x-1}{n})(np_n)^x(1-\frac{np_n}{n})^{n-x}\end{aligned}$$

知，对于给定的 x，有

$$\lim_{n\to\infty}1\cdot(1-\frac{1}{n})\cdots\cdot(1-\frac{x-1}{n})=1,\quad \lim_{n\to\infty}(np_n)^x=\lambda^x,\quad \lim_{n\to\infty}(1-\frac{np_n}{n})^{n-x}=e^{-\lambda},$$

因此证得结论。

由定理 2.2.1 知，若 $X \sim B(n,p)$，当 ***n* 较大**，***np* 较小**时，对于**较小的 *x***，有

$$P(X=x)=\binom{n}{x}p^x(1-p)^{n-x}\approx\frac{\lambda^x}{x!}e^{-\lambda},$$

其中 $\lambda=np$。

下表比较了四组 $B(n,p)$ 与 Poi(1) 在 0、1、2、3、4 处的概率值，从中可见用 Poisson 分布近似二项分布概率值的效果。

	B(10,0.1)	B(20,0.05)	B(40,0.025)	B(100,0.01)	Poi(1)
$P(X=0)$	0.3487	0.3585	0.3632	0.3660	0.3679
$P(X=1)$	0.3874	0.3774	0.3725	0.3697	0.3679
$P(X=2)$	0.1937	0.1887	0.1863	0.1849	0.1839
$P(X=3)$	0.0574	0.0596	0.0605	0.0610	0.0613
$P(X=4)$	0.0112	0.0133	0.0143	0.0149	0.0153
$P(X>4)$	0.0016	0.0026	0.0031	0.0034	0.0037

Poisson 分布的应用

- 用于对一定时间段内某类事件发生的次数建模。基本假定：记在充分小的时间段 h 内，这类事件发生的次数为 Y，则 1) $P(Y=1)$ 与 h 成比例；2) $P(Y\geq 2)=0$；3) 在不交叉的时间段内该类事件发生的次数相互独立。
- 用于对一定空间范围内某类事物出现的个数建模。
- 例
  - 1875－1894 年间普鲁士军队中每年被马踢死的士兵数；
  - 给定时间段内一个放射源发出的 α 粒子数；
  - 二次大战中，在固定时间长度内，伦敦被炮击中的城区数；
  - 一分钟内到达某银行的人数；
  - 一定时间内通过某个十字路口的汽车数；
  - 单位布匹上的疵斑数 ……

例 2.2.4 某非传染性疾病的发病率为 0.001。某公司有 5000 人。问该公司患该病的人数超过 5 人的概率。

解：

设该公司患该疾病的人数为 X。可认为 $X \sim B(5000,0.001)$。要求的是 $P(X>5)$。因 n 很大，$np=5000\cdot 0.001=5$ 较小，因此，对较小的 $x=0,1,\cdots,5$，$P(X=x)$ 可用 Poisson 分布近似计算。用 Excel 函数 Poisson.dist(x,λ,1) 算得

$$\begin{aligned}P(X>5)&=1-P(X\le 5)\approx 1-\sum_{k=0}^{5}\frac{5^k}{k!}e^{-5}\\&=1-\text{Poisson.dist}(5,5,1)=0.384039345.\end{aligned}$$

而直接用 Excel 中二项分布函数 Binom.dist(x,n,p,l) 算得

$$\begin{aligned}P(X>5)&=1-P(X\le 5)=1-\sum_{k=0}^{5}\binom{5000}{k}0.001^k 0.999^{5000-k}\\&=1-\text{Binom.dist}(5,5000,0.001,1)=0.384039331.\end{aligned}$$

例 2.2.5 例 1.3.8 所述 1910 年 Rutherford 实验中 7.5 秒时间内观测到了α粒子数的频率分布与参数 $\lambda = 3.87$ 的 Poisson 分布非常接近。

7.5 秒内测得的粒子数 k	0	1	2	3	4	5	6	7	8	9	≥10	合计
测得频数 N_k	57	203	383	525	532	408	273	139	45	27	16	2608
频率 f_k	0.0219	0.0778	0.1469	0.2013	0.2040	0.1564	0.1047	0.0533	0.0173	0.0104	0.0061	1.0000
Poi(3.87)	0.0209	0.0807	0.1562	0.2015	0.1949	0.1509	0.0973	0.0538	0.0260	0.0112	0.0065	1.0000

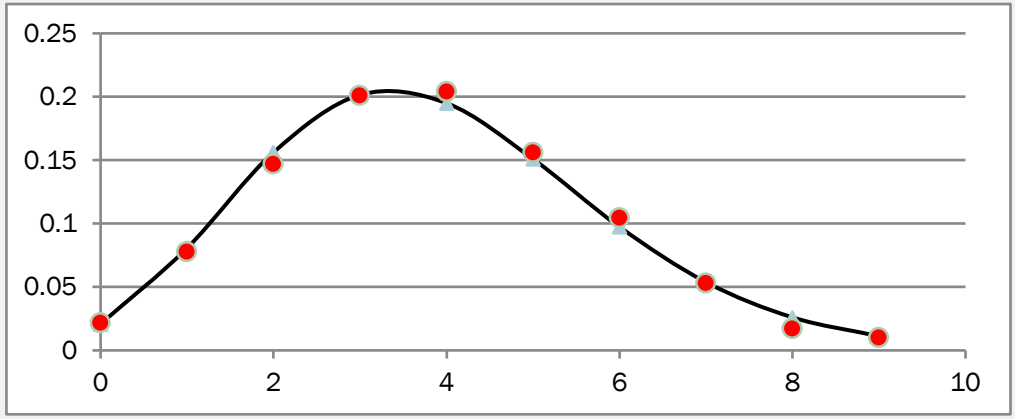

§2.3 连续型随机变量

一、连续型 r.v.与连续型分布

有些情况下随机变量可能的取值非常多，以至于可以假定它的取值充满某些实数区间。例如：人的寿命、产品的无故障工作时间、测量误差、股票的收益率等等。这类随机变量的概率分布，无法用分布列全面刻划。

用分组方法可以粗略描述这类 r.v. 的概率分布：将 r.v.的取值范围分割成若干个小区间，然后确定它落在各小区间中的概率。这些概率可用直方图(histogram)表示：直方条的面积表示概率大小；直方条的高度表示概率与区间长度之比，即概率密集于该区间内的程度大小。

可以想象：区间分割得越细，那么直方图对 r.v.的概率分布描述得越精细。若当各区间的宽度趋于 0 时，各直方条的高度都存在极限，记之为 $p(x)$，那么由对 $p(x)$ 的定积分就可算出随机变量落在任意一个实数区间内的概率，因而用此 $p(x)$ 就可全面描述 r.v.的概率分布。

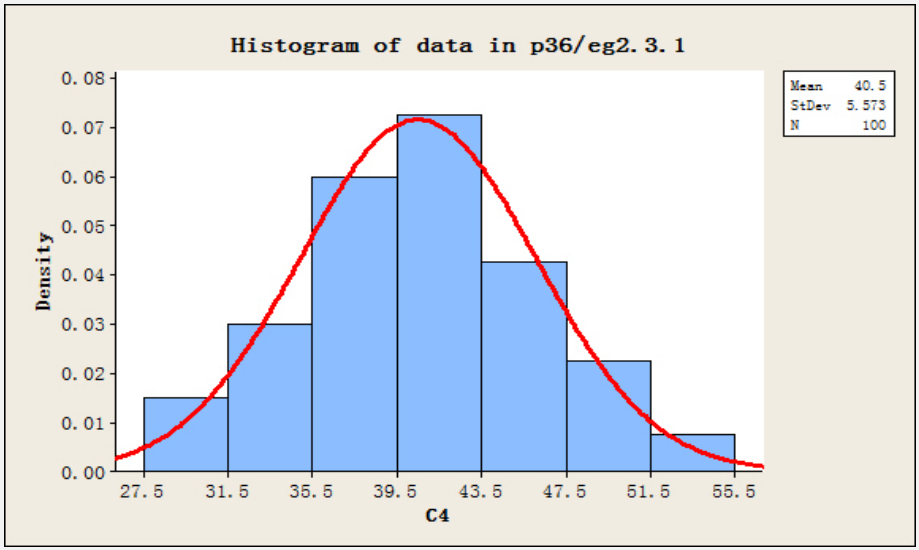

定义 2.3.1 (连续型 r.v.与连续型分布) 若存在$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的**非负可测**函数$p(x)$，使 r.v. X 的 d.f.

$$F(x)=\int_{-\infty}^{x}p(u)du,\ \forall x\in\mathbb{R},$$

则称 X 是连续型 r.v.，称其概率分布是连续型分布，称 $p(x)$ 为连续型 r.v. X (或连续型分布) 的概率密度函数 (*probability density function*, p.d.f.)，简称密度函数。

注：

✧ 定义 2.3.1 中的积分，严格来说应是 Lebesgue 积分$\int_{(-\infty,x]} p(u)d\lambda$，其中$\lambda$是$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的 Lebesgue 测度。我们暂时把它理解为 Riemann 积分。通常，非负函数若 Riemann 可积，必 Lebesgue 可积；反之，不然。

✧ 显然，连续型 r.v.的 d.f.是其 p.d.f.的原函数，因而其概率分布取决于其 p.d.f.。由定义 2.3.1 及积分的性质知，对于$\forall -\infty \le a \le b < \infty$，即有

$$P(X \in (a,b]) = F(b) - F(a) = \int_{-\infty}^{b} p(x)dx - \int_{-\infty}^{a} p(x)dx = \int_{a}^{b} p(x)dx \text{。}$$

进一步有

$$P(X \in A) = \int_{A} p(x)d\lambda,\ \forall A \in \mathcal{B}_{\mathbb{R}} \text{。}$$

✧ 任意可测函数在 Lebesgue 零测集上的积分为 0，i.e.，对于$\forall N \in \mathcal{B}_{\mathbb{R}}$，若$\lambda(N)=0$则有$\int_{N} p(x)d\lambda = 0$。由此可知：

(1) 连续型 r.v.落在任意 Lebesgue **零测集** N 上的概率为 0，即 $P(X\in N)=\int_N p(x)d\lambda=0$。特别地，$P(X=a)=\int_{\{a\}}p(x)dx=0,\ \forall a\in\mathbb{R}$。因而

$$P(a<X\le b)=P(a<X<b)=P(a\le X<b)=P(a\le X\le b)=\int_a^b p(x)dx。$$

这说明零概率事件不一定是不可能事件，概率为 1 的事件也不一定是必然事件。

(2) 连续型 r.v.或连续型分布的 d.f. **处处连续**（反之不真），因为

$$F(x)-F(x-)=P(X=x)=0,\ \forall x\in\mathbb{R}。$$

(3) 连续型 r.v. 的 p.d.f.不唯一。设非负可测函数 $\tilde{p}(x)$ 与 p.d.f. $p(x)$ 在 Lebesgue 测度意义下**几乎处处**相同，即 $N=\{x\in\mathbb{R}:\tilde{p}(x)\ne p(x)\}$ 而 $\lambda(N)=0$，则

$$\begin{aligned}F(x)&=\int_{(-\infty,x]}p(x)d\lambda=\int_{(-\infty,x]\cap N^c}p(x)d\lambda+\int_{(-\infty,x]\cap N}p(x)d\lambda\\&=\int_{(-\infty,x]\cap N^c}\tilde{p}(x)d\lambda+\int_{(-\infty,x]\cap N}\tilde{p}(x)d\lambda=\int_{(-\infty,x]}\tilde{p}(x)d\lambda,\ \forall x\in(-\infty,\infty).\end{aligned}$$

这说明 $\tilde{p}(x)$ 也是 $F(x)$ 的 p.d.f.，它与 $p(x)$ 描述的连续型分布相同。

✧ 下面是 Chung (2010) 书中引用的 Natanson (1955) 书中的一个命题。

定理 2.3.1 设 $F(x)$ 是一个 d.f.，记 $S=\{x\in\mathbb{R}: F'(x)$ 存在且 $0\le F'(x)<\infty\}$，则：

(1) $\lambda(S^c)=0$；

(2) 若 $F(x)$ 是连续型分布的 d.f.，则

$$F(x)=\int_{(-\infty,x]\cap S}F'(u)d\lambda,\ \forall x\in\mathbb{R},$$

即任一与导函数 $F'(x)$ 在 Lebesgue 测度意义下几乎处处相同的非负可测函数，比如 $F'(x)I_S(x)$，都是 $F(x)$ 的 p.d.f.。

定理 2.3.1 说明：任一 d.f.都几乎处处可导；但**只有**连续型分布的 d.f.，才是其导函数的原函数。据此定理，对于连续型分布，可对其 d.f.求导获得 p.d.f.；也可通过验证 d.f. 是否是其导函数的原函数来判断，该 d.f.是否是连续型的。

✧ 连续型分布也常泛指$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上 d.f.满足定义 2.3.1 的概率测度（未必由某 r.v.导出），在测度论中指的是关于 Lebesgue 测度λ绝对连续的概率测度，即：对于$\forall A\in\mathcal{B}_{\mathbb{R}}$，若$\lambda(A)=0$，必有$P(A)=0$。由测度论中的 Radon-Nikodym 定理知，定义 2.3.1 与之等价。

定理 2.3.2 (连续型 p.d.f.的基本性质) $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的可测函数$p(x)$是连续型 p.d.f.的充要条件：

a)（非负性）$p(x)\geq 0,\ \forall x\in\mathbb{R}$；b)（规范性）$\int_{-\infty}^{\infty}p(x)dx=1$。

如同 p.m.f 之于离散型分布，p.d.f.是研究连续型分布的重要且实用的工具，常用于对连续型 r.v.建模、将有关的概率转化为积分来计算。因 p.d.f.不唯一，实际应用中常取尽量光滑的、Riemann 可积的函数作为 p.d.f.。

注意，p.d.f.是定义在$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的非负可测函数，常用小写字母表示，如 $p(x),g(x),h(x)$ 等等，写成$p(X=x)$是错误的。

若连续型 p.d.f. $p(x)$ 在 x 处连续，则

$$\lim_{\varepsilon\to 0+}\frac{P(x-\varepsilon<X\le x+\varepsilon)}{2\varepsilon}=\lim_{\varepsilon\to 0+}\frac{1}{2\varepsilon}\int_{x-\varepsilon}^{x+\varepsilon}p(u)du=p(x).$$

故当 $\varepsilon>0$ 足够小时有

$$P(x-\varepsilon\le X\le x+\varepsilon)=\int_{x-\varepsilon}^{x+\varepsilon}p(u)du\approx p(x)\cdot 2\varepsilon,$$

或者用微分符号表示为

$$P(x\le X\le x+dx)\approx p(x)dx。$$

直观而言，p.d.f. $p(x)$ 就是 r.v.落在 x 的邻域内的概率与邻域长度之比的极限，是概率密集在 x 附近的程度。连续型分布是以长度为参照确定概率的，是几何概率的推广。

例 2.3.1 在区间 $(0,1)$ 上随机地投针，针尖扎中点的坐标记为 X。假定针尖扎中 $(0,1)$ 上任何一点“机会均等”。

此例假定 r.v. X 的取值充满区间 $(0,1)$ 符合直观；若将“机会均等”理解为“X 落在 $(0,1)$ 内任意一点附近的概率密集程度相同”，则 X 的概率分布可用如下 p.d.f.描述：

$$p(x)=I_{(0,1)}(x)=\begin{cases}1, & \text{if } x\in(0,1),\\ 0, & \text{else.}\end{cases}$$

容易验证，$p(x)$ 满足非负性、规范性，是一个 p.d.f.。其 d.f.为

$$F(x)=\int_{-\infty}^{x}p(t)dt=\begin{cases}0, & x\le 0,\\ x, & 0<x\le 1,\\ 1, & x>1.\end{cases}$$

也易算得 X 落在任意一个实数区间 (a,b) 内的概率为

$$P(a<X<b)=\int_a^b p(x)dx=\min\{b,1\}\vee 0-\max\{a,0\}\wedge 1\text{。}$$

此例中 X 的分布常称为区间 $(0,1)$ 上的均匀分布，记作 $X\sim U(0,1)$。令 $\tilde{p}(x)=I_{(0,1)\cap\mathbb{Q}^c}(x)$，显然 $\{x\in\mathbb{R}:p(x)\neq\tilde{p}(x)\}=(0,1)\cap\mathbb{Q}$，$\lambda((0,1)\cap\mathbb{Q})=0$，故 $\tilde{p}(x)$ 也是 $U(0,1)$ 的 p.d.f.，它 Lebesgue 可积但非 Riemann 可积。

例 2.3.2 (茆诗松等,2019, p64/例 2.1.8) 某种型号电子元件的寿命 X（小时）具有 pdf

$$p(x)=\frac{1000}{x^2}I_{(1000,\infty)}(x),$$

现有一大批此种元件，各元件工作相互独立。

(1) 任取一只，寿命大于 1500 小时的概率是多少？寿命小于 1500 小时的概率呢？

$$P(X>1500)=\int_{1500}^{\infty}p(x)dx=-\frac{1000}{x}\bigg|_{1500}^{\infty}=\frac{2}{3}.$$

(2) 任取四只，寿命都大于 1500 小时的概率是多少？

记四只元件的寿命分别为 $X_1,\cdots,X_4$。它们具有相同的 pdf $p(x)$，且工作相互独立，故

$$P(X_1>1500,\cdots,X_4>1500)=\prod_{i=1}^{4}P(X_i>1500)=(\frac{2}{3})^4=\frac{16}{81}.$$

(3) 任取四只，至少有一只寿命大于 1500 小时的概率是多少？

(4) 已知某只元件用了 1500 小时没坏，那它的寿命大于 2000 小时的概率是多少？

二、常用连续型分布

1. 均匀分布 (Uniform Distribution)：描述的是几何概率。

若 r.v. X 具有 p.d.f.

$$p(x)=\frac{1}{b-a}I_{[a,b]}(x)=\begin{cases}\dfrac{1}{b-a}, & \text{if } x\in[a,b],\\ 0, & \text{else.}\end{cases}$$

则称 $X \sim \mathrm{U}[a,b]$。其 d.f.为

$$F(x)=\int_{-\infty}^{x}p(t)dt=\begin{cases}\int_{-\infty}^{x}0dt=0, & x\le a,\\ \int_{-\infty}^{a}0dt+\int_{a}^{x}\dfrac{1}{b-a}dt=\dfrac{x-a}{b-a}, & a<x\le b,\\ \int_{-\infty}^{a}0dt+\int_{a}^{b}\dfrac{1}{b-a}dt+\int_{b}^{x}0dt=1, & x>b.\end{cases}$$

注意：不能把该分布的 p.d.f.写成 $p(x)=\dfrac{1}{b-a}$！另外，$U(a,b),U(a,b],U[a,b)$ 本质上都相同。

2. 正态分布 (Normal Distribution / Gauss Distribution)

✧ 由 Gauss 在研究测量误差的规律时提出，在概率论与数理统计中有着相当重要的作用，早期数理统计的许多理论与方法是建立在正态分布基础上的。。

✧ 若一个随机变量是众多微小的随机因素综合作用的结果、且所有因素都不起支配作用，这样的随机变量往往服从正态分布。

✧ 自然现象、社会现象中，很多变量可以近似地用正态分布描述。例如：人的身高、IQ 得分、气体分子的运动速度、海洋声纳信号、金融产品收益率的对数，等等

称 p.d.f.为

$$p(x;\mu,\sigma^2)=\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\},\quad x\in\mathbb{R}$$

的连续型分布为正态分布，其中参数 $\mu\in\mathbb{R},\ \sigma>0$。记作 $N(\mu,\sigma^2)$。

验证：这确实是一个 pdf。其 d.f.为

$$F(x;\mu,\sigma^2)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(t-\mu)^2}{2\sigma^2}\}dt,\quad x\in\mathbb{R}。$$

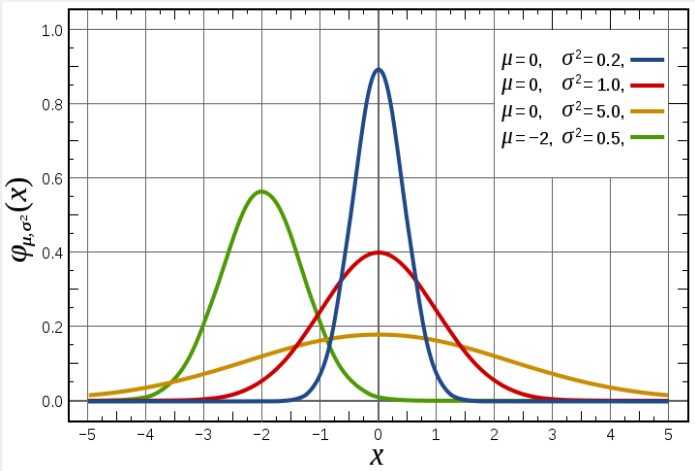

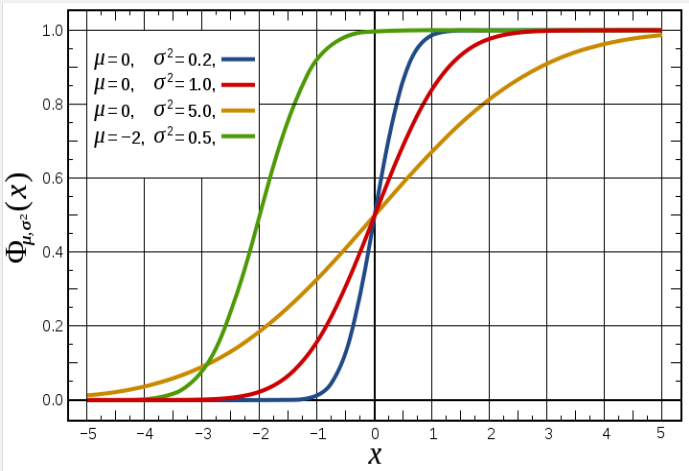

正态分布密度函数的特点

✧ p.d.f. 关于 $x=\mu$ 对称；函数值在 $x=\mu$ 处最大，有界；

✧ $x\to\pm\infty$ 时， $p(x)\to 0$；

✧ $x=\mu\pm\sigma$ 是 p.d.f. 的两个拐点；

✧ 固定 σ，改变 μ 的值，p.d.f. 曲线形状不变，位置随 μ 平移；固定 μ 改变 σ，则 p.d.f.中心位置不变，形状随 σ 变瘦高或矮胖。

标准正态分布 参数 $\mu=0,\sigma^2=1$ 的正态分布称为标准正态分布，即 $N(0,1)$。

✧ p.d.f. 为 $\phi(x)=\dfrac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$， 是一个偶函数，即 $\phi(-x)=\phi(x),\ \forall x\in\mathbb{R}$。

✧ d.f. 为 $\Phi(x)=\int_{-\infty}^{x}\phi(t)dt$； $\Phi(-x)=1-\Phi(x),\forall x\in\mathbb{R}$。

✧ 与 $N(\mu,\sigma^2)$ 的密度函数、分布函数的关系：

$$p(x;\mu,\sigma^2)=\frac{1}{\sigma}\phi(\frac{x-\mu}{\sigma}),\quad F(x;\mu,\sigma^2)=\Phi(\frac{x-\mu}{\sigma})。$$

故若 $X\sim N(\mu,\sigma^2)$，则有

$$P(X\le c)=F(c;\mu,\sigma^2)=\Phi(\frac{c-\mu}{\sigma}),$$

$$P(a<X\le b)=F(b;\mu,\sigma^2)-F(a;\mu,\sigma^2)=\Phi(\frac{b-\mu}{\sigma})-\Phi(\frac{a-\mu}{\sigma}),$$

$$P(|X-\mu|\le c\sigma)=F(\mu+c\sigma;\mu,\sigma^2)-F(\mu-c\sigma;\mu,\sigma^2)=\Phi(c)-\Phi(-c)=2\Phi(c)-1.$$

✧ 记 $N(0,1)$ 的 p 分位点为 u_p，即 $p=\Phi(u_p)$，记 $N(\mu,\sigma^2)$ 的 p 分位点为 a_p。则由

$$F(a_p;\mu,\sigma^2)=\Phi\left(\frac{a_p-\mu}{\sigma}\right)=p$$

得 $\dfrac{a_p-\mu}{\sigma}=u_p$，即 $a_p=\mu+\sigma u_p$。

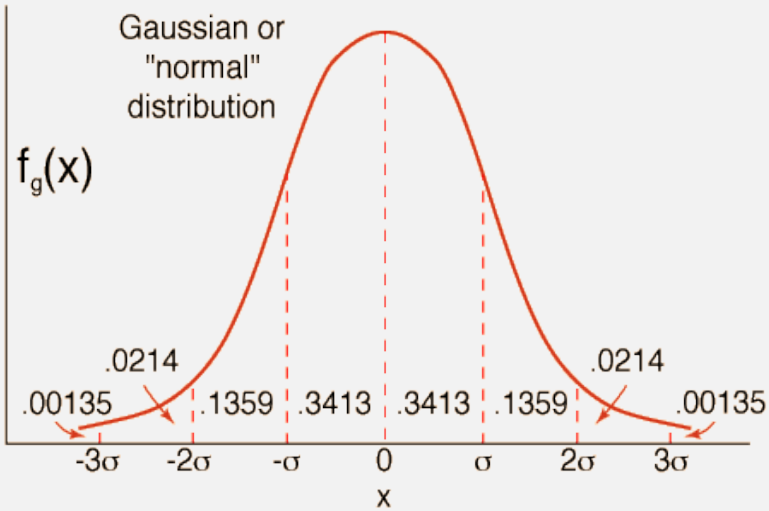

$$P(|X-\mu|\le k\sigma)=\begin{cases}0.6826, & k=1,\\ 0.9544, & k=2,\\ 0.9973, & k=3,\\ 0.95, & k=1.96,\\ 0.99, & k=2.58,\\ \cdots & \cdots\end{cases}$$

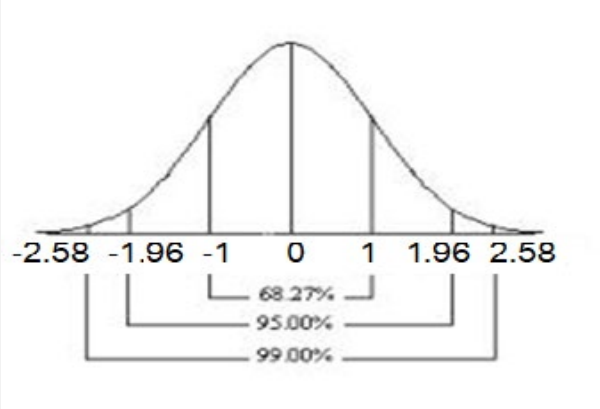

常用的 $N(0,1)$ 分位点

p	0.50	0.90	0.95	0.975	0.99	0.995
u_p	0	1.282	1.645	1.960	2.326	2.576

3．指数分布 (Exponential distribution)

称 p.d.f. 为

$$p(x;\lambda)=\begin{cases}\lambda e^{-\lambda x}, & \text{if } x>0,\\ 0, & \text{else.}\end{cases}$$

的连续型分布为指数分布，其中参数 $\lambda>0$。记作 $\mathrm{Exp}(\lambda)$。其 d.f.为

$$F(x;\lambda)=\int_{-\infty}^{x}p(t;\lambda)dt=\begin{cases}0, & x\le 0,\\ 1-e^{-\lambda x}, & x>0.\end{cases}$$

指数分布常用来对“寿命”建模。它有类似于几何分布的无记忆性特点。设 $X\sim\mathrm{Exp}(\lambda)$，对于 $\forall s>0,\ \forall t\ge 0$，有

$$P(X>s+t\mid X>t)=P(X>s)。$$

而且，指数分布是唯一具有此无记忆性的非负连续型分布。

与 Poisson 过程的关系

若某设备在时间$[s,s+t]$内发生故障的次数$N(t)\sim \mathrm{Poi}(\lambda t)$，与起始时点 s 无关，且不同时间段内发生故障的次数之间相互独立，则：

1) 相继两次故障之间的时间间隔 $T_1\sim \mathrm{Exp}(\lambda)$；

2) 更一般地，以任一故障发生时点为起始点至之后第 r 次故障发生所历经的时间间隔 T_r 服从 Erlang 分布，Erlang 分布是 Gamma 分布的一类特例，即 $T_r\sim \mathrm{Ga}(r,\lambda)$。

两参数指数分布。称 p.d.f. 为

$$p(x;\mu,\lambda)=\begin{cases}\lambda e^{-\lambda(x-\mu)}, & \text{if } x>\mu,\\ 0, & \text{else.}\end{cases}$$

的连续型分布为两参数指数分布，其中参数 $\mu\in\mathbb{R},\lambda>0$。记作$\mathrm{Exp}(\mu,\lambda)$。

4. Gamma 分布 称 p.d.f. 为

$$p(x;\alpha,\lambda)=\frac{1}{\Gamma(\alpha)}\lambda^{\alpha}x^{\alpha-1}e^{-\lambda x}I_{(0,\infty)}(x)$$

的连续型分布为 Gamma 分布，其中形状(shape)参数 $\alpha>0$，尺度(scale)参数 $\lambda>0$。记为 $\mathrm{Ga}(\alpha,\lambda)$。

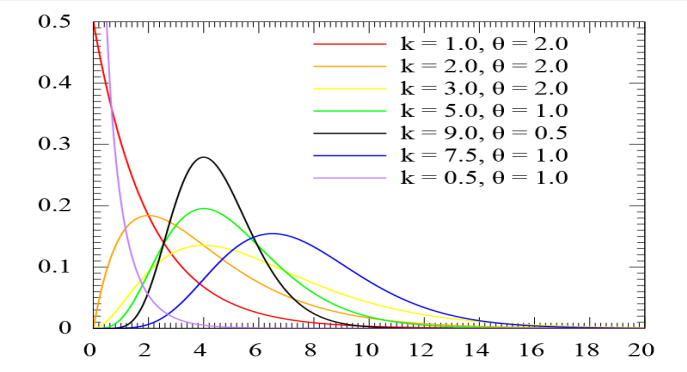

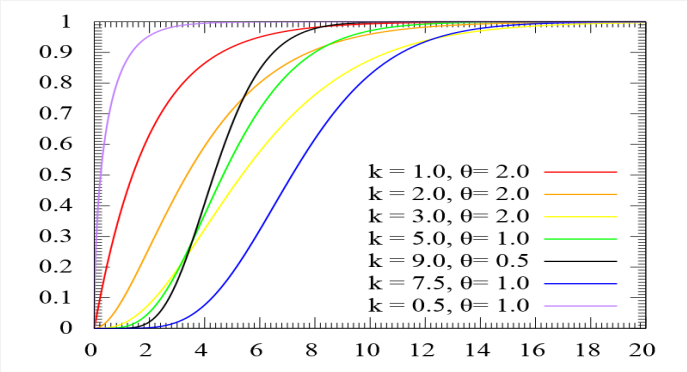

（左图为 pdf，右图为 cdf，图中参数 k 即 α，参数 $\theta=\lambda^{-1}$。）

$\mathrm{Ga}(1,\lambda)$ 即 $\mathrm{Exp}(\lambda)$；α 为正整数时即 Erlang 分布；$\mathrm{Ga}(\frac{\alpha}{2},\frac{1}{2})$ 即 $\chi^2(\alpha)$ 分布。

5. Beta 分布 称 p.d.f. 为

$$p(x;\alpha,\beta)=\frac{1}{\mathrm{B}(\alpha,\beta)}x^{\alpha-1}(1-x)^{\beta-1}I_{(0,1)}(x)$$

的连续型分布为 Beta 分布，其中参数 $\alpha>0,\beta>0$，记作 $\mathrm{Beta}(\alpha,\beta)$。常用于对比例建模。

特例，Beta(1,1) 即 U(0,1)。

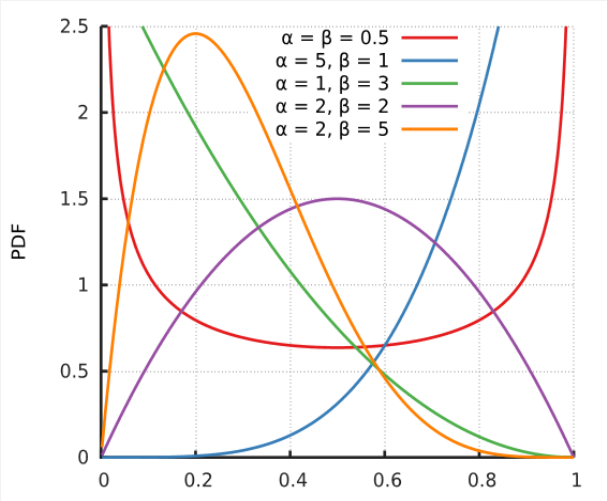

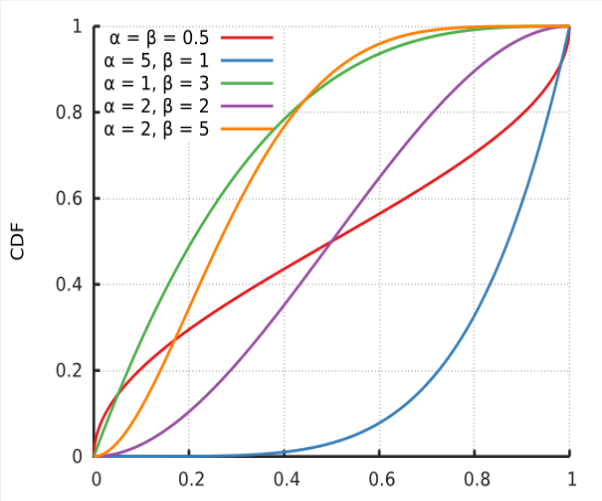

三、概率分布的类型

由测度论中的 Lebesgue 分解定理知，$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上的概率分布有三种基本类型：

1) 离散型（d.f. 是阶梯函数）；

2) 连续型（关于 Lebesgue 测度绝对连续，d.f.连续，且是自身导数的原函数）；

3) 奇异型（存在无穷不可列集$S\in B_{\mathbb{R}}$，$\lambda(S)=0$但$P(S)=1$；其 d.f.连续，导数几乎处处为 0，但 d.f.不是自身导数的原函数）。

$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上任意概率分布 P，都可以分解为这三种基本类型的凸组合，其 d.f. $F(x)$可表示为这三类分布函数的凸组合，即

$$F(x)=c_1F_d(x)+c_2F_c(x)+c_3F_s(x),$$

其中$c_i\geq 0,i=1,2,3$且$c_1+c_2+c_3=1$；$F_d(x),F_c(x),F_s(x)$分别是离散型、连续型、奇异型 d.f.。实际应用中几乎用不到奇异型分布，经常单独使用离散型、连续型分布或者两者的混合（即凸组合）对随机变量建模。

***例 2.3.3** (Cantor 分布) C 是区间[0,1]上的三分 Cantor 集，先在 $[0,1]\setminus C$ 上定义函数 $g(x)$：

$$g(x)=2^{-1},\quad x\in(\frac{1}{3},\frac{2}{3})\quad（C\text{ 的第 1 级余区间}）;$$

$$g(x)=\begin{cases}2^{-2}, & x\in(\frac{1}{3^2},\frac{2}{3^2}),\\ 3\cdot 2^{-2}, & x\in(\frac{7}{3^2},\frac{8}{3^2}),\end{cases}\quad（C\text{ 的第 2 级余区间}）;$$

$$g(x)=\frac{1}{2^n},\frac{3}{2^n},\cdots\frac{2^n-1}{2^n},\ x\in(\frac{1}{3^n},\frac{2}{3^n}),(\frac{7}{3^n},\frac{8}{3^n}),\cdots,(\frac{3^n-2}{3^n},\frac{3^n-1}{3^n})\quad（C\text{ 的第 }n\text{ 级余区间}）;\ \cdots$$

所得 $g(x)$ 在 $[0,1]\setminus C$ 上单调不减，值取遍(0,1)内所有二进制有理数，它们形成一个稠密集。

将 $g(x)$ 延拓到[0,1]上：令 $g(0)=0,\ g(x)=\sup\{g(y):y<x,y\in[0,1]\setminus C\},x\in(0,1]$。延拓所得 $g(x)$ 称为 Cantor 函数，在[0,1]上单调不减、连续。Cantor 分布的 d.f.为

$$F(x)=\begin{cases}0, & x<0,\\ g(x), & 0\le x<1,\\ 1, & x\ge 1.\end{cases}$$

它在$(-\infty,\infty)$上处处连续，在$(-\infty,\infty)\setminus C$上导数恒为 0，而$\lambda(C)=0$。所以，它是奇异型分布。

a.e. 与 a.s.

设$(\Omega,\mathcal{F},\mu)$是一个测度空间。设$A\subset\Omega$，若$\exists N\in\mathcal{F},\ni A\subset N$，且$\mu(N)=0$，则称$A$为$\mu$可略集；若$A\in\mathcal{F}$且$\mu(A)=0$，则称$A$为$\mu$零测集。

设$D(\omega)$表示有关样本点ω的一个命题，记

$$A=\{\omega\in\Omega: D(\omega)\text{不真}\}。$$

若A为μ可略集，则称“$D(\omega)$在测度μ意义下几乎处处为真”，记为“$D(\omega)$真 a.e. μ”(almost everywhere, a.e.)。特别地，若P是$(\Omega,\mathcal{F})$上的概率测度，常改“几乎处处”为“几乎必然”，改记“$D(\omega)$真 a.e. P”为“$D(\omega)$真 a.s. P”(almost surely, a.s.)。

概率分布的支撑 (support)

设 P 是 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的概率分布 (测度)，称集合

$$S=\{x\in(-\infty,\infty):P((x-\varepsilon,x+\varepsilon))>0,\forall\varepsilon>0\}$$

为 P 的支撑。

显然，$P(S)=1$，反之不然。为方便使用，若 $B\subset S$ 且 $P(B)=1$，也称 B 为 P 的(广义的)支撑。B 只比 S 少一个 P 零测集。

分布列为 $\{(x_i,p_i):i=1,2,\cdots\}$ 的离散型分布，$S=\{x_i:p_i>0,i=1,2,\cdots\}$ 为其支撑。d.f.为 $F(x)$ 的连续型分布，$S=\{x:\max(F'_-(x),F'_+(x))>0\}$ 为其支撑；任一满足 $P(B)=1$、$B\subset S$ 的 $\mathcal{B}_{\mathbb{R}}$ 可测集 B 都是该分布广义的支撑，比如 $\{x:F'(x)>0\}$、$\{x\in S:\text{p.d.f. }p(x)>0\}$。

§ 2.4 随机变量函数的分布

在概率统计的理论与应用中，常需要研究随机变量函数的分布。比如，在研究 r.v.的方差、各阶矩及矩母函数等数值特征时，会涉及 r.v.的多项式及指数函数变换，在研究各类概率分布之间的关系时，会涉及 r.v.的线性、多项式、倒数、对数、三角函数等函数变换。数理统计中广泛用于统计推断的统计量，就是单个或者多个 r.v.的函数。研究 r.v.函数的概率分布，是概率论与数理统计中的一块重要的内容。

例 2.4.1 设某生产线的次品率为 p。从其生产的大量产品中随机抽取 n 个，那么其中的次品数 $X \sim B(n,p)$。

- 通常也可能考虑：n 件产品中的合格品数 $Y = n - X$、不合格品率 $Z = \dfrac{X}{n}$ 的分布；
- 计算 X 的方差时，会涉及 $X^2, (X-p)^2$ 的分布；等等。

这里 $Y, Z, X^2, (X-p)^2$ 都是 r.v. X 的函数。它们也都是 r.v.，且分布取决于 X 的分布。

一般地，设 $y=g(x)$ 是一个已知的、$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的可测函数，X 是定义在 $(\Omega,\mathcal{F})$ 上的 r.v.。那么 $Y=g(X)$ 既是 X 的值域空间 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的 r.v.，又由定理 2.1.3 (Doob)知，它也是 $(\Omega,\mathcal{F})$ 上的 r.v.。设 P 是 $(\Omega,\mathcal{F})$ 上的概率测度，r.v. X 的概率分布为

$$P_X(A)=P(X\in A),\forall A\in\mathcal{B}_{\mathbb{R}}。$$

若将 Y 视为定义在 X 的值域空间 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的 r.v.，其概率分布由 X 的概率分布导出，则

$$P_Y(B)=P_X(g^{-1}(B)),\forall B\in\mathcal{B}_{\mathbb{R}};$$

若将 Y 视为复合映射 $g\circ X$，是定义在 $(\Omega,\mathcal{F})$ 上的 r.v.，则其概率分布为

$$P_Y(B)=P(Y\in B)=P((g\circ X)^{-1}(B))=P(X^{-1}[g^{-1}(B)]),\forall B\in\mathcal{B}_{\mathbb{R}}。$$

显然

$$P_X(g^{-1}(B))=P(X^{-1}[g^{-1}(B)]),\forall B\in\mathcal{B}_{\mathbb{R}},$$

两者完全相同。这说明 Y 的概率分布取决于 X 的概率分布、可由 X 的概率分布求得。

本节讨论如何根据 X 的分布来计算 Y 的分布。因概率分布由其 d.f.唯一确定，故一般情况下只要求得 Y 的 d.f. $F_Y(y)$ 即可。当 Y 离散型分布时，常要求其分布列（或 p.m.f.），为连续型分布时，常要求其 p.d.f.。

一、离散型随机变量函数的分布

设离散型 r.v. X 的分布列为 $\{(x_k, p_k): k=1,2,\cdots\}$，记其支撑为 $S_X=\{x_k: p_k>0, k=1,2,\cdots\}$，设 $Y=g(X)$。令 $S_Y=g(S_X)=\{g(x_k): k=0,1,\cdots\}$，这是一个可列集。显然 $S_X \subset g^{-1}(S_Y)$，故

$$P_Y(S_Y)=P(X\in g^{-1}(S_Y))\geq P(X\in S_X)=1,$$

因此 Y 的分布是离散型的，S_Y 是其支撑。这说明，离散型 r.v.的函数必是离散型 r.v.。

求 Y 分布列的一般步骤为：

1) 求出 Y 所有可能的取值，即其分布的支撑 $S_Y=g(S_X)=\{g(x_k): p_k>0, k=0,1,\cdots\}$；

2) 把相同 $g(x_k)$ 对应的概率 p_k 相加，得到 Y 的分布列，即

$$P(Y=y)=P(X\in g^{-1}\{y\})=\sum_{k=1}^{\infty}P(X=x_k)I_{g^{-1}\{y\}}(x_k)=\sum_{k=1}^{\infty}p_kI(g(x_k)=y),\ \forall y\in S_Y\text{。}$$

例 2.4.1(续) n 件产品中的合格品数 Y 可能的取值为 $0,1,\cdots,n$，其分布列为

$$P(Y=y)=P(X=n-y)=\binom{n}{n-y}p^{n-y}(1-p)^y\overset{令q=1-p}{=}\binom{n}{y}q^y(1-q)^{n-y},\quad y=0,1,\cdots,n,$$

故 $Y\sim B(n,q)$。而不合格品率 $Z=\dfrac{X}{n}$ 可能的取值为 $0,\dfrac{1}{n},\dfrac{2}{n}\cdots,1$，其分布列为

$$P(Z=\frac{x}{n})=P(X=x)=\binom{n}{x}p^x(1-p)^{n-x},\quad x=0,1,\cdots,n\text{。}$$

$W=X^2$ 的分布列为 $P(W=x^2)=P(X=x)=\binom{n}{x}p^x(1-p)^{n-x},\quad x=0,1,\cdots,n$。

例 2.4.2 $X\sim\{-2,-1,0,1,2,3\}$ 上的离散均匀分布，求 $Y=|X|$ 的分布列。

先求 Y 分布的支撑：$S_Y=\{|x|:x=-2,-1,0,1,2,3\}=\{0,1,2,3\}$；再求 Y 的分布列：

$$P(Y=0)=P(X=0)=\frac{1}{6}, P(Y=1)=P(X\in\{-1,1\})=\frac{1}{3}, P(Y=2)=\frac{1}{3}, P(Y=3)=\frac{1}{6}。$$

二、连续型随机变量函数的分布

当 X 为连续型 r.v.时，$Y=g(X)$ 的概率分布情况就有多种多样，例如：

- 当 $g(x)$ 是光滑的、严格单调或分段严格单调时，Y 可能服从连续型分布；
- 当 $g(x)$ 是分段阶梯函数时，Y 可能服从离散型分布；
- Y 的分布可能是连续型与离散型的混合。

此时，Y 的分布有时可精确地显式表达，但更多情况下只能数值近似、通过随机模拟近似、或通过少量数字特征粗略刻画。

若 X 是离散与连续混合型的 r.v.，情况更复杂。

设 $p_X(x)$ 为连续型 r.v. X 的 p.d.f. ，下面分几种情况讨论 $Y=g(X)$ 分布的求法。

1．若 Y 的分布非离散型，求 Y 分布的基本方法：求出 Y 的分布函数。

Y 的分布函数为

$$F_Y(y)=P(Y\le y)=P(g(X)\le y)=P(X\in g^{-1}(-\infty,y])=\int_{g^{-1}(-\infty,y]}p_X(x)dx\text{。}$$

再对 $F_Y(y)$ 求导数（不可导点取为 0）。若其导数 $p_Y(y)$ 是一个 p.d.f.，则 Y 是连续型的，$p_Y(y)$ 就是其 p.d.f.。

若 $\exists S_X\in\mathcal{B}_{\mathbb{R}},\ni P(X\in S_X)=1$，比如 S_X 为 X 分布的支撑（或广义支撑），那么

$$F_Y(y)=P(X\in g^{-1}(-\infty,y])=P(X\in(g^{-1}(-\infty,y])\cap S_X)=\int_{g^{-1}(-\infty,y]\cap S_X}p_X(x)dx\text{。}$$

此时，函数 $y=g(x)$ 只要在 S_X 上有定义就可以，它在 S_X^c 上的取值不影响 $Y=g(X)$ 的概率分布。

例 2.4.3 设 $X \sim N(\mu,\sigma^2)$，$Y = e^X$，求 Y 的概率分布。

解： 求 Y 的分布函数 $F_Y(y)$。先对函数 $y = e^x$ 分析区间 $(-\infty, y]$ 的原像：

$$g^{-1}(-\infty, y] = \{x : e^x \le y\} = \begin{cases} \varnothing, & \text{if } y \le 0, \\ (-\infty, \log y], & \text{if } y > 0. \end{cases}$$

因此，

$$F_Y(y) = P(Y \le y) = P(X \in g^{-1}(-\infty, y]) = \begin{cases} 0, & \text{if } y \le 0, \\ \int_{-\infty}^{\log y} \frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right)dx & \text{if } y > 0. \end{cases}$$

对 $F_Y(y)$ 求导，得

$$p_Y(y) = \begin{cases} \frac{1}{\sigma y}\phi\left(\frac{\log y - \mu}{\sigma}\right), & \text{if } y > 0, \\ 0, & \text{else.} \end{cases}$$

易见 $p_Y(y)$ 是一个 p.d.f.，故 Y 是连续型 r.v.。常称 Y 的分布为对数正态分布，记为 $LN(\mu,\sigma^2)$。

同理可得：若 $X \sim N(\mu,\sigma^2)$，$Y = aX + b\ (a \neq 0)$，则 $Y \sim N(a\mu + b, a^2\sigma^2)$。特别地，

(1) 若 $X \sim N(\mu,\sigma^2)$，则 $Y = \dfrac{X-\mu}{\sigma} \sim N(0,1)$；

(2) 若 $X \sim N(0,1)$，则当 $\sigma \neq 0$ 时，$Y = \mu + \sigma X \sim N(\mu,\sigma^2)$。

但若 $a = 0$，那么 $Y = aX + b \equiv b$，则 $Y \sim \delta_b$。

对 $F_Y(y)$ 求导时常用到下列含参积分的求导公式：

$$\frac{d}{dy}\int_{a(y)}^{b(y)} f(x)dx = f[b(y)]b'(y) - f[a(y)]a'(y)。$$

例 2.4.4 设 $X \sim N(0,1)$，$Y = X^2$，求 Y 的概率分布。

解：求 Y 的分布函数 $F_Y(y)$。先对函数 $y = x^2$ 分析区间 $(-\infty, y]$ 的原像：

$$g^{-1}(-\infty, y] = \{x : x^2 \le y\} = \begin{cases} \varnothing, & \text{if } y < 0, \\ [-\sqrt{y}, \sqrt{y}], & \text{if } y \ge 0. \end{cases}$$

因此，

$$F_Y(y) = P(Y \le y) = P(X \in g^{-1}(-\infty, y]) = \begin{cases} 0, & \text{if } y < 0, \\ \int_{-\sqrt{y}}^{\sqrt{y}} \phi(x)dx, & \text{if } y \ge 0. \end{cases}$$

对 $F_Y(y)$ 求导得

$$p_Y(y) = y^{-1/2}\phi(\sqrt{y})I_{[0,\infty)}(y) = \frac{1}{\Gamma(1/2)}\left(\frac{1}{2}\right)^{1/2} y^{-1/2}e^{-y/2}I_{[0,\infty)}(y)\text{。}$$

其中 $\Gamma(\frac{1}{2}) = \sqrt{\pi}$。易见 $p_Y(y)$ 是 $\mathrm{Ga}(\frac{1}{2}, \frac{1}{2})$（也即 $\chi^2(1)$）分布的 p.d.f.，即 $Y \sim \chi^2(1)$。

2．一一对应的光滑变换

定理 2.4.1 设函数 $y=g(x),\ x\in(a,b)$ 一一对应、可导，反函数为 $x=g^{-1}(y),\ y\in(c,d)$；其中 a,c 可取 $-\infty$，b,d 可取 ∞。连续型 r.v. X 的 p.d.f.为 $p_X(x)$，且 $P(X\in(a,b))=1$。那么 $Y=g(X)$ 也是连续型 r.v.，其 p.d.f.为

$$p_Y(y)=\begin{cases} p_X(g^{-1}(y))\left|\dfrac{dx}{dy}\right|, & \text{if } y\in(c,d), \\ 0, & \text{else.} \end{cases}$$

（**注：**一一对应且连续的一元函数必定是严格单调函数。）

证明：

不妨设函数 $y=g(x),x\in(a,b)$ 严增。为求 Y 的 d.f. $F_Y(y)$，先分析区间 $(-\infty,y]$ 的原像：

$$g^{-1}(-\infty,y]\bigcap(a,b)=\begin{cases} \varnothing, & y\le c, \\ (a,g^{-1}(y)], & c<y<d, \\ (a,b), & y\ge d. \end{cases}$$

因此，

$$F_Y(y)=P(Y\le y)=P(X\in g^{-1}(-\infty,y]\bigcap(a,b))=\begin{cases}0, & y\le c,\\ \int_a^{g^{-1}(y)}p_X(x)dx, & c<y<d,\\ 1, & y\ge d.\end{cases}$$

对 $F_Y(y)$ 求导得

$$p_Y(y)=\begin{cases}p_X(g^{-1}(y))\left|\dfrac{dg^{-1}(y)}{dy}\right|, & \text{if } y\in(c,d),\\ 0, & \text{else.}\end{cases}$$

易验证， $p_Y(y)$ 是一个 p.d.f.。函数 $y=g(x),x\in(a,b)$ 严格单调减的情况同理可证。证毕。

例 2.4.5 设 $X\sim U(0,1)$， $Y=-\dfrac{1}{\lambda}\log X$，参数 $\lambda>0$。求 Y 的概率分布。

解：

函数 $y=-\frac{1}{\lambda}\log x, x\in(0,\infty)$ 严格单调减，反函数为 $x=e^{-\lambda y}, y\in(-\infty,\infty)$，$\frac{dx}{dy}=-\lambda e^{-\lambda y}$。

X 的 p.d.f.为 $p_X(x)=I_{(0,1)}(x)$，显然 X 分布的广义支撑 $(0,1)\subset(0,\infty)$，即有 $P(X\in(0,\infty))=1$。

因此，由定理 2.4.1 知，Y 的 pdf 为

$$p_Y(y)=p_X(e^{-\lambda y})\cdot|-\lambda e^{-\lambda y}|=\lambda e^{-\lambda y}I_{(0,\infty)}(y).$$

可见，$Y\sim\mathrm{Exp}(\lambda)$。

例 2.4.6 设 $X\sim U[-\frac{\pi}{2},\frac{\pi}{2}]$，$Y=\tan X$。求 Y 的概率分布。

解：

函数 $y=\tan x, x\in(-\frac{\pi}{2},\frac{\pi}{2})$ 严格单调增，反函数 $x=\arctan y, y\in(-\infty,\infty)$，$\frac{dx}{dy}=\frac{1}{1+y^2}$。$X$ 的 p.d.f.为 $p_X(x)=\frac{1}{\pi}I_{(-\frac{\pi}{2},\frac{\pi}{2})}(x)$，$(-\frac{\pi}{2},\frac{\pi}{2})$ 为 X 分布的广义支撑。因此，由定理 2.4.1 知，Y

的 p.d.f.为

$$p_Y(y)=p_X(\arctan y)\frac{1}{1+y^2}=\frac{1}{\pi(1+y^2)},\ y\in(-\infty,\infty).$$

Y 的分布便是著名的 Cauchy 分布。

定理 2.4.2 设区间 $(a_j,b_j), j=1,\cdots,k$ 互斥，函数 $y=g(x)$ 在 $x\in(a_j,b_j)$ 上严格单调且可导，反函数为 $x=g_j^{-1}(y), y\in(c_j,d_j)$， $j=1,\cdots,k$；连续型 r.v. X 的密度函数为 $p_X(x)$，且 $P(X\in\sum_{j=1}^{k}(a_j,b_j))=1$。那么 $Y=g(X)$ 的 pdf 为

$$p_Y(y)=\sum_{j=1}^{k}p_X(g_j^{-1}(y))\left|\frac{dg_j^{-1}(y)}{dy}\right|I_{(c_j,d_j)}(y)。$$

注：设 $a_1<b_1\le\cdots\le a_k<b_k$，则 $a_1,c_1,\cdots,c_k$ 可取 $-\infty$、$b_k,d_1,\cdots,d_k$ 可取 ∞；$(c_j,d_j), j=1,\cdots,k$ 未必互斥。

例 2.4.7 (1) 用定理 2.4.2 求例 2.4.4 中 $\chi^2(1)$ 分布的 pdf。

解：

函数 $y=x^2$ 在 $(-\infty,0)$ 上严减，反函数为 $x=-\sqrt{y}, y\in(0,\infty)$，$\dfrac{dx}{dy}=-\dfrac{1}{2}y^{-\frac{1}{2}}$；在 $(0,\infty)$ 上严增，反函数为 $x=\sqrt{y}, y\in(0,\infty)$，$\dfrac{dx}{dy}=\dfrac{1}{2}y^{-\frac{1}{2}}$。

X 的 p.d.f.为 $\phi(x)$，$P(X\in(-\infty,0)\cup(0,\infty))=1$。因此，由定理 2.4.2 知，$Y$ 的 pdf 为

$$p_Y(y)=p_X(-\sqrt{y})\left|\frac{d(-\sqrt{y})}{dy}\right|I_{(0,\infty)}(y)+p_X(\sqrt{y})\left|\frac{d\sqrt{y}}{dy}\right|I_{(0,\infty)}(y)=\frac{1}{\sqrt{2\pi}}y^{-\frac{1}{2}}e^{-\frac{y}{2}}I_{(0,\infty)}(y).$$

注：这里虽然忽略了 $X=0$ 的情况，但因 $P(X=0)=0$，故忽略它对 Y 的分布没有影响。

(2) 设 $X\sim U(-1,2)$，求 $Y=\dfrac{1}{|X|}$ 的概率分布。

解：

若 $x\in(-\infty,0)$， $y=\dfrac{1}{|x|}=-\dfrac{1}{x}$ 严格单调增，反函数为 $x=-y^{-1}, y\in(0,\infty)$， $\dfrac{dx}{dy}=y^{-2}$。

若 $x\in(0,\infty)$， $y=\dfrac{1}{|x|}=\dfrac{1}{x}$ 严格单调减，反函数为 $x=y^{-1}, y\in(0,\infty)$，且 $\dfrac{dx}{dy}=-y^{-2}$。

X 的 pdf 为 $p_X(x)=\dfrac{1}{3}I_{(-1,2)}(x)$。显然 $P(X\in(-\infty,0)\cup(0,\infty))=1$。因此，由定理 2.4.2 知，$Y$ 的 pdf 为

$$
\begin{aligned}
p_Y(y)&=p_X(-y^{-1})|y^{-2}|I_{(0,\infty)}(y)+p_X(y^{-1})|-y^{-2}|I_{(0,\infty)}(y)\\
&=\frac{1}{3}y^{-2}I_{(-1,2)}(-y^{-1})I_{(0,\infty)}(y)+\frac{1}{3}y^{-2}I_{(-1,2)}(y^{-1})I_{(0,\infty)}(y)\\
&=\frac{1}{3}y^{-2}[I_{(1,\infty)}(y)+I_{(\frac{1}{2},\infty)}(y)]=\frac{1}{3}y^{-2}I_{(\frac{1}{2},1]}(y)+\frac{2}{3}y^{-2}I_{(1,\infty)}(y).
\end{aligned}
$$

注：虽然 $x=0$ 时 $y=\dfrac{1}{|x|}$ 无定义，但因 $P(X=0)=0$，故忽略它对 Y 的分布没有影响。

3. Y 非连续型分布的情况

例 2.4.8 设某机床加工零件的尺寸误差 $X \sim N(0,\sigma^2)$。正、负误差导致的损失可表示为

$$Y = \begin{cases} a, & \text{if } X \geq 0, \\ b, & \text{if } X < 0. \end{cases}$$

其中 $a \neq b$。求 Y 的概率分布。

解：

Y 仅可能取 2 个不同的值，因此服从离散型分布，其分布列为

$$P(Y=a) = P(X \geq 0) = \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} dx = \frac{1}{2},$$

$$P(Y=b) = 1 - P(Y=a) = \frac{1}{2}.$$

§ 2.5 数学期望

前面，我们讨论了全面刻画$(\mathbb{R},\mathcal{B}_{\mathbb{R}})$上概率分布的三个最常用的数学工具：d.f.、分布列与 p.d.f.。在实际应用中，也常常需要用少量数值去概括一个概率分布的主要特征。这些数值就称为概率分布的数字特征。

例如：

1) 某厂生产的某种电视机的寿命 T 可用一个概率分布来描述。在产品介绍时，通常不会详细介绍该概率分布，而会介绍该产品的平均寿命、可靠度(产品在规定时间段内无故障地工作的概率)、一定可靠度下的可靠寿命等信息。“平均寿命”、“可靠度”、“可靠寿命”，这些数值概括的就是 T 的概率分布的特征。

2) 在选拔运动员时，假定每位运动员在未来赛事中的成绩都分别可用一个概率分布来描述，那么对运动员的比较也往往基于他们各自成绩分布的数字特征来进行，比如，看他们的最好成绩、平均成绩、成绩波动大小等特征。

概括概率分布的常用数字特征有：

✧ 矩 (moments)，包括原点矩与中心矩两类，数学期望、方差是其中最常用的数字特征。

✧ 与矩有关的数字特征，如标准差、偏度系数、峰度系数、相关系数等。

✧ 部分分位点（quantiles），比如第一及第三四分位点、中位数、第 1~9 十分位点等。

✧ 与分位点有关的数字特征，如四分位间距、极差等。

这些数字特征，有些刻画概率分布的“中心”位置，如数学期望、中位数；有些刻画概率分布的范围大小，如方差、标准差、四分位间距、极差等；有些刻画分布的对称性，比如偏度系数；有些刻画厚尾程度，如峰度系数。

数学期望(简称期望，expectation)是最重要、最基本的一个数字特征。它是 r.v.的取值以其概率为权重的加权平均，描述分布的中心（或重心）位置。据说，这个概念源于 17 世纪 Pascal 对于分赌注问题的研究。

例 2.5.1 (分赌注问题) 甲乙两人各出赌注 50 法郎，用轮流掷一枚均匀硬币进行赌博。规则是掷一次硬币算一局，得正面算甲胜，得反面算乙胜。谁先胜三局就赢得全部 100 法郎赌注。掷三次硬币后，甲胜两局乙胜一局，赌博因故中止。问这 100 法郎赌注该如何分配才算合理？

Pascal 提出的赌注分配方案是：以甲、乙两人各自赢得赌注的期望值来分配赌注。若赌博继续，记甲的最终所得为 r.v. X，其分布列为

x	200	0
$P(X=x)$	3/4	1/4

所谓期望值，就是各种所得情况按其概率加权平均：$100\times\frac{3}{4}+0\times\frac{1}{4}=75$。乙的期望为 25。

数学期望可用测度论中关于概率测度的积分严格、统一地定义。这里先基于微积分知识从实用的角度按概率分布的类型分别给出定义。这些定义与严格定义不矛盾。

一、数学期望的定义

定义 2.5.1 (离散型分布的数学期望) 设离散型 r.v. X 的分布列为$\{(x_i, p_i): i=1,2,\cdots\}$。若 $\sum_{i=1}^{\infty}|x_i|p_i<\infty$，则称

$$E(X)=\sum_{i=1}^{\infty}x_i p_i,$$

为X(或X分布)的数学期望；若$\sum_{i=1}^{\infty}|x_i|p_i=\infty$，则称数学期望不存在。

注：

✧ 定义中条件 $\sum_{i=1}^{\infty}|x_i|p_i<\infty$ 与严格定义的要求一致。该条件保证了在计算 $\sum_{i=1}^{\infty}x_i p_i$ 时任意交换有限项的次序不会改变级数的值，避免了对数学期望给出不明确的定义。

✧ 直观上，$E(X)$就是以概率为权重对 r.v. X所有可能取值的加权平均，类似于力学中“力矩”的概念。

✧ 若 r.v. X只取有限个值，则$E(X)$必存在。

例 2.5.2 某福利彩票每张售 2 元，采用 30 选 7 的方式投注。开奖、中奖的方式与目前的“七乐彩”相同，但奖金设置固定。具体如下表所列。

> 通过摇奖器确定开奖号码。摇奖时从 01～30 个号码中，先摇出 7 个号码作为基本号码，再摇出 1 个号码作为特别号码。
> 一等奖：投注号码与当期开奖号码中 7 个基本号码完全相同（顺序不限，下同）；奖金 200 万元。
> 二等奖：投注号码与当期开奖号码中任意 6 个基本号码及特别号码相同；奖金 5 万元。
> 三等奖：投注号码与当期开奖号码中任意 6 个基本号码相同；奖金 5000 元。
> 四等奖：投注号码与当期开奖号码中任意 5 个基本号码及特别号码相同；奖金 200 元。
> 五等奖：投注号码与当期开奖号码中任意 5 个基本号码相同；奖金 50 元。

设 r.v. X 为购买一张彩票所得的奖金金额。那么 X 的分布列为

X	0	5	10	50	200	2,000	50,000	2,000,000	Total
P	$1-67460c$	$53900c$	$8085c$	$4851c$	$462c$	$154c$	$7c$	c	1
概率近似值	0.9669	2.648e-2	3.971e-3	2.383e-3	2.269e-4	7.565e-5	3.438e-6	4.912e-7	1

其中 $c=\binom{30}{7}^{-1}$。故 X 的数学期望为

$$E(X)=0\times 0.9669+5\times 2.648\times 10^{-2}+\cdots+2\times 10^{6}\times 4.912\times 10^{-7}=1.6423(\text{元})。$$

如何理解这个数学期望值？它有什么用？

例 2.5.3 (group testing) 在有 N 个人的群体中普查某种疾病，需要逐个验血。一个人的血样呈阳性表明此人患有该疾病，呈阴性则无此病。逐人验血需要验 N 次，若 N 很大那工作量也很大。为减少工作量，有人提出，把 $k(\geqslant 2)$个人的血样混合后检验。若呈阴性则此 k 人均无此病；若呈阳性则再对这 k 人逐个检验，此时为确认谁患此病共需检验 $k+1$ 次。若每个人血样阳性的概率为 p，且各人之间相互独立。那么该方法能否减少验血次数？减少多少？Dorfman (1943) 首先研究了这个方法。

解：

设采用混合检验法对一个人验血的次数为 X，其分布列为

x	$1/k$	$1+1/k$
$P(X=x)$	$(1-p)^k$	$1-(1-p)^k$

则

$$E(X)=\frac{1}{k}(1-p)^k+(1+\frac{1}{k})[1-(1-p)^k]=1-(1-p)^k+\frac{1}{k}。$$

对于每一个人，用混合检验法比逐个检验法预期可减少验血次数

$$1-E(X)=(1-p)^k-\frac{1}{k}。$$

这个数可理解为："平均每人"可减少的验血次数。若它大于 0，说明混合检验法确实能减少验血次数。如 $p=0.1,\ k=2$，$1-E(X)=0.9^2-0.5=0.31$，即"平均每人"减少 0.31 次。假如某人群共 1 万人，那么可期望减少验血次数 3100 次。

问题：给定 p 时，k 取多大可使最大程度地减少验血量？

例 2.5.4 离散型分布的数学期望

(1) 若 $X\sim \mathrm{B}(n,p)$，则 $E(X)=np$。

(2) 若 $X\sim \mathrm{Ge}(p)$，则 $E(X)=\dfrac{1}{p}$。

(3) 若 $X\sim \mathrm{Poi}(\lambda)$，则 $E(X)=\lambda$。

(4) (**期望不存在**) 设 X 的分布列为 $P\left[X=(-1)^k\dfrac{2^k}{k}\right]=2^{-k}, k=1,2,\cdots$。

尽管 $\sum_{k=1}^{\infty}(-1)^k\dfrac{2^k}{k}\cdot 2^{-k}=-\log 2$，但该级数不绝对收敛，所以 X 的期望不存在。

定义 2.5.2 (连续型分布的数学期望) 设连续型 r.v. X 的 p.d.f. 为 $p(x)$。若 $\int_{-\infty}^{\infty}|x|\,p(x)dx<\infty$，则称

$$E(X)=\int_{-\infty}^{\infty}xp(x)dx$$

为 X（或 X 分布）的数学期望；若 $\int_{-\infty}^{\infty}|x|\,p(x)dx=\infty$，则称数学期望不存在。

注：

✧ 可先将这里的积分理解为 Riemann 积分，严格定义中的是 Lebesgue 积分。若 $\int_{-\infty}^{\infty}|x|\,p(x)dx<\infty$，则由 $\int_{-\infty}^{\infty}xp(x)dx$ Riemann 可积可得它 Lebesgue 可积。

✧ 该定义是“加权平均”在连续型分布场合的推广。若取点 $x_0<x_1<\cdots<x_n$，分割 X 的值

域范围，用和式 $\sum_{i=0}^{n-1} x_i P(X \in [x_i, x_{i+1})) \approx \sum_{i=0}^{n-1} x_i p(x_i)(x_{i+1} - x_i)$ 近似 X 的取值关于概率的加权平均。当 $\max_i (x_{i+1} - x_i) \to 0$ 时，该和式的极限（若存在）即为定义中的积分。

例 2.5.5 连续型分布的数学期望

(1) 设 $X \sim U(a,b)$。因 $\int_{-\infty}^{\infty} |x| p(x) dx < \infty$（请自行证明），故 X 的数学期望存在，且为

$$E(X) = \int_{-\infty}^{\infty} x p(x) dx = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{a+b}{2}。$$

(2) 若 $X \sim N(\mu, \sigma^2)$，则 $E(X) = \mu$。

(3) 若 $X \sim \mathrm{Ga}(\alpha, \lambda)$，则 $E(X) = \dfrac{\alpha}{\lambda}$。特例，$\mathrm{Exp}(\lambda)$ 的期望为 $\dfrac{1}{\lambda}$，$\chi^2(k)$ 的期望为 k。

(4) 若 $X \sim \mathrm{Beta}(\alpha, \beta)$，则 $E(X) = \dfrac{\alpha}{\alpha + \beta}$。

(5) 设 X 服从 Cauchy 分布，pdf 为 $p(x)=\dfrac{1}{\pi(1+x^2)}, x\in\mathbb{R}$，则 $E(X)$ 不存在；例 2.3.2 中连续型随机变量 X 的数学期望不存在。

适合 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上所有概率分布的数学期望的定义

定义 2.5.3 设 r.v. X 的 d.f. 为 $F(x)$。若 $\int_{-\infty}^{\infty}|x|dF(x)<\infty$，则称

$$E(X)=\int_{-\infty}^{\infty}xdF(x)$$

为 X（或 X 分布）的数学期望；若 $\int_{-\infty}^{\infty}|x|dF(x)=\infty$，则称数学期望不存在。

注：

✧ 可先将这里的积分先理解为 Riemann-Stieltjes 积分，严格定义中的是 Lebesgue-Stieltjes 积分。若 $\int_{-\infty}^{\infty}|x|dF(x)<\infty$，则由 $\int_{-\infty}^{\infty}xdF(x)$ R-S 可积可得 L-S 可积。

✧ 该定义是“加权平均”的推广。测度论中对 $E(X)$ 分三步定义：

1) 如定义 2.5.1 般定义简单 r.v.（即取有限个值的离散型 r.v.）的期望；

2) 将 X 分解为正部、负部，即 $X = X^+ - X^-$，分别用单调不减、不大于 $X^\pm$ 且极限为 $X^\pm$ 的简单 r.v.序列 $X_n^\pm$ 逼近 $X^\pm$，定义 $E(X^+) = \lim\limits_{n\to\infty} E(X_n^+),\ E(X^-) = \lim\limits_{n\to\infty} E(X_n^-)$；

3) 若 $\max\{E(X^+), E(X^-)\} < \infty$，则定义 $E(X) = E(X^+) - E(X^-)$，否则称期望不存在。

其中，用单调不减的非负简单 r.v.序列 X_n^+ 逼近 X^+、用 $\lim\limits_{n\to\infty} E(X_n^+)$ 定义 $E(X^+)$，实际就是对 $[0,\infty)$ 取分割点 $0 = x_0 < x_1 < \cdots < x_n < \infty$、对和式 $\sum\limits_{i=0}^{n-1} x_i P(X \in [x_i, x_{i+1})) + x_n P(X \ge x_n)$ 求极限的过程。而

$$\sum_{i=0}^{n-1} x_i P(X \in [x_i, x_{i+1})) + x_n P(X \ge x_n) = \sum_{i=0}^{n-1} x_i [F(x_{i+1}-) - F(x_i-)] + x_n [1 - F(x_n-)],$$

它的极限即为 R-S 积分 $\int_0^\infty x^+ dF(x)$。

✧ 当 $F(x)$ 为阶梯函数（即离散型 d.f.）时，

$$\int_{-\infty}^{\infty} x dF(x) = \sum_{x:F(x)-F(x')>0} x[F(x)-F(x-)],$$

与定义 2.5.1 一致；

当 $F(x)$ 为连续型 d.f.，$\int_{-\infty}^{\infty} x dF(x) = \int_{-\infty}^{\infty} xF'(x)dx$，与定义 2.5.2 一致；

当 $F(x)$ 为离散与连续型混合的 d.f.时，即 $F(x) = c_1 F_d(x) + c_2 F_c(x)$，则

$$\int_{-\infty}^{\infty} x dF(x) = \sum_{x:F(x)-F(x')>0} x[F(x)-F(x-)] + \int_{-\infty}^{\infty} xF'(x)dx。$$

二、随机变量函数的数学期望

设 X 是 $(\Omega,\mathcal{F},P)$ 上的 r.v.，$g(\cdot)$ 是 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的可测函数。令 $Y = g(X)$，则可视 Y 是定义在 X 的值域空间 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的 r.v.，其概率分布由 X 的分布导出。

欲求 Y 的期望，可先求出 Y 的分布，再按期望的定义求；另一条途径是，直接对 $g(x)$ 关于 X 的 d.f.求 Lebesgue-Stieltjes 积分。下列定理说明两者是一致的，李贤平 (2010) 书中称此定理为佚名统计学家公式。

定理 2.5.1 设 r.v. X 的 d.f.为 $F_X(x)$，$g(\cdot)$ 是 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的可测函数，$Y=g(X)$。若 $E(Y)$ 存在，

则 $E(Y)=\int_{-\infty}^{\infty} y dF_Y(y)=\int_{-\infty}^{\infty} g(x) dF_X(x)$。

注：

✧ $E(Y)$ 的存在性，可由 $\int_{-\infty}^{\infty}|g(x)|dF(x)<\infty$ 判断。定理由测度论中积分的变换易证，对此本课程不作要求。

✧ 视定理中的两个积分为L-S积分，两者相等；但视之为R-S积分则不然。比如，$X\sim U(0,1)$，$g(x)=I_{\mathbb{Q}}(x)$，R-S 积分

$$\int_{-\infty}^{\infty} g(x)dF_X(x) = \lim_{\substack{\max_i (x_{i+1}-x_i)\to 0 \\ 0=x_0<\cdots<x_{n+1}=1}} \sum_{i=0}^{n} g(x_i')(x_{i+1}-x_i)$$

不存在。而 Y 的分布列为 $P(Y=1)=P(X\in\mathbb{Q})=0=1-P(Y=0)$，R-S 积分

$$\int_{-\infty}^{\infty} ydF_Y(y)=0 \text{。}$$

推论 2.5.1 设 $g(\cdot)$ 是 $(\mathbb{R},\mathcal{B}_{\mathbb{R}})$ 上的可测函数，$Y=g(X)$。

(1) 若 X 的分布列为 $\{(x_i,p_i):i=1,2,\cdots\}$，且 $\sum_{i=1}^{\infty}|g(x_i)|p_i<\infty$，则 Y 的期望存在，为

$$E(Y)=E[g(X)]=\sum_{i=1}^{\infty} g(x_i)p_i \text{。}$$

(2) 若 X 的 p.d.f.为 $p(x)$，且 $\int_{-\infty}^{\infty}|g(x)|p(x)dx<\infty$，则 Y 的期望存在，为

$$E(Y)=E[g(X)]=\int_{-\infty}^{\infty} g(x)p(x)dx \text{。}$$

注：

✧ 若 $g(x)=x$，$Eg(X)$ 就是 $E(X)$，因而该推论的结论包含了 $E(X)$ 的定义。

✧ 若 $g(x)=I_A(x)$，则 $Y=I_A(X)\sim B(1,p)$，其中 $p=P(X\in A)=E[I_A(X)]$。

✧ 若 $P(X\in A)=1$，那么 X 在 $\overline{A}$ 上的取值不影响 $E(X), Eg(X)$。因此 $g(x)$ 只要在 A 上有定义即可，即使在 $\overline{A}$ 上没有定义也不影响 $Eg(X)$ 的定义与计算。

✧ 通常 $E(Y)\neq g[E(X)]$。

例 2.5.6 某人参加这样一个掷骰子的赌博游戏：若押点数为 1，则奖金与赌注之比为 $4:1$；若押点数为 3 或 5，则奖金与赌注之比为 $1.5:1$；若押点数为 2，4 或 6，则奖金与赌注之比为 $1:1$。设一轮赌博中此人拿出 8 元押 1 点、3 元押 3 或 5 点、2 元押 2，4，6 点。求他在此轮赌博中赢利 Y 元的分布及 $E(Y)$。

解：

记该轮赌博中骰子掷出的点数为 X。显然，Y 是 X 的函数，记为 $Y=g(X)$，其中

$$g(x)=\begin{cases} 8\times 4-3-2, & \text{if } x=1, \\ -8+3\times 1.5-2, & \text{if } x=3,5, \\ -8-3+2, & \text{if } x=2,4,6. \end{cases}$$

X 的分布列及 Y 与 X 的关系列于下表：

X	1	2	3	4	5	6
Y	27	−9	−5.5	−9	−5.5	−9
P	1/6	1/6	1/6	1/6	1/6	1/6

故 Y 的分布列为

Y	27	−5.5	−9
P	1/6	1/3	1/2

$$E(Y)=27\times\frac{1}{6}+(-5.5)\times\frac{1}{3}+(-9)\times\frac{1}{2}=-\frac{11}{6}\text{。}$$

事实上，由前一张表容易看出，

$$E(Y)=g(1)\times P(X=1)+g(2)\times P(X=2)+\cdots+g(6)\times P(X=6)\text{。}$$

另外，$E(X)=3.5$，而 $g(3.5)$ 无定义，因此显然 $E(Y)\neq g(E(X))$。

例 2.5.7

(1) 设 $X \sim U(a,b),\ Y = X^2$，则

$$E(Y) = E(X^2) = \int_{-\infty}^{\infty} x^2 p(x)dx = \int_a^b x^2 \cdot \frac{1}{b-a} dx = \frac{b^3 - a^3}{3(b-a)} = \frac{b^2 + ab + a^2}{3}。$$

(2) 若 $Y \sim \mathrm{LN}(\mu,\sigma^2)$，则 $Y \overset{d}{=} e^X$，其中 $X \sim N(\mu,\sigma^2)$，因此

$$E(Y) = E[g(X)] = \int_{-\infty}^{\infty} e^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = e^{\mu + \frac{\sigma^2}{2}}。$$

三、数学期望的基本性质

定理 2.5.2 设 X 是 r.v.，$P(X \in A) = 1$；$g(\cdot),\ g_1(\cdot),\ g_2(\cdot)$ 是 $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ 上的可测函数；a, b, c 表示常数。

(1) 若 $a \le g(x) \le b, \forall x \in A$，则 $Eg(X)$ 必存在，且 $a \le Eg(X) \le b$。特别地，$Ec = c$。

(2)（线性性质）$E\left[ag_1(X)+bg_2(X)+c\right]=aEg_1(X)+bEg_2(X)+c$。

(3) 若 $g_1(x)\ge g_2(x),\forall x\in A$，则 $Eg_1(X)\ge Eg_2(X)$。

例 2.5.8

(1) 设 $X\sim \mathrm{Poi}(\lambda)$，其分布列为 $P(X=x)=\dfrac{\lambda^x}{x!}e^{-\lambda},\ x=0,1,2,\cdots$。则

$$E(X)=\sum_{x=0}^{\infty}xP(X=x)=\sum_{x=1}^{\infty}\frac{\lambda\cdot\lambda^{x-1}}{(x-1)!}e^{-\lambda}=\lambda,$$

$$E(X^2)=E[X(X-1)+X]=\sum_{k=0}^{\infty}k(k-1)\frac{\lambda^k}{k!}e^{-\lambda}+E(X)=\lambda^2+\lambda。$$

(2) 对于任意随机变量 X，只要 $E(X^2)$ 存在，即 $E(X^2)<\infty$，则必有 $E(X)$ 存在。

证明：因为对 $\forall x\in\mathbb{R}$，不等式 $|x|<x^2+1$ 都成立。若 $E(X^2)<\infty$，则由性质(3)知

$$E(|X|) \le E(X^2)+1<\infty,$$

即 $E(X)$ 存在。

本例结论可推广至：对于 $\forall 0<a<b$，若 $E(|X|^b)<\infty$ 则必有 $E(|X|^a)<\infty$。

§2.6 方差及其他数字特征

一、方差

定义 2.6.1 若 $E(X-EX)^2$ 存在，则称之为 r.v. X 的方差(*variance*)，记为 $\mathrm{var}(X)$。称 $\sqrt{\mathrm{var}(X)}$ 为 X 的标准差（*standard deviation, std*），常记为 $\mathrm{std}(X)$。

方差是刻划随机变量取值分散程度的一个量，方差越小说明 X 的取值越集中，越大则越分散。方差存在则期望一定存在；反之不然。

计算方法

- $$\mathrm{var}(X)=\begin{cases}\sum\limits_{x\in\mathcal{S}_X}(x-EX)^2P(X=x), & X\text{离散型分布},\\ \int_{-\infty}^{\infty}(x-EX)^2p(x)dx, & X\text{连续型分布}.\end{cases}$$
- $\mathrm{var}(X)=E(X^2)-(EX)^2$

例 2.6.1 (1) 设 r.v. X 等概率地取 -2、0、1、3、4 五个值。求 X 的方差与标准差。

解：

$$E(X)=\frac{1}{5}(-2+0+1+3+4)=1.2\text{。}$$

$$\mathrm{var}(X)=E(X-EX)^2=\frac{1}{5}[(-2-1.2)^2+(0-1.2)^2+\cdots+(4-1.2)^2]=4.56 \quad \text{或者}$$

$$\mathrm{var}(X)=E(X^2)-(EX)^2=\frac{1}{5}[(-2)^2+0^2+\cdots+4^2]-1.2^2=4.56\text{。}$$

标准差为 $\mathrm{std}(X)=\sqrt{\mathrm{var}(X)}=\sqrt{4.56}=2.135$。

(2) 设 $X\sim \mathrm{Poi}(\lambda)$，其分布列为 $P(X=x)=\dfrac{\lambda^x}{x!}e^{-\lambda},\ x=0,1,2,\cdots$。则 $\mathrm{var}(X)=\lambda$。

(3) 设 $X\sim U(a,b)$，则 $\mathrm{var}(X)=\dfrac{(b-a)^2}{12}$。

(4) 对于任意随机变量 X，只要 $\mathrm{var}(X)$ 存在，则必有 $E(X)$ 存在。

定理 2.6.1 (方差的基本性质)

(1) c 为常数，则 $\mathrm{var}(c)=0$。

(2) a，c 为常数，则 $\mathrm{var}(aX+c)=a^2\,\mathrm{var}(X)$。

(3) $\mathrm{var}(X)=\min\limits_{c}E(X-c)^2$。

(4) (Chebyshev 不等式) 若 $\mu=E(X),\ \sigma^2=\mathrm{var}(X)$，则对 $\forall\varepsilon>0$，有

$$P\big(|X-\mu|\geq\varepsilon\big)\leq\frac{\sigma^2}{\varepsilon^2}。$$

或等价地 $P\big(|X-\mu|<\varepsilon\big)\geq 1-\dfrac{\sigma^2}{\varepsilon^2}$。若令 $\varepsilon=c\sigma$，则有 $P\big(|X-\mu|\geq c\sigma\big)\leq\dfrac{1}{c^2}$。

（由数学期望性质(3)可证。是 Markov 不等式的特例。）

(5) $\mathrm{var}(X)=0\iff P(X=E(X))=1$。

随机变量的标准化

设 $\mu = E(X),\ \sigma^2 = \mathrm{var}(X) > 0$，称 $X^* = \dfrac{X-\mu}{\sigma}$ 是 X 的标准化。易知，$EX^* = 0,\ \mathrm{var}(X^*) = 1$。

二、矩(moment)及与矩有关的数字特征

k 阶原点矩：$EX^k,\ k = 1, 2, \cdots$

k 阶中心矩：$E(X - EX)^k,\ k = 1, 2, \cdots$

偏度系数(skewness)：$\gamma_3 = \dfrac{E(X-EX)^3}{\left[\mathrm{var}(X)\right]^{3/2}}$

峰度系数(kurtosis)：$\gamma_4 = \dfrac{E(X-EX)^4}{\left[\mathrm{var}(X)\right]^{2}} - 3$

变异系数(Coefficient of Variance)：$\mathrm{CV} = \dfrac{\sqrt{\mathrm{var}(X)}}{E(X)}$ (if $E(X) > 0$)

根据数学期望、中位数、标准差、四分位间距、偏度、峰度等数字特征判断分布的形态

矩母函数

定义 2.6.2 设 r.v. $X \sim F(x)$，若存在 $h>0$，使 $\forall t \in (-h,h)$， Ee^{tX} 存在，则称 $M_X(t)=Ee^{tX}$ 为 X (或 $F(x)$) 的矩母函数 (*moment generating function*，*m.g.f.*)。若在 0 的任何一个邻域 Ee^{tX} 都不存在，则称 X 的 m.g.f.不存在。

性质：

(1) 若 X 的 m.g.f. $M_X(t)$ 存在，则 $EX^n = M_X^{(n)}(0) \hat{=} \left.\dfrac{d^n}{dt^n} M_X(t)\right|_{t=0}$ 。

(2) 若 r.v. X, Y 的矩母函数都存在，且存在 $h>0$，使得 $M_X(t)=M_Y(t),\ \forall t \in (-h,h)$。则 $F_X(u)=F_Y(u),\ \forall u \in \mathbb{R}$。

特别地，若存在 $0 \le M < \infty$ 使得 $P(|X| \le M) = P(|Y| \le M) = 1$，则有

$$EX^r = EY^r,\ r=0,1,2,\cdots \Longleftrightarrow F_X(u)=F_Y(u),\ \forall u \in \mathbb{R}。$$

(3) $M_{aX+b}(t) = e^{bt} M_X(at)$.

特征函数（*characteristic function*）后面专门讨论。

其他生成函数：

累积量生成函数（*cumulant generating function*）：$K(t)=\log[M_X(t)]$。

阶乘矩生成函数（李(2010)书中称为*母函数*）：Et^X