第五章　概率极限定理简介

极限定理是概率论中的重要内容，在理论与实际问题的研究中都有广泛应用。

概率论中最初的极限定理包括大数定律 (Laws of Large Numbers)、中心极限定理 (Central Limit Theorems)两类。大数定律给出了频率稳定性的理论解释，是经典频率统计学的重要理论依据。中心极限定理解释了正态分布的来源、揭示了复杂随机现象背后的简洁规律，在概率近似计算、大样本统计分析等众多领域有广泛应用。

提　纲

§ 5.1　随机变量序列的收敛性

§ 5.2　大数定律

§ 5.3　依分布收敛的性质

§ 5.4　中心极限定理

§ 5.1 随机变量序列的收敛性

随机变量是以样本点为自变量、取有限实数值的函数。定义在一个概率空间上的随机变量序列，类似于普通的实函数序列。对于 r.v.序列，也可像对实函数序列那样，考察其逐点收敛、一致收敛等收敛性。但是，这些收敛性对于 r.v.序列而言往往过于严苛而没有多少意义，概率论中针对 r.v.序列研究更广意义下的收敛性。

本节给出针对 r.v.序列常用的一些收敛性定义及其基本性质。这里的收敛性，指的都是趋于**有限极限**的收敛。

几乎必然/几乎处处收敛(convergence almost sure/everywhere, a.s. / a.e.)

定义 5.1.1 设 $X(\omega), X_n(\omega), n=1,2,\cdots$ 都是同一个概率空间 $(\Omega,\mathcal{F},P)$ 上的有限值 r.v.。若

$$P(\{\omega:\lim_{n\to\infty}X_n(\omega)=X(\omega)\})=1,$$

则称 r.v.序列 $\{X_n:n=1,2,\cdots\}$ 几乎必然(或几乎处处)收敛于 X，记作 $X_n\to_{a.s.}X$。（也称以概率 1 收敛）

定理 5.1.1 $X_n \to_{a.s.} X$ 的充要条件是：对于 $\forall \varepsilon > 0$，

$$P\left(\bigcap_{n=1}^{\infty}\bigcup_{m=n}^{\infty}\{\omega : |X_m(\omega) - X(\omega)| \geq \varepsilon\}\right) = 0 \quad \text{或者} \quad P\left(\bigcup_{n=1}^{\infty}\bigcap_{m=n}^{\infty}\{\omega : |X_m(\omega) - X(\omega)| < \varepsilon\}\right) = 1。$$

证明：

记 $A = \{\omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}$， $B(\varepsilon) = \bigcup_{n=1}^{\infty}\bigcap_{m=n}^{\infty}\{\omega : |X_m(\omega) - X(\omega)| < \varepsilon\}$。

必要性。对 $\forall \varepsilon > 0$，$\forall \omega \in A$，按数列极限的定义：$\exists N(\omega)$，$\forall m \geq N(\omega)$，$|X_m(\omega) - X(\omega)| < \varepsilon$，

即 $\omega \in \bigcap_{m=N(\omega)}^{\infty}\{\omega : |X_m(\omega) - X(\omega)| < \varepsilon\} \subset B(\varepsilon)$。故 $A \subset B(\varepsilon)$。由 $X_n \to_{a.s.} X$ 知 $P(B(\varepsilon)) \geq P(A) = 1$。

充分性。$\forall \omega \in \overline{A}$， $\exists k \in \mathbb{N}$， $\ni \omega \in \overline{B(2^{-k})}$，即 $\omega \in \bigcup_{k=1}^{\infty}\overline{B(2^{-k})}$。因此， $\overline{A} \subset \bigcup_{k=1}^{\infty}\overline{B(2^{-k})}$。由

$$P(\overline{A}) \leq P[\bigcup_{k=1}^{\infty}\overline{B(2^{-k})}] \leq \sum_{k=1}^{\infty} P[\overline{B(2^{-k})}] = 0$$

知 $P(\overline{A}) = 0$，即 $X_n \to_{a.s.} X$。

定理 5.1.2 (Borel-Cantelli 引理) 设 $(\Omega,\mathcal{F},P)$ 是一个概率空间，$A_n\in\mathcal{F},n=1,2,\cdots$ 是一列事件。

常记 $\limsup\limits_{n\to\infty}A_n=\{A_n,\text{i.o.}\}$ (i.o. 是 infinitely often 的缩写)。证明：

(1) 如果 $\sum_{n=1}^{\infty}P(A_n)<\infty$，则 $P(A_n,\text{i.o.})=0$；

(2) 如果 $A_n,n=1,2,\cdots$ 相互独立，且 $\sum_{n=1}^{\infty}P(A_n)=\infty$，则 $P(A_n,\text{i.o.})=1$。

证明见第三周习题解答。

依概率收敛 (Convergence in Probability)

定义 5.1.2 设 $X(\omega),X_n(\omega),n=1,2,\cdots$ 都是同一个概率空间 $(\Omega,\mathcal{F},P)$ 上的有限值 r.v.。若对 $\forall\varepsilon>0$ 都有

$$\lim_{n\to\infty}P(|X_n-X|\geq\varepsilon)=0 \quad \text{或} \quad \lim_{n\to\infty}P(|X_n-X|<\varepsilon)=1,$$

则称 r.v.序列 $\{X_n:n=1,2,\cdots\}$ 依概率收敛于 X，记作 $X_n\to_p X$。

定理 5.1.3 设 $X(\omega), X_n(\omega), n=1,2,\cdots$ 都是同一个概率空间 $(\Omega,\mathcal{F},P)$ 上的有限值 r.v.。

(1) $X_n \to_{a.s.} X \Rightarrow X_n \to_p X$；

(2) 若 $X_n \to_p X$，则存在子列 $\{X_{n_k}(\omega): k=1,2,\cdots\}$，使得 $X_{n_k} \to_{a.s.} X$。

证明：

(1) $\forall \varepsilon > 0$，由 $\{|X_n - X| \ge \varepsilon\} \subset \bigcup_{m=n}^{\infty} \{|X_m - X| \ge \varepsilon\}$ 知

$$P(|X_n - X| \ge \varepsilon) \le P\left(\bigcup_{m=n}^{\infty} \{|X_m - X| \ge \varepsilon\}\right),\ n=1,2,\cdots。$$

因 $X_n \to_{a.s.} X$，由定理 5.1.1 知，

$$0 \le \overline{\lim_{n\to\infty}} P(|X_n - X| \ge \varepsilon) \le \lim_{n\to\infty} P\left(\bigcup_{m=n}^{\infty} \{|X_m - X| \ge \varepsilon\}\right) = P\left(\bigcap_{n=1}^{\infty}\bigcup_{m=n}^{\infty} \{|X_m - X| \ge \varepsilon\}\right) = 0。$$

故 $\lim_{n\to\infty} P(|X_n - X| \ge \varepsilon) = 0$，即 $X_n \to_p X$。

(2) 对于 $\forall k \in \mathbb{N}$，$\exists n_k$，使得 $P\left(|X_{n_k} - X| \geq k^{-1}\right) \leq 2^{-k}$。因此

$$\sum_{k=1}^{\infty} P\left(|X_{n_k} - X| \geq k^{-1}\right) \leq \sum_{k=1}^{\infty} 2^{-k} = 1 < \infty 。$$

对于 $\forall \varepsilon > 0, \exists m_\varepsilon \in \mathbb{N}, \ni m_\varepsilon^{-1} < \varepsilon$，对于 $\forall k \geq m_\varepsilon$ 有

$$\left\{|X_{n_k} - X| \geq \varepsilon\right\} \subset \left\{|X_{n_k} - X| \geq k^{-1}\right\},$$

从而有

$$\bigcap_{m=1}^{\infty} \bigcup_{k=m}^{\infty} \left\{|X_{n_k} - X| \geq \varepsilon\right\} \subset \bigcap_{m=m_\varepsilon}^{\infty} \bigcup_{k=m}^{\infty} \left\{|X_{n_k} - X| \geq \varepsilon\right\} \subset \bigcap_{m=m_\varepsilon}^{\infty} \bigcup_{k=m}^{\infty} \left\{|X_{n_k} - X| \geq k^{-1}\right\}。$$

因此，

$$P\left(\bigcap_{m=1}^{\infty} \bigcup_{k=m}^{\infty} \left\{|X_{n_k} - X| \geq \varepsilon\right\}\right) \leq P\left(\bigcap_{m=m_\varepsilon}^{\infty} \bigcup_{k=m}^{\infty} \left\{|X_{n_k} - X| \geq k^{-1}\right\}\right)$$

$$= \lim_{m\to\infty} P\left(\bigcup_{k=m}^{\infty} \left\{|X_{n_k} - X| \geq k^{-1}\right\}\right) \leq \lim_{m\to\infty} \sum_{k=m}^{\infty} P(|X_{n_k} - X| \geq k^{-1}) = 0.$$

再由定理 5.1.1 知 $X_{n_k} \to_{a.s.} X$。

推论 5.1.1 若对 $\forall \varepsilon > 0$ 都有 $\sum_{n=1}^{\infty} P(|X_n - X| \geq \varepsilon) < \infty$，则有 $X_n \to_{a.s.} X$。

例 5.1.1 依概率收敛但不几乎处处收敛的例子。考虑下列定义在 $([0,1], \mathcal{B}_{[0,1]})$ 上的 r.v.序列

$$X_n(\omega) = I_{[\frac{k-1}{2^m}, \frac{k}{2^m}]}(\omega), \quad n = 2^m - 1 + k, k = 1, \cdots, 2^m, m = 0, 1, \cdots,$$

在 $([0,1], \mathcal{B}_{[0,1]})$ 上的几何概率 P 意义下，因 $\lim_{n\to\infty} P(|X_n - 0| > 0) = \lim_{n\to\infty} 2^{-m} = 0$，故 $X_n \to_p 0$。但 $\{\omega : \lim_{n\to\infty} X_n(\omega) = 0\} = \varnothing$，故 $X_n \not\to_{a.s.} 0$。

L^r **收敛（*r* 阶矩收敛，**Convergence in *r*-mean）

定义 5.1.3 设 $X, X_n, n = 1, 2, \cdots$ 都是同一个概率空间 $(\Omega, \mathcal{F}, P)$ 上的有限值 r.v.。$r \in (0, \infty)$。若 $E(|X|^r) < \infty, E(|X_n|^r) < \infty, n = 1, 2, \cdots$ 且 $\lim_{n\to\infty} E|X_n - X|^r = 0$，则称 r.v.序列 $\{X_n : n = 1, 2, \cdots\}$ L^r 收敛于 X，记作 $X_n \to_{L^r} X$。

定理 5.1.4 设 $X_n \to_{L^r} X$，则 $X_n \to_p X$。反之，若 $|X_n| \le Y\ a.s.$，且 $EY^r < \infty$，则由 $X_n \to_p 0$ 可得 $X_n \to_{L^r} 0$。

证明：

若 $X_n \to_{L^r} X$，由 Markov 不等式（或期望的性质）知，$\forall \varepsilon > 0$

$$P(|X_n - X| \ge \varepsilon) = EI_{(|X_n - X| \ge \varepsilon)} \le E\left[\varepsilon^{-r} |X_n - X|^r\right] \to 0,\ \text{as}\ n \to \infty.$$

因此，$X_n \to_p X$。

反之，对于 $\forall \varepsilon > 0$，

$$E|X_n|^r = E\left[I_{(|X_n| \le \varepsilon)} |X_n|^r + I_{(|X_n| > \varepsilon)} |X_n|^r\right] \le \varepsilon^r + E[I_{(|X_n| > \varepsilon)} Y^r]。$$

因 $X_n \to_p 0$，故 $\lim\limits_{n\to\infty} P(|X_n| > \varepsilon) = 0$；而 $EY^r < \infty$，由期望的性质知 $\lim\limits_{n\to\infty} E[I_{(|X_n| > \varepsilon)} Y^r] = 0$。再由 $\varepsilon \to 0$ 得 $\lim\limits_{n\to\infty} E|X_n|^r = 0$，即 $X_n \to_{L^r} 0$。

注：若没有满足 $EY^r < \infty$ 的 Y，使 $|X_n| \le Y\ a.s.$，则由依概率收敛不能推出 L^r 收敛。另外，若将 $X_n \to_p 0$ 换成 $X_n \to_p X$，还应考虑 $E(|X|^r) < \infty$ 是否成立。

定理 5.1.5 $X_n \to_p 0$ 的充分必要条件是 $E\left(\frac{|X_n|}{1+|X_n|}\right) \to 0$。

证明：

函数 $y=\frac{x}{1+x}$ 在 $x\in[0,\infty)$ 上连续且严格单调增，故 $x\ge\varepsilon \Leftrightarrow \frac{x}{1+x}\ge\frac{\varepsilon}{1+\varepsilon}$。因此，

$$\{|X_n|\ge\varepsilon\}=\left\{\frac{|X_n|}{1+|X_n|}\ge\frac{\varepsilon}{1+\varepsilon}\right\},$$

所以 $|X_n|\to_p 0 \Leftrightarrow \frac{|X_n|}{1+|X_n|}\to_p 0$。又 $\left|\frac{|X_n|}{1+|X_n|}\right|\le 1$，$E(1)=1<\infty$，由定理 5.1.4 知，

$$\frac{|X_n|}{1+|X_n|}\to_p 0 \Leftrightarrow E\left(\frac{|X_n|}{1+|X_n|}\right)\to 0。$$

定理 5.1.6 (极限的唯一性) 对于 (1) $X_n \to_{a.s.} X$ 且 $X_n \to_{a.s.} Y$；(2) $X_n \to_p X$ 且 $X_n \to_p Y$；(3) $X_n \to_{L^r} X$ 且 $X_n \to_{L^r} Y$ 之中的任意一种情况，都有 $P(X-Y=0)=1$，即 $X=Y\ a.s.$。

依分布收敛 (Convergence in Distribution/ in Law)、**弱收敛**

定义 5.1.4 设$F(x), F_1(x), F_2(x),\cdots$是一列 d.f.。若对$F(x)$的任一连续点 x 都有

$$\lim_{n\to\infty} F_n(x) = F(x),$$

则称分布函数序列$\{F_n(x): n=1,2,\cdots\}$弱收敛于$F(x)$，记作 $F_n(x) \to_W F(x)$。

若 r.v.序列$X_1, X_2,\cdots$的 d.f. 弱收敛于 r.v.X的 d.f. $F(x)$，则称 r.v.序列$\{X_n: n=1,2,\cdots\}$依分布收敛于X(或$F(x)$)，记作 $X_n \to_d X$ (或$X_n \to_d F(x)$)。

例 5.1.2 设$X_1, X_2,\cdots$是一列单点分布的 r.v.，$P(X_n = n^{-1}) = 1$，X_n的 d.f.为$F_n(x) = I_{[n^{-1},\infty)}(x)$。显然$X_n \to_p 0$。在逐点收敛的意义下 $\lim_{n\to\infty} F_n(x) = I_{(0,\infty)}(x)$，该极限在 0 点处左连续，不是一个 d.f.。但在弱收敛意义下，$F_n(x) \to_W I_{[0,\infty)}(x)$，即$\delta_0$的 d.f.，这与$X_n \to_p 0$一致。此例说明，数学分析中的逐点收敛对于考察 d.f.序列的收敛性过于严苛，引进弱收敛概念是必要的。

定理 5.1.7 若 $X_n \to_p X$，则 $X_n \to_d X$。(逆命题不真)

证明： $\forall \varepsilon > 0$，

$$\begin{aligned} F_n(x) &= P(X_n \le x) = P(\{X_n \le x\} \bigcap \{|X_n - X| < \varepsilon\}) + P(\{X_n \le x\} \bigcap \{|X_n - X| \ge \varepsilon\}) \\ &\le P(X \le x + \varepsilon) + P(|X_n - X| \ge \varepsilon) \\ &= F(x+\varepsilon) + P(|X_n - X| \ge \varepsilon), \end{aligned}$$

$$F_n(x) = P(X_n \le x) \ge P(\{X \le x - \varepsilon\} \bigcap \{|X_n - X| < \varepsilon\}) \ge F(x-\varepsilon) - P(|X_n - X| \ge \varepsilon)。$$

因此，

$$F(x-\varepsilon) \le \varliminf_{n\to\infty} F_n(x) \le \varlimsup_{n\to\infty} F_n(x) \le F(x+\varepsilon)。$$

若 $F(x)$ 在 x 处连续，则 $\lim_{n\to\infty} F_n(x) = F(x)$。

定理 5.1.8 设 c 是一个常数，$\{X_n : n = 1, 2, \cdots\}$ 是一个 r.v.序列。则 $X_n \to_p c$ 等价于 $X_n \to_d c$。

证明：

只须证充分性。设 $F_n(x)$ 为 X_n 的 d.f.，单点分布 δ_c 的 d.f.为 $F(x)=I_{[c,\infty)}(x)$。对 $\forall\varepsilon>0$，

$$\begin{aligned}P(|X_n-c|\ge\varepsilon)&=P(X_n\ge c+\varepsilon)+P(X_n\le c-\varepsilon)\\&\le P(X_n>c+\varepsilon/2)+P(X_n\le c-\varepsilon)=1-F_n(c+\varepsilon/2)+F_n(c-\varepsilon).\end{aligned}$$

由于 $c+\varepsilon/2, c-\varepsilon$ 都是 $F(x)$ 的连续点，且 $F_n(x)\to_w F(x)$，故

$$0\le\overline{\lim_{n\to\infty}}P(|X_n-c|\ge\varepsilon)\le 1-\lim_{n\to\infty}F_n(c+\varepsilon/2)+\lim_{n\to\infty}F(c-\varepsilon)=0,$$

即 $X_n\to_p c$。

四种收敛性的关系

$$\begin{array}{ccccc}
X_n\to_{a.s.}X & \underset{\text{存在}a.s.\text{收敛子列}}{\overset{Th5.1.3}{\Rightarrow\atop\Leftarrow}} & X_n\to_p X & \underset{Th5.1.8\ X\sim\delta_c}{\overset{Th5.1.7}{\Rightarrow\atop\Leftarrow}} & X_n\to_d X \\
 & & Th5.1.4\ \Uparrow\Downarrow\ |X_n|\le Y\text{可积} & & \\
 & & X_n\to_{L^r}X & &
\end{array}$$

随机向量的收敛性

定义 5.1.5 设 $\boldsymbol{X},\boldsymbol{X}_1,\boldsymbol{X}_2,\cdots$ 是定义在某一概率空间 $(\Omega,\mathcal{F},P)$ 上的 k 维 r.vec.。

(i) 若 $P(\lim\limits_{n\to\infty}\boldsymbol{X}_n=\boldsymbol{X})=1$，则称 $\boldsymbol{X}_n\to_{a.s.}\boldsymbol{X}$。

(ii) 若对 $\forall\varepsilon>0$ 有 $\lim\limits_{n\to\infty}P(\|\boldsymbol{X}_n-\boldsymbol{X}\|\geq\varepsilon)=0$，则称 $\boldsymbol{X}_n\to_p\boldsymbol{X}$。

(iii) 若对 $r>0$，$E\|\boldsymbol{X}_n\|_r^r<\infty, E\|\boldsymbol{X}\|_r^r<\infty, \lim\limits_{\delta x\to 0}E\|\boldsymbol{X}_n-\boldsymbol{X}\|_r^r=0$，则称 $\boldsymbol{X}_n\to_{L^r}\boldsymbol{X}$。

(iv) 设 $F(\boldsymbol{x}), F_1(\boldsymbol{x}), F_2(\boldsymbol{x}),\cdots$ 是 k 维 d.f.序列，若在 $F(\boldsymbol{x})$ 的连续点上都有 $\lim\limits_{n\to\infty}F_n(\boldsymbol{x})=F(\boldsymbol{x})$，则称 $F_n(\boldsymbol{x})\to_W F(\boldsymbol{x})$。若 r.vec. $\boldsymbol{X}_1,\boldsymbol{X}_2,\cdots$ 的 d.f.序列弱收敛于 $\boldsymbol{X}$ 的 d.f. $F(\boldsymbol{x})$，则称 $\boldsymbol{X}_n\to_d\boldsymbol{X}$。

其中 $\|(c_1,\cdots,c_k)'\|_r=(\sum_{j=1}^k|c_j|^r)^{1/r}$，$\|\cdot\|=\|\cdot\|_2$。

r.vec.序列 a.s.收敛、依概率收敛，分别等价于所有分量 a.s.收敛、依概率收敛。但所有分量依分布收敛只是 r.vec.依分布收敛的必要条件。r.vec.依分布收敛的充要条件是所有线性组合依分布收敛。

定理 5.1.9 (连续映射定理, Mann & Wald (1943)) 设 $X, X_1, X_2 \cdots$ 是定义在某个概率空间上的 k 维 r.v./r.vec.序列。$g(\cdot):(\mathbb{R}^k, \mathcal{B}_{\mathbb{R}^k}) \to (\mathbb{R}^m, \mathcal{B}_{\mathbb{R}^m})$ 是可测映射，在 $C \in \mathcal{B}_{\mathbb{R}^k}$ 上连续，$P(X \in C) = 1$。

(1) $X_n \to_{a.s.} X \Rightarrow g(X_n) \to_{a.s.} g(X)$；

(2) $X_n \to_p X \Rightarrow g(X_n) \to_p g(X)$；

(3) $X_n \to_d X \Rightarrow g(X_n) \to_d g(X)$。

定理 5.1.10 (Slusky) 设 $X_n \to_d X$, $Y_n \to_p c$，其中 X 是一个 r.v.，c 是一个常数。则有

(1) $X_n \pm Y_n \to_d X \pm c$；

(2) $X_n \times Y_n \to_d aX$；

(3) 若 $c \neq 0$ 则 $X_n / Y_n \to_d X / c$。

证明：

设 X 的 d.f.为 $F(x)$，则 $X + c$ 的 d.f.为 $F(x - c)$。

(1) $\forall z \in \mathbb{R}, \varepsilon > 0$，有

$$\begin{aligned} G_n(z) &= P(X_n + Y_n \le z) = P(X_n + Y_n \le z, |Y_n - c| < \varepsilon) + P(X_n + Y_n \le z, |Y_n - c| \ge \varepsilon) \\ &\le P(X_n \le z - (c - \varepsilon)) + P(|Y_n - c| \ge \varepsilon). \end{aligned}$$

若 $z-(c-\varepsilon_1)$ 是 $F(x)$ 的连续点，则

$$\overline{\lim_{n\to\infty}} G_n(z) \le \lim_{n\to\infty} F_n(z-(c-\varepsilon_1)) = F(z-(c-\varepsilon_1))。$$

又因

$$1 - G_n(z) = P(X_n + Y_n > z) \le P(X_n > z - (c+\varepsilon)) + P(|Y_n - c| \ge \varepsilon),$$

知

$$G_n(z) \ge F_n(z-(c+\varepsilon)) - P(|Y_n - c| \ge \varepsilon)。$$

若 $z-(c+\varepsilon_2)$ 是 $F(x)$ 的连续点，则

$$\underline{\lim_{n\to\infty}} G_n(z) \ge \lim_{n\to\infty} F_n(z-(c+\varepsilon_2)) = F(z-(c+\varepsilon_2))。$$

因此

$$F(z-c-0) \le \varliminf_{n\to\infty} G_n(z) \le \varlimsup_{n\to\infty} G_n(z) \le F(z-c)。$$

所以，若 $F(z-c)$ 在 z 处连续，则有 $\lim\limits_{n\to\infty} G_n(z) = F(z-c)$，即 $X_n + Y_n \to_d X + c$。

定理 5.1.11 (Cramér-Wold) k 维 r.vec.序列 $\boldsymbol{X}_n \to_d \boldsymbol{X}$，当且仅当 $\boldsymbol{c}'\boldsymbol{X}_n \to_d \boldsymbol{c}'\boldsymbol{X}$, $\forall \boldsymbol{c} \in \mathbb{R}^k$。

§ 5.2 大数定律

定义 5.2.1 对于 r.v.序列$\{X_n : n=1,2,\cdots\}$，记$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i, n=1,2,\cdots$。若当$n\to\infty$时，有$\bar{X}_n - E(\bar{X}_n) \to_p 0$，则称$\{X_n : n=1,2,\cdots\}$服从(弱)大数定律(*Weak Law of Large Numbers*, WLLN / LLN)；若有 $\bar{X}_n - E(\bar{X}_n) \to_{a.s.} 0$，则称$\{X_n : n=1,2,\cdots\}$服从强大数定律(*Strong Law of Large Numbers*, SLLN)。

大数定律源于对频率稳定性的解释。

定理 5.2.1 (Bernoulli LLN) 设一次 Bernoulli 试验中的成功概率为 p。在相同条件下独立地重复 n 次，记成功次数为 S_n，成功的频率为 $\bar{X}_n = \frac{S_n}{n}$。则当$n\to\infty$时有

$$\bar{X}_n - p \to_p 0。$$

较一般的大数定律描述的是 r.v.序列平均值的稳定性。

定理 5.2.2 (Chebyshev LLN) 设 $X_1, X_2, \cdots$ 是一列两两不相关的随机变量序列，各个变量的方差存在且有共同上界，即 $\mathrm{var}(X_i) \le c,\ i = 1, 2, \cdots$。则当 $n \to \infty$ 时有

$$\bar{X}_n - E(\bar{X}_n) \to_p 0 \text{。}$$

推论 5.2.1 设 $X_1, X_2, \cdots$ i.i.d.，$E(X_1) = \mu,\ \mathrm{var}(X_1) = \sigma^2 < \infty$，记 $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$。则当 $n \to \infty$ 时有 $\bar{X}_n - \mu \to_p 0$ 或 $\bar{X}_n \to_p \mu$。

其他形式的大数定律

定理 5.2.3 (Markov LLN) 设 $X_1, X_2, \cdots$ 是一列随机变量序列，满足 $\frac{1}{n^2}\mathrm{var}\left(\sum_{i=1}^{n} X_i\right) \to 0$。则当 $n \to \infty$ 时有 $\bar{X}_n - E(\bar{X}_n) \to_p 0$。

定理 5.2.4 (Khinchin(辛钦) LLN) 设 $X_1, X_2, \cdots$ i.i.d.，若 $EX_1 = \mu$ 存在，则当 $n \to \infty$ 时，

$\bar{X}_n \to_p \mu$。

大数定律的应用

例 5.2.1 (Monte Carlo 积分) 设 $0 \le f(x) \le M,\ \forall x \in [0,1]$。近似计算 $J = \int_0^1 f(x)dx$。

方法一

若 $X_1, \cdots, X_n$ i.i.d. $U(0,1)$，则 $f(X_1), \cdots, f(X_n)$ i.i.d.，它们共同的期望为

$$Ef(X_1) = \int_0^1 f(x) \cdot 1\, dx = J,$$

共同的方差有限。由推论 5.2.1 知，当 $n \to \infty$ 时，有 $\frac{1}{n}\sum_{i=1}^{n} f(X_i) \to_p J$。因此，若按 $U(0,1)$ 独立地反复产生随机数 $x_1, \cdots, x_n$，当 n 足够大时，就可以用 $\frac{1}{n}\sum_{i=1}^{n} f(x_i)$ 来近似 J。

方法二

若 $X_1, Y_1, \cdots, X_n, Y_n$ i.i.d. $U(0,1)$。记

$$Z_i = \begin{cases} 1, & \text{if } Y_i \le f(X_i)/M, \\ 0, & \text{else}, \end{cases} \quad i = 1, \cdots, n。$$

则 $Z_1, \cdots, Z_n$ i.i.d. $B(1, p)$，其中

$$p = P(Y_1 \le \frac{f(X_1)}{M}) = \int_0^1 \left(\int_0^{f(x)/M} 1 dy \right) dx = \frac{J}{M}。$$

由定理 5.2.1 知，当 $n \to \infty$ 时，有 $\frac{1}{n}\sum_{i=1}^{n} Z_i \to_p p = \frac{J}{M}$。

故若独立地反复产生随机数 $(x_1, y_1), \cdots, (x_n, y_n)$，计算 $z_1, \cdots, z_n$，当 n 足够大时，就可以用 $M \cdot \frac{1}{n}\sum_{i=1}^{n} z_i$ 来近似 J。

类似地，通过 Buffon 投针试验近似计算 π 的合理性，也可用定理 5.2.1 来解释。

强大数定律

定理 5.2.5 (Borel,1909) 设 r.v. $X_1, X_2, \cdots$ i.i.d.，$EX_1^4 < \infty$，则 $\{X_n : n = 1, 2, \cdots\}$ 服从强大数定律。

证明：

记 $\mu = E(X_1), \sigma^2 = \mathrm{var}(X_1)$。根据推论 5.1.1，只须证明，对 $\forall \varepsilon > 0$ 有

$$\sum_{n=1}^{\infty} P\left(\left|\bar{X}_n - \mu\right| \geq \varepsilon\right) < \infty 。$$

由 Markov 不等式知

$$\begin{aligned}
&\sum_{n=1}^{\infty} P\left(|\bar{X}_n - \mu| \geq \varepsilon\right) \leq \sum_{n=1}^{\infty} \frac{1}{(n\varepsilon)^4} E\left[\sum_{i=1}^{n}(X_i - \mu)\right]^4 \\
&= \sum_{n=1}^{\infty} \frac{1}{(n\varepsilon)^4}\left[E\sum_{i=1}^{n}(X_i - \mu)^4 + \sum_{1 \leq i \neq j \leq n} E(X_i - \mu)^2 (X_j - \mu)^2\right] \\
&= \sum_{n=1}^{\infty} \frac{1}{(n\varepsilon)^4}\left[nE(X_1 - \mu)^4 + n(n-1)\sigma^4\right] < \infty.
\end{aligned}$$

由此即得 $\bar{X}_n \to_{a.s.} \mu$。

***定理 5.2.6** (Kolmogorov 不等式) 设 $X_1, X_2, \cdots$ 是独立 r.v.序列， $\mathrm{var}(X_n) < \infty, n = 1, 2, \cdots$，

记 $S_k = \sum_{j=1}^{k} X_j, k = 1, 2, \cdots$ 则对 $\forall \varepsilon > 0$ 有

$$P\left(\max_{1 \le k \le n} \left|S_k - E(S_k)\right| \ge \varepsilon\right) \le \frac{\mathrm{var}(S_n)}{\varepsilon^2} = \frac{1}{\varepsilon^2} \sum_{i=1}^{n} \mathrm{var}(X_i)\text{。}$$

***定理 5.2.7** (Kolmogorov) 设 $X_1, X_2, \cdots$ 是独立 r.v.序列，且 $\sum_{n=1}^{\infty} \frac{\mathrm{var}(X_n)}{n^2} < \infty$，则当 $n \to \infty$ 时有

$$\bar{X}_n - E(\bar{X}_n) \to_{a.s.} 0\text{。}$$

i.i.d.序列的强大数定律只需要期望存在即可，条件等同于辛钦 LLN。

***定理 5.2.8** (Kolmogorov 强大数定律) 设 $X_1, X_2, \cdots$ 是 i.i.d.的 r.v 序列， $E(X_1) = \mu$ 存在，

则有 $\bar{X}_n \to_{a.s.} \mu$。

证明：

不妨设 $\mu=0$。分解 $X_k=U_k+V_k$，其中 $U_k=X_kI_{(|X_k|\le k)},V_k=X_kI_{(|X_k|>k)}$。只要证明 $\{U_n\}$ 服从强大数定律，而 $\{V_n\}$ 有有限多个非零的概率为 1。

§ 5.3 依分布收敛的性质

例 5.3.1 (1) $X_n \sim U(-n,n), n=1,2,\cdots$。其 p.d.f. 序列

$$p_n(x)=\frac{1}{2n}I_{(-n,n)}(x)\to f(x)\equiv 0,\ \forall x\in\mathbb{R}\text{（极限非 p.d.f.）},$$

其 d.f.序列

$$F_n(x)=\begin{cases}0, & x\le -n,\\ \dfrac{x+n}{2n}, & -n<x\le n,\\ 1, & x>n,\end{cases}\to F(x)\equiv\frac{1}{2},\ \forall x\in\mathbb{R}\text{（极限非 d.f.，也不弱收敛于某 d.f.）。}$$

(2) $X_n \sim U(-n^{-1},n^{-1}), n=1,2,\cdots$。其 p.d.f. 序列

$$p_n(x)=\frac{n}{2}I_{(-n^{-1},n^{-1})}(x)\to f(x)=\infty\cdot I_{\{0\}}(x),\ \forall x\in\mathbb{R}\text{（极限非 p.d.f.）},$$

其 d.f.序列

$$F_n(x)=\begin{cases}0, & x\le -n^{-1}\\ \frac{n}{2}(x+\frac{1}{n}), & x\in(-n^{-1},n^{-1}]\\ 1, & x>n\end{cases}\to F(x)=\begin{cases}0, & x<0,\\ \frac{1}{2}, & x=0,\\ 1, & x>0,\end{cases}$$（极限非 d.f.，但 $F_n(x)\to_W F_{\delta_0}(x)$）。

定理 5.3.1 (Skorohod) 设 $F(x),F_n(x),n=1,2,\cdots$ 都是 $\mathbb{R}$ 上的 d.f.。若 $F_n(x)\to_W F(x)$，则存在概率空间 $(\Omega,\mathcal{F},P)$ 及其上的 r.v.序列 $X,X_n,n=1,2,\cdots$，其 d.f.分别为 $F(x),F_n(x),n=1,2,\cdots$，使得 $X_n(\omega)\to X(\omega),\ \forall\omega\in\Omega$ (点点收敛)。

证明：

记 d.f.的广义逆为 $F^{-1}(x)=\inf\{y:F(y)\ge x\},F_n^{-1}(x)=\inf\{y:F_n(y)\ge x\},\forall x\in(0,1)$，$D$ 为 $F^{-1}(x)$ 的不连续点集。因 $F^{-1}(x)$ 递增，故 D 是可列集。取 $y\in\overline{D}$，必存在 $F(x)$ 的连续点 x,x'，使得 $x<F^{-1}(y)<x'$。由广义逆性质知，$F(x)<y<F(x')$。由 $F_n(x)\to_W F(x)$ 知，当 n 充分大

时，$F_n(x) < y < F_n(x')$，再由广义逆性质知 $x < F_n^{-1}(y) < x'$。故

$$|F_n^{-1}(y) - F^{-1}(y)| \le x' - x,$$

由 $x' - x \to 0$ 得 $F_n^{-1}(y) \to F^{-1}(y),\ \forall y \in \bar{D}$。

设 U 是定义在某概率空间 $(\Omega, \mathcal{F}, P)$ 上 $U(0,1)$ 分布的 r.v.，令

$$X = F^{-1}(U) I_{\bar{D}}(U),\ X_n = F_n^{-1}(U) I_{\bar{D}}(U), n = 1, 2, \cdots。$$

由 $F_n^{-1}(y) \to F^{-1}(y),\ \forall y \in \bar{D}$ 知，$X_n(U(\omega)) \to X(U(\omega)),\ \forall \omega \in \Omega$。而 $X, X_n, n = 1, 2, \cdots$ 的 d.f.分别为 $F(x), F_n(x), n = 1, 2, \cdots$。

定理 5.3.2 (Helly-Bray) 设 $F(x), F_n(x), n = 1, 2, \cdots$ 都是 $\mathbb{R}$ 上的 d.f.。则 $F_n(x) \to_W F(x)$ 当且仅当对任意有界连续函数 $f(x)$ 有 $\lim\limits_{n\to\infty} \int_{\mathbb{R}} f(x) dF_n(x) \to \int_{\mathbb{R}} f(x) dF(x)$。

用 Skorohod 定理和积分的有界收敛性证。这个定理说明，$F_n(x) \to_W F(x)$ 蕴含着特征函数 $\varphi_n(t) \to \varphi(t), \forall t \in \mathbb{R}$。

定理 5.3.3 (Lévy-Cramér 连续性定理) 设 $\varphi_n(t)$ 是 d.f. $F_n(x)$ 的特征函数，$n=1,2,\cdots$。

(1) 设 $F(x)$ 是 d.f.，$\varphi(t)$ 是其特征函数。若 $F_n(x)\to_W F(x)$，则 $\varphi_n(t)\to\varphi(t),\forall t\in\mathbb{R}$，且在任意有限区间内收敛是一致的。

(2) 若 $\varphi_n(t)\to\varphi(t),\forall t\in\mathbb{R}$，且 $\varphi(t)$ 在 $t=0$ 处连续，则 $\varphi(t)$ 必是某 d.f. $F(x)$ 的特征函数，且 $F_n(x)\to_W F(x)$。

定理 5.3.3 的应用：

1) 辛钦 LLN (定理 5.2.4)：$X_1,X_2,\cdots$ i.i.d.，$E(X_1)=\mu$ 存在，则 $\overline{X}_n\to_d\mu$。

2) (CLT) $X_1,X_2,\cdots$ i.i.d.，$E(X_1)=\mu,\operatorname{var}(X_1)=\sigma^2<\infty$，则 $\sqrt{n}(\overline{X}_n-\mu)/\sigma\to_d N(0,1)$。

3) X,Y i.i.d., $E(X)=0,\operatorname{var}(X)=1$。则 $X+Y$ 与 $X-Y$ 相互独立当且仅当 $X\sim N(0,1)$。

定理 5.3.4 (Scheffé 定理) 设 $f_n(x), n=1,2,\cdots$ 是$\mathbb{R}^k$上的一列 p.d.f.。若 $\lim\limits_{n\to\infty} f_n(x) \to f(x)$ $a.e.\ \lambda_k$(k 维 Lebesgue 测度)，且 $f(x)$ 是$\mathbb{R}^k$上的 p.d.f.，则 $\lim\limits_{n\to\infty}\int_{\mathbb{R}^k} |f_n(x)-f(x)|\,dx = 0$。

即 $f_n(x)$ 相应的 d.f.列 $F_n(x) \to_W F(x)$，$F(x)$ 是 $f(x)$ 的 d.f.。

§ 5.4 中心极限定理

本节介绍独立 r.v.之和的中心极限定理(Central Limit Thereoms, CLTs)。设 $X_1, X_2, \cdots$ 是一个**相互独立**的 r.v.序列，其前 n 项之和记为 $S_n = X_1 + \cdots + X_n$，平均值记为 $\bar{X}_n = \dfrac{S_n}{n}$。记 $E(X_i) = \mu_i, \operatorname{var}(X_i) = \sigma_i^2, i = 1, 2, \cdots$。记

$$B_n^2 = \operatorname{var}(S_n) = \sigma_1^2 + \cdots + \sigma_n^2,$$

而 $\operatorname{var}(\bar{X}_n) = \dfrac{1}{n^2} B_n^2$。对 S_n、$\bar{X}_n$ 标准化，即

$$Y_n = \frac{S_n - E(S_n)}{B_n} = \frac{\bar{X}_n - E(\bar{X}_n)}{B_n / n} = \frac{\sum_{i=1}^n (X_i - \mu_i)}{\sqrt{\sigma_1^2 + \cdots + \sigma_n^2}}。$$

本节的结论说明，在一定条件下，当 $n \to \infty$ 时，$Y_n \to_d N(0,1)$。

中心极限定理解释了为何在很多场合适合用正态分布对 r.v.建模，也对 $\bar{X}_n$ 的收敛性给出了比大数定律更丰富的结论。

一、独立同分布随机变量之和的中心极限定理

定理 5.4.1 (De Moivre – Laplace CLT) 在定理 4.3.1 条件下，若 $0<p<1$，则对 $\forall x\in\mathbb{R}$ 有

$$\lim_{n\to\infty}P\left(\frac{S_n-np}{\sqrt{np(1-p)}}\le x\right)=\lim_{n\to\infty}P\left(\frac{\overline{X}_n-p}{\sqrt{p(1-p)/n}}\le x\right)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt=\Phi(x)\text{。}$$

即当 $n\to\infty$ 时，$Y_n\to_d N(0,1)$。

定理 5.4.2 (Lindeberg – Lévy CLT) 设 $X_1,X_2,\cdots$ i.i.d.，$E(X_1)=\mu,\ 0<\mathrm{Var}(X_1)=\sigma^2<\infty$。则对 $\forall x\in\mathbb{R}$ 有

$$\lim_{n\to\infty}P\left(\frac{S_n-n\mu}{\sqrt{n\sigma^2}}\le x\right)=\lim_{n\to\infty}P\left(\frac{\overline{X}_n-\mu}{\sigma/\sqrt{n}}\le x\right)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-y^2/2}dy=\Phi(x)\text{，}$$

即当 $n\to\infty$ 时，$Y_n\to_d N(0,1)$。

证明：(见第 12 周习题解答)

令 $Z_i = \dfrac{X_i - \mu}{\sigma}$，则 $E(Z_1) = 0, E(Z_1^2) = 1$，$Z_1, Z_2, \cdots$ i.i.d.。故由推论 4.2.1 知，Z_1 的特征函数 $\psi(t)$ 在 $t = 0$ 的邻域内有展式

$$\varphi(t) = 1 - \frac{t^2}{2} + o(t^2)\text{。}$$

$Y_n = \dfrac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} = \dfrac{1}{\sqrt{n}}(Z_1 + \cdots + Z_n)$ 的特征函数

$$\varphi_n(t) = [\varphi(\frac{t}{\sqrt{n}})]^n = \left[1 - \frac{t^2}{2n} + o(\frac{t^2}{n})\right]^n\text{。}$$

对于 $\forall t \in \mathbb{R}$，其极限

$$\lim_{n\to\infty} \varphi_n(t) = e^{-\frac{t^2}{2}}\text{。}$$

该极限显然是 $N(0,1)$ 的特征函数，由连续性定理 5.3.3 知，$Y_n \to_d N(0,1)$。

注：

1. 显然，定理 5.4.1 是定理 5.4.2 的特例，是专门针对二项分布序列的 CLT，历史上先于定理 5.4.2 出现。

2. 若 $X_1,\cdots,X_n$ i.i.d.，一般情况下 $S_n=\sum_{i=1}^{n}X_i$ 或者 $\bar{X}_n=S_n/n$ 的精确分布不容易求。但由定理 5.4.2，当 n 足够大时可求得它们的近似分布，即

$$\frac{S_n-n\mu}{\sqrt{n}\sigma}\dot{\sim}N(0,1),\quad S_n\dot{\sim}N(n\mu,n\sigma^2);\quad \frac{\bar{X}_n-\mu}{\sigma/\sqrt{n}}\dot{\sim}N(0,1),\quad \bar{X}_n\dot{\sim}N(\mu,\frac{\sigma^2}{n}).$$

因而有

$$P\left(\left|\bar{X}_n-\mu\right|\le\varepsilon\right)=P\left(\frac{\left|\bar{X}_n-\mu\right|}{\sigma/\sqrt{n}}\le\frac{\varepsilon}{\sigma/\sqrt{n}}\right)\approx 2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right)-1\text{。}$$

中心极限定理的应用

例 5.4.1 (1) 生成 $N(0,1)$ 随机数。

若 $X_1,\cdots,X_n$ i.i.d. $U(0,1)$，则 $\mu=E(X_1)=\frac{1}{2}$，$\sigma^2=\mathrm{var}(X_1)=\frac{1}{12}$，由定理 5.4.1 知，当 n 较大时，$S_n \dot{\sim} N\left(\frac{n}{2},\frac{n}{12}\right)$。在 SAS 等统计软件中，常用 $S_{12}-6$ 生成 $N(0,1)$ 的随机数。

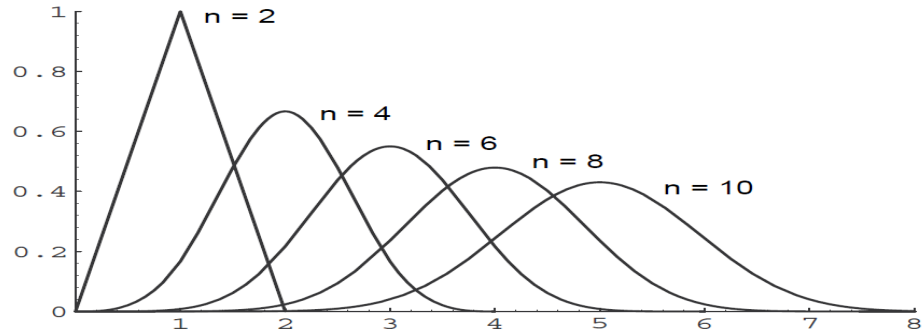

Figure 7.6: Convolution of n uniform densities.

(2) 高尔顿板钉实验结果的解释

二项分布概率的近似计算。设 $X \sim B(n,p)$。

- 用 Poisson 分布近似。适用条件：n 较大，np 较小，对于较小的 k，有

$$P(X=k) \approx \frac{(np)^k}{k!}e^{-np}, \quad P(X \le k) \approx \sum_{i=0}^{k} \frac{(np)^i}{i!}e^{-np} 。$$

- 用正态分布近似。适用条件：n 较大，np 与 $n(1-p)$ 都不太小（通常要求大于 5）时，

$$P(k_1 < X \le k_2) = P\left(\frac{k_1 - np}{\sqrt{np(1-p)}} < \frac{X - np}{\sqrt{np(1-p)}} \le \frac{k_2 - np}{\sqrt{np(1-p)}}\right) \approx \Phi\left(\frac{k_2 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k_1 - np}{\sqrt{np(1-p)}}\right).$$

连续性修正：对于非负整数 k，

$$P(X \le k) \approx \Phi\left(\frac{k+0.5-np}{\sqrt{np(1-p)}}\right), \qquad P(X < k) \approx \Phi\left(\frac{k-0.5-np}{\sqrt{np(1-p)}}\right),$$

$$P(X=k) \approx \Phi\left(\frac{k+0.5-np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k-0.5-np}{\sqrt{np(1-p)}}\right) \approx \phi\left(\frac{k-np}{\sqrt{np(1-p)}}\right)\frac{1}{\sqrt{np(1-p)}}.$$

例 5.4.2 某保险公司有一项针对一个特定人群设计的人寿保险业务。该保险每一单的保险费是 1200 元，若在指定保险期间投保人死亡，则其家属可得 20 万元。已知该人群在保险设计期间的死亡率为 0.003。假定每个投保人只买一份保险。

(1) 如果该公司卖出这种保险 5000 份，求该公司在这项业务中亏本的概率。

(2) 若要以 95%的把握保证该公司此项业务的盈利不少于 400 万元，那么至少应该销售出多少份保险？

解：

设共有 n 人投保，假定各投保人是否死亡相互独立。用 $X_i=1$ 表示第 i 个投保人在保险期间死亡，用 $X_i=0$ 表示未死亡，则 $X_1,\cdots,X_n$ i.i.d. $B(1,0.003)$。记 $S_n=\sum_{i=1}^{n}X_i$。

(1) “该公司此项业务亏本”即“$2\cdot 10^5 S_n \ge 1200n$”。当 $n=5000$ 时，由定理 4.4.2 知

$$P(2\cdot 10^5 S_{5000}\ge 1200\cdot 5000)$$

$$=P(S_{5000}\ge 30)\approx 1-\Phi\left(\frac{30-0.5-0.003\cdot 5000}{\sqrt{5000\cdot 0.003\cdot(1-0.003)}}\right)=1-\Phi(3.6978)\approx 0.0001\ .$$

(2)“盈利不少于 400 万元”可表示为“$1200n-2\cdot 10^5 S_n \ge 4\cdot 10^6$”。要求最小的 n，使

$$P(1200n-2\cdot 10^5 S_n \ge 4\cdot 10^6) \ge 95\% \quad . \tag{1}$$

由定理 4.4.2 知

$$P(1200n-2\cdot 10^5 S_n \ge 4\cdot 10^6) = P(S_n \le 0.006n-20)$$
$$\approx \Phi\left(\frac{(0.006n-20)+0.5-0.003n}{\sqrt{n\cdot 0.003\cdot(1-0.003)}}\right) = \Phi\left(\frac{0.003n-19.5}{\sqrt{0.002991n}}\right).$$

当 $\dfrac{0.003n-19.5}{\sqrt{0.002991n}} \ge z_{0.95} = 1.64$ 时，(1)式成立。又因 $\dfrac{0.003n-19.5}{\sqrt{0.002991n}}$ 关于 n 单调增，故满足 (1) 式的最小 $n = 9398.396 \approx 9399$。

例 5.4.3 有一枚质地均匀的硬币，(1)需掷多少次才能保证正面出现的频率在 0.4 至 0.6 之间的概率不少于 90%？(2) 若掷了 900 次，那么我们能有不少于 95%把握说，用频率近似概率的最大绝对误差不超过多少？

解：

记掷 n 次钱币正面出现的次数为 S_n。因钱币材质均匀，可假定每次掷得正面的概率为 0.5；同时，可假定每次抛掷相互独立。故有 $S_n \sim B(n,0.5)$。

(1) $\{0.4 \le S_n/n \le 0.6\}$ 表示事件“正面出现的频率在 0.4 至 0.6 之间”，现在要求 n 使

$$P(0.4 \le \frac{S_n}{n} \le 0.6) = P(0.4n \le S_n \le 0.6n) \ge 0.90. \tag{2}$$

由定理 5.4.2 知

$$P(0.4n \le S_n \le 0.6n) \approx \Phi\left(\frac{0.6n+0.5-0.5n}{\sqrt{n\cdot 0.5\cdot 0.5}}\right) - \Phi\left(\frac{0.4n-0.5-0.5n}{\sqrt{n\cdot 0.5\cdot 0.5}}\right) = 2\Phi\left(\frac{0.1n+0.5}{0.5\sqrt{n}}\right) - 1。$$

故当 $\dfrac{0.1n+0.5}{0.5\sqrt{n}} \ge z_{0.95} = 1.64$ 时，(2) 式成立。最小的 $n = 56.80 \approx 57$。

(2) 求 c，满足

$$P\left(\left|\frac{S_n}{n} - 0.5\right| \le c\right) \ge 95\%.$$

由定理 5.4.2 知

$$P\left(\left|\frac{S_n}{n}-0.5\right|\le c\right)=P\left(\frac{|S_n/n-0.5|}{\sqrt{0.5\cdot 0.5/n}}\le\frac{c}{\sqrt{0.5\cdot 0.5/n}}\right)\approx 2\Phi\left(\frac{c}{\sqrt{0.5\cdot 0.5/n}}\right)-1,$$

故 $\dfrac{c}{0.5/\sqrt{n}}=z_{0.975}=1.96$，即 $c=1.96\cdot 0.5/\sqrt{n}=0.032667$。

思考：对于一枚不均匀的硬币，设一次掷得正面的概率为 p，则(2)的答案是什么？

例 5.4.4 Poisson 分布概率的近似计算。设 $X\sim \mathrm{Poi}(\lambda)$。当 λ 很大时，也可用正态分布近似。

(1) 若 λ 为整数，则 X 与 $S_\lambda=\sum_{i=1}^{\lambda}X_i$ 同分布，其中 $X_1,\cdots,X_\lambda$ i.i.d. Poi(1)。因 $E(X_1)=1$，$\mathrm{var}(X_1)=1$，由定理 4.4.1 知，当 λ 较大时，

$$P(X\le a)=P(S_\lambda\le a)=P\left(\frac{S_\lambda-\lambda\cdot 1}{\sqrt{\lambda\cdot 1}}\le\frac{a-\lambda}{\sqrt{\lambda}}\right)\approx\Phi\left(\frac{a-\lambda}{\sqrt{\lambda}}\right)。$$

连续性修正的方法与二项分布的情况类似。

(2) 若 λ 非整数，则由下面的独立不同分布 r.v.之和的 CLT 可知，上述近似公式亦成立。

二、独立不同分布随机变量之和的中心极限定理

定理 5.4.3 (Lindeberg) 设 $X_1, X_2, \cdots$ 是独立 r.v.序列，$E(X_i)=\mu_i, \operatorname{var}(X_i)=\sigma_i^2, i=1,2,\cdots$。若该序列满足 Lindeberg 条件：对 $\forall \tau>0$，有

$$\lim_{n\to\infty}\frac{1}{\tau^2 B_n^2}\sum_{i=1}^{n}E\left[(X_i-\mu_i)^2 I(|X_i-\mu_i|>\tau B_n)\right]=0,$$

则对 $\forall x\in\mathbb{R}$ 有

$$\lim_{n\to\infty}P\left(\frac{S_n-E(S_n)}{B_n}\le x\right)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-y^2/2}dy=\Phi(x)。$$

即当 $n\to\infty$ 时，$Y_n\to_d N(0,1)$。

注：

- 若 $X_1, X_2, \cdots$ i.i.d.，$\mu_i\equiv\mu, \sigma_i^2\equiv\sigma^2\in(0,\infty)$，则容易验证该 r.v.序列满足 Lindeberg 条件，故定理 5.4.2 可视为定理 5.4.3 的特例。

- 若 $X_1, X_2, \cdots$ 相互独立不一定同分布，但 $\mu_i \equiv \mu, \sigma_i^2 \equiv \sigma^2 \in (0,\infty)$，则该 r.v.序列也满足 Lindeberg 条件，故亦有定理 5.4.2（或定理 5.4.3）的结论。

定理 5.4.4 (Liapounov) 将定理 5.4.3 中 Lindeberg 条件替换为：$\exists \delta > 0$，使独立 r.v.序列满足

$$\lim_{n\to\infty} \frac{1}{B_n^{2+\delta}} \sum_{i=1}^{n} E|X_i - \mu_i|^{2+\delta} = 0,$$

则定理 5.4.3 的结论依然成立。

注：

- 由 Liapounov 条件可推出 Lindeberg 条件，反之不然。
- Liapounov 条件往往比 Lindeberg 条件容易验证。

多元中心极限定理

Delta 方法